

Speech to Sign Language Translation with 3D Avatar Integration

Khang Nhut Lam^{1✉}, An Trong La¹, Van Lam Le¹, and Jugal Kalita²

¹ Can Tho University, Can Tho, Vietnam

² University of Colorado, Colorado Springs, USA

Abstract. Chuyển đổi giọng nói tiếng Việt sang Ngôn ngữ Ký hiệu Việt Nam (Vietnamese Sign Language - VSL) là một bài toán nhiều thách thức do sự khan hiếm dữ liệu cho học máy và sự khác biệt về cấu trúc cú pháp giữa hai ngôn ngữ. Trong nghiên cứu này, chúng tôi triển khai một hệ thống chuyển đổi từ giọng nói sang ngôn ngữ ký hiệu Việt Nam, trong đó các mô-đun bao gồm giọng nói tiếng Việt được nhận dạng và chuyển thành văn bản, văn bản sau đó được chuyển đổi sang cấu trúc ngôn ngữ ký hiệu ở mức gloss, và cuối cùng chuỗi câu VSL được ánh xạ sang biểu diễn SiGML để hiển thị bằng avatar 3D. Ở giai đoạn đầu, mô-đun nhận dạng giọng nói sử dụng PhoWhisper để chuyển đổi giọng nói sang văn bản có độ chính xác cao và ranh giới câu phù hợp, qua đó hạn chế sự lan truyền lỗi sang bước dịch. Đối với mô-đun chuyển văn bản sang VSL, chúng tôi tập trung giải quyết bài toán dữ liệu ít tài nguyên thông qua các chiến lược tăng cường dữ liệu dựa trên mô hình ngôn ngữ lớn, kết hợp truy hồi ngữ nghĩa và prompting có điều hướng bởi luật cú pháp. Dữ liệu tổng hợp thu được được sử dụng để huấn luyện và so sánh nhiều mô hình dịch dựa trên kiến trúc Transformer trong các thiết lập kết hợp dữ liệu khác nhau, phản ánh đặc điểm và mục tiêu của từng mô hình. Cuối cùng, chuỗi gloss đầu ra được ánh xạ sang chuỗi SiGML và trực quan hóa bằng avatar 3D JASigning. Kết quả cho thấy việc kết hợp mô-đun ASR, tăng cường dữ liệu có kiểm soát và lựa chọn mô hình dịch phù hợp là một hướng tiếp cận triển vọng cho bài toán chuyển đổi giọng nói tiếng Việt sang Ngôn ngữ Ký hiệu Việt Nam trong bối cảnh tài nguyên hạn chế.

1 Introduction

Các em cần giải thích "gloss" là gì và cho ví dụ minh họa ở cả tiếng Anh và tiếng Việt

Khả năng tiếp cận thông tin của cộng đồng người khiếm thính vẫn còn hạn chế do phần lớn nội dung giao tiếp hằng ngày tồn tại dưới dạng ngôn ngữ nói hoặc văn bản viết. Nhưng đối với người khiếm thính, ngôn ngữ ký hiệu là phương thức giao tiếp tự nhiên đối với họ, nhưng hiện nay vẫn chưa được tích hợp rộng rãi trong các hệ thống truyền tải thông tin. Theo Điều tra Quốc gia về Người khuyết tật 2016 do Tổng cục Thống kê Việt Nam phối hợp với UNICEF thực hiện, dựa trên tỷ lệ người trưởng thành gặp khó khăn về nghe được báo cáo

trong khảo sát có 1,37% dân số từ 18 tuổi trở lên, số người khiếm thính hoặc suy giảm thính lực ảnh hưởng đáng kể đến giao tiếp tại Việt Nam được ước tính khoảng 890.000 người. Thực tế này cho thấy một bộ phận đáng kể dân số đang đối mặt với rào cản nghiêm trọng trong tiếp cận thông tin, giáo dục và các dịch vụ công, đặc biệt khi ngôn ngữ ký hiệu vẫn chưa được tích hợp rộng rãi trong các hệ thống truyền thông và công nghệ hỗ trợ hiện nay.

Những tiến bộ gần đây của các mô hình học sâu, đặc biệt là các kiến trúc dựa trên Transformer, đã mang lại hiệu quả vượt trội cho nhiều bài toán xử lý ngôn ngữ như dịch máy thần kinh và sinh chuỗi văn bản [50]. Các mô hình này cho phép xây dựng các hệ thống chuyển đổi ngôn ngữ linh hoạt, có khả năng áp dụng trong nhiều bối cảnh ứng dụng khác nhau. Trong các hệ thống chuyển đổi từ giọng nói hoặc văn bản sang ngôn ngữ ký hiệu, kiến trúc pipeline nhiều tầng thường được áp dụng, trong đó chuỗi gloss đóng vai trò là biểu diễn trung gian giúp chuẩn hóa đầu ra và tách biệt xử lý ngôn ngữ khỏi giai đoạn tổng hợp ký hiệu. Gloss là dạng biểu diễn ký hiệu trung gian ở mức từ hoặc nhân ký hiệu, thường được viết bằng chữ in hoa, trong đó mỗi gloss tương ứng với một ký hiệu tay và không nhất thiết phản ánh đầy đủ ngữ pháp của ngôn ngữ nói. Ví dụ, câu tiếng Anh “I go to school” có thể được biểu diễn dưới dạng gloss là I GO SCHOOL trong ASL, và câu tiếng Việt “Tôi đi học” tương ứng với chuỗi gloss TÔI ĐI HỌC trong Ngôn ngữ Ký hiệu Việt Nam. Nhờ tính đơn giản và khả năng chuẩn hóa, gloss được sử dụng rộng rãi như một biểu diễn trung gian trong các hệ thống dịch và tổng hợp ngôn ngữ ký hiệu, đặc biệt phù hợp với các ngôn ngữ ký hiệu trong điều kiện tài nguyên hạn chế [59,20,33,31].

Cách tiếp cận dựa trên gloss đặc biệt phù hợp với các ngôn ngữ ký hiệu tài nguyên thấp, nơi dữ liệu song song còn hạn chế. Gần đây, nhiều nghiên cứu đã tiếp cận bài toán dịch từ văn bản sang gloss như một dạng dịch máy thần kinh trong điều kiện dữ liệu hạn chế. Các kết quả cho thấy mô hình Transformer, khi được tăng cường bằng tri thức ngôn ngữ và các chiến lược làm giàu dữ liệu, có thể cải thiện đáng kể chất lượng dịch gloss. Đáng chú ý, Saha và cộng sự đã chứng minh hiệu quả của cách tiếp cận này đối với Bangla Sign Language, đồng thời khẳng định gloss là biểu diễn trung gian phù hợp cho các hệ thống tổng hợp ngôn ngữ ký hiệu trong bối cảnh tài nguyên thấp [44].

Mặc dù vậy, nghiên cứu về bài toán chuyển đổi từ tiếng nói sang Ngôn ngữ Ký hiệu Việt Nam vẫn còn hạn chế. Những thách thức chính bao gồm sự khan hiếm dữ liệu song song tiếng Việt-VSL và nhu cầu chuẩn hóa đầu ra để phục vụ việc dựng hoạt ảnh ký hiệu.

Trong nghiên cứu này, chúng tôi đề xuất một kiến trúc mô-đun cho bài toán chuyển đổi tiếng Việt nói sang Ngôn ngữ Ký hiệu Việt Nam trong điều kiện hạn chế tài nguyên. Hệ thống sử dụng mô-đun nhận dạng tiếng nói tự động (ASR) để thu được văn bản tiếng Việt, mô hình sinh chuỗi dựa trên Transformer cho bài toán dịch từ văn bản sang gloss, và cơ chế ánh xạ từ gloss sang SiGML để dựng hoạt ảnh avatar 3D thông qua một bộ tổng hợp ký hiệu dựa trên SiGML, chẳng hạn như JASigning [15], [37]. Trong phạm vi bài báo này, ASR được xem là mô-đun đầu vào và trọng tâm nghiên cứu tập trung vào khối dịch cấu trúc câu tiếng Việt sang cấu trúc câu ngôn ngữ ký hiệu trong bối cảnh dữ liệu ít tài

nguyên và cơ chế biểu diễn, kết xuất ngôn ngữ ký hiệu. Đầu ra của hệ thống được chuẩn hóa theo biến thể Ngôn ngữ Ký hiệu Việt Nam khu vực miền Nam nhằm đảm bảo tính nhất quán trong toàn bộ quá trình huấn luyện, ánh xạ và dựng hoạt ảnh, từ đó tạo điều kiện thuận lợi cho việc đánh giá tính khả thi của cách tiếp cận đề xuất.

2 Related Work

2.1 Ngôn ngữ Ký Hiệu

Ngôn ngữ ký hiệu là phương tiện giao tiếp chính của cộng đồng người khiếm thính, sở hữu cấu trúc ngữ pháp và từ vựng độc lập, khác biệt căn bản so với ngôn ngữ nói. Trong nhiều thập kỷ qua, bài toán xử lý và dịch máy ngôn ngữ ký hiệu đã thu hút sự quan tâm rộng rãi của cộng đồng nghiên cứu trên thế giới [35]. Tuy nhiên, đây vẫn được xem là một trong những bài toán khó do tính đa dạng, sự phụ thuộc mạnh vào ngữ cảnh không gian-thời gian, cũng như những hạn chế về dữ liệu và công nghệ.

Những năm gần đây, đã xuất hiện nhiều khảo sát và nghiên cứu áp dụng các phương pháp tiên tiến, đặc biệt là học sâu và mô hình đa mô thức, giúp thúc đẩy mạnh mẽ quá trình xử lý ngôn ngữ ký hiệu trên thế giới [46,30]. Một số công trình ứng dụng học sâu trong nhận dạng và dịch ngôn ngữ ký hiệu cho kết quả hứa hẹn trên các benchmark quốc tế, ví dụ như nghiên cứu về dịch ngôn ngữ ký hiệu kết hợp tiên huấn luyện, cho thấy mức độ dịch được cải thiện đáng kể trên các tập dữ liệu chuẩn như PHOENIX14T hoặc CSL-Daily [58]. Theo khảo sát mới nhất [30], các nghiên cứu không chỉ dừng lại ở bài toán nhận diện ký hiệu đơn lẻ mà đang chuyển dịch sang bài toán dịch ngôn ngữ ký hiệu, cho phép chuyển đổi hai chiều giữa video ký hiệu và văn bản/giọng nói, từ đó giúp phá vỡ rào cản giao tiếp. Tuy nhiên, phần lớn các nghiên cứu tiên tiến vẫn tập trung vào các ngôn ngữ ký hiệu phổ biến (ASL, DGS, CSL) do sự sẵn có của dữ liệu, để lại khoảng trống lớn cho các ngôn ngữ ít tài nguyên như Ngôn ngữ Ký hiệu Việt Nam.

2.2 Ngôn ngữ Ký Hiệu Việt Nam

Trước khi đi sâu vào Ngôn ngữ Ký hiệu Việt Nam (VSL), một trong những sai lầm phổ biến mà nhiều người hay nhầm lẫn đó chính là ngôn ngữ ký hiệu mang tính toán cầu và là một phiên bản chỉ chuyển thể từ ngôn ngữ nói sang hình ảnh. Tuy nhiên, các nghiên cứu ngôn ngữ học đã chứng minh rằng mỗi ngôn ngữ ký hiệu là một hệ thống tự nhiên độc lập, phát triển gắn liền với văn hóa, xã hội và cộng đồng người sử dụng của từng quốc gia. Ngay cả trên cùng một quốc gia, sự khác biệt vùng miền cũng dẫn đến nhiều biến thể khác nhau [2]. Do đó, việc sử dụng ngôn ngữ ký hiệu chung cho tiếng Việt là không khả thi.

Tại Việt Nam, các nhà ngôn ngữ học đã ghi nhận sự tồn tại của nhiều biến thể VSL theo đặc điểm văn hóa từng vùng miền [23]. Trong những năm gần đây, nghiên cứu về VSL đã có những bước tiến, chủ yếu tập trung vào bài toán nhận

dạng ngôn ngữ ký hiệu, tức là chuyển đổi từ dữ liệu video hoặc chuỗi khung xương (skeleton) sang văn bản hoặc ký hiệu [48]. Ngoài ra, một hướng nghiên cứu khác tại Việt Nam là sử dụng avatar 3D để biểu diễn ngôn ngữ ký hiệu, giúp mô phỏng giao tiếp ký hiệu trực quan và tự động [36]. Nghiên cứu này xây dựng chuyển động khung xương 3D cho ký hiệu từ văn bản, kết nối các chuyển động để biểu đạt cho câu, và được đánh giá khả thi khi áp dụng cho VSL.

Ngược lại, các nghiên cứu theo hướng dịch ngôn ngữ, đặc biệt là chuyển đổi từ tiếng Việt nói hoặc văn bản sang ký hiệu, vẫn còn hạn chế [27]. Nguyên nhân chủ yếu là sự thiếu hụt dữ liệu song ngữ chú thích đầy đủ, cũng như thách thức trong việc mô hình hóa ngữ pháp đặc thù và các thành phần phi thủ công của ngôn ngữ ký hiệu. Khoảng trống này nhấn mạnh nhu cầu cấp thiết về các hệ thống dịch VSL nhằm hỗ trợ giao tiếp và hòa nhập xã hội cho cộng đồng người khiếm thính tại Việt Nam.

2.3 Nhân Diện Giọng Nói Tiếng Việt

Các mô hình nhận diện giọng nói đã tiến hóa từ các hệ thống truyền thống sang các kiến trúc học sâu. Các phương pháp dựa trên Sequence to Sequence (Seq2Seq) và Connectionist Temporal Classification (CTC), điển hình là nghiên cứu Deep Speech 2 [3], đã cải thiện đáng kể hiệu suất ASR bằng cách xử lý trực tiếp chuỗi âm thanh. Tuy nhiên, khi áp dụng cho Tiếng Việt - một ngôn ngữ phân lập, có tính thanh điệu phức tạp và sự đa dạng giọng nói vùng miền cao - các mô hình ASR truyền thống này thường gặp thách thức lớn trong việc xử lý tính bất đồng nhất về ngữ âm và sự phức tạp trong phân đoạn từ (word segmentation) của ngôn ngữ này. Điều này làm gia tăng nguy cơ lỗi tích lũy từ đầu ra ASR, ảnh hưởng đến chất lượng toàn bộ hệ thống dịch máy.

Để giải quyết những hạn chế này và nâng cao chất lượng cho đầu vào văn bản, lĩnh vực ASR đã chuyển sang các mô hình tiền huấn luyện tự giám sát. Sự ra đời của kiến trúc wav2vec 2.0 [5] đã cách mạng hóa ASR bằng cách học các biểu diễn âm thanh từ dữ liệu không được gán nhãn. Tiếp theo, mô hình Whisper [42] đã thiết lập chuẩn mực mới về khả năng xử lý đa ngôn ngữ và tính mạnh mẽ nhờ được huấn luyện trên khối lượng dữ liệu khổng lồ.

2.4 Dịch Máy Ngôn Ngữ Ký Hiệu

Dịch máy ngôn ngữ ký hiệu (SLT) là giai đoạn cốt lõi của hệ thống, tập trung vào việc chuyển đổi từ văn bản tiếng Việt sang cấu trúc VSL. Bài toán này thường được mô hình hóa như một nhiệm vụ dịch máy tuần tự, trong đó đầu vào là câu văn bản và đầu ra là chuỗi gloss tương ứng. Các phương pháp hiện đại dựa trên kiến trúc Transformer đã cho thấy hiệu quả vượt trội trong việc học quan hệ ngữ nghĩa và cấu trúc cú pháp giữa ngôn ngữ nói và ngôn ngữ ký hiệu [8,33].

Tuy nhiên, đối với các ngôn ngữ ký hiệu nguồn lực thấp như VSL, hiệu quả của các mô hình SLT bị hạn chế nghiêm trọng bởi sự thiếu hụt các cặp dữ liệu song song chất lượng cao. Do đó, nhiều nghiên cứu gần đây đã tập trung vào các chiến lược tiền huấn luyện và tăng cường dữ liệu, chẳng hạn như sinh pseudo

gloss hoặc khai thác các mô hình tiền huấn luyện đa ngôn ngữ nhằm cải thiện khả năng tổng quát hóa của mô hình trong điều kiện dữ liệu hạn chế [34].

2.5 Tăng Cường Dữ Liệu Dịch Máy với Ngôn Ngữ Ít Tài Nguyên

Dịch máy ngôn ngữ ký hiệu đối với các ngôn ngữ ít tài nguyên như VSL đối mặt với thách thức nghiêm trọng về sự khan hiếm các cặp dữ liệu song song chất lượng cao. Không giống như dịch máy giữa các ngôn ngữ nói, nơi có sẵn các kho dữ liệu lớn và được chuẩn hóa, dữ liệu dịch máy ngôn ngữ ký hiệu thường có quy mô nhỏ và thiếu tính đồng nhất. Sự khan hiếm này chủ yếu xuất phát từ chi phí cao của quá trình thu thập và chú giải dữ liệu, trong đó đặc biệt là bước gán gloss đòi hỏi sự tham gia trực tiếp của các chuyên gia ngôn ngữ ký hiệu, khiến việc mở rộng quy mô dữ liệu trở nên khó khăn hơn nhiều so với dữ liệu văn bản thuần túy [12,55,59,11].

Những hạn chế về dữ liệu khiến việc tăng cường dữ liệu cho bài toán dịch máy ngôn ngữ ký hiệu trở nên phức tạp hơn đáng kể so với các bài toán xử lý văn bản. Trong khi tăng cường dữ liệu cho văn bản có thể áp dụng các kỹ thuật như như xáo trộn từ hay chèn từ ngẫu nhiên thì các phép biến đổi tương tự khó để áp dụng trực tiếp cho dữ liệu ngôn ngữ ký hiệu mà không làm sai lệch cấu trúc ngữ pháp hoặc ý nghĩa ký hiệu. Ngoài ra, dữ liệu ngôn ngữ ký hiệu mang tính đa phương thức và chứa nhiều thông tin không tuyến tính, khiến các chiến lược tăng cường dữ liệu tiêu chuẩn khó đảm bảo tính hợp lệ về mặt ngôn ngữ [12].

Bên cạnh đó, dịch máy ngôn ngữ ký hiệu hạn chế hơn so với dịch máy text truyền thống do sự khác biệt căn bản về cấu trúc ngôn ngữ. Ngôn ngữ ký hiệu không chỉ khác ngôn ngữ nói ở mặt từ vựng mà còn ở trật tự cú pháp, cách biểu đạt thông tin không gian và sự đồng thời của các thành phần ngôn ngữ. Do đó, việc ánh xạ trực tiếp từ câu văn bản sang biểu diễn ngôn ngữ ký hiệu, ngay cả ở dạng text có cấu trúc như gloss, vẫn là một bài toán khó hơn so với dịch giữa hai ngôn ngữ nói có cấu trúc tuyến tính tương đồng. [23]

Để giảm bớt ảnh hưởng của sự thiếu hụt dữ liệu, nhiều nghiên cứu đã đề xuất sử dụng pseudo gloss như một chiến lược tăng cường dữ liệu hiệu quả. Cụ thể, việc sinh các cặp pseudo gloss với quy mô lớn cho phép mô hình được tiền huấn luyện nhằm học các quy luật cú pháp cơ bản giữa gloss và ngôn ngữ nói, cũng như mở rộng phạm vi ngữ cảnh trước khi fine-tune trên tập dữ liệu thật. Cách tiếp cận này đã được chứng minh là giúp cải thiện đáng kể hiệu suất so với việc huấn luyện trực tiếp trên các tập dữ liệu ngôn ngữ ký hiệu quy mô nhỏ [34,16].

2.6 Sinh Gloss Giả bằng Mô hình Ngôn ngữ Lớn (LLMs):

Trong bối cảnh nguồn lực thấp, các mô hình NMT truyền thống thường khó mô hình hóa đầy đủ sự phức tạp ngữ nghĩa của ngôn ngữ ký hiệu. Ngược lại, các mô hình ngôn ngữ lớn với khả năng suy luận ngữ nghĩa và ngữ pháp vượt trội có thể

sinh ra các chuỗi gloss giả tự nhiên và nhất quán ngữ cảnh hơn [18,16]. Nghiên cứu trên ngôn ngữ Bangla cho thấy việc sử dụng mô hình tiền huấn luyện đa ngôn ngữ mBART để sinh gloss tổng hợp mang lại hiệu quả rõ rệt cho nhiệm vụ Text to Gloss (T2G) trong điều kiện thiếu dữ liệu song ngữ [1]. Gần đây, thông qua prompt engineering, một số LLMs thậm chí cho chất lượng sinh gloss vượt trội so với các mô hình chuyên biệt truyền thống, đặc biệt trong việc xử lý các biến thể từ vựng và cú pháp phức tạp.

2.7 Trực Quan Hóa Bằng Avatar 3D

Một số công trình tiên phong đã tiến hành số hóa và trực quan hóa ngôn ngữ ký hiệu tiếng Việt bằng avatar 3D, điển hình là nghiên cứu của Ngôn và cộng sự [37], trong đó hơn 2558 từ diễn tả NNKH đã được xây dựng. Mặc dù các nghiên cứu này đã đạt được những kết quả quan trọng trong việc mô tả hình thái thủ công của ký hiệu (ví dụ: hình dạng bàn tay, hướng và chuyển động), các yếu tố phi thủ công, đặc biệt là biểu cảm khuôn mặt và hình thái cảm xúc, vẫn chưa được mô hình hóa một cách đầy đủ và có hệ thống. Trong khi đó, các đặc trưng phi thủ công đóng vai trò then chốt trong việc biểu đạt ngữ nghĩa, thái độ và cấu trúc cú pháp của ký hiệu [51].

Do đó, trong nghiên cứu này, nhóm chúng tôi tập trung xây dựng một bộ từ điển ký hiệu chỉ dành cho hệ thống ngôn ngữ ký hiệu miền Nam Việt Nam, đồng thời biểu diễn bao gồm các hình thái cảm xúc và cử chỉ khuôn mặt trong quá trình sinh SiGML và trực quan hóa bằng avatar 3D.

3 System Overview

Trong phần này, chúng tôi giới thiệu kiến trúc tổng thể của hệ thống hỗ trợ giao tiếp tiếng Việt - (VSL), cũng như các quyết định thiết kế chính cho mô-đun dịch văn bản tiếng Việt sang gloss VSL trong bối cảnh dữ liệu cực kỳ ít tài nguyên.

Tương tự các hệ thống dịch nói sang ký hiệu kinh điển cho Spanish–LSE và German–DGS, chúng tôi áp dụng kiến trúc *modular* với các tầng biểu diễn trung gian, thay vì một mô hình end-to-end duy nhất [8,59].

Pipeline tổng thể gồm ba khối:

1. **ASR tiếng Việt (Voice-to-Text):** giọng nói tiếng Việt được chuyển thành văn bản thông qua một mô hình nhận diện giọng nói tiền huấn luyện tự giám sát như wav2vec 2.0 hoặc Whisper [5,42]. Đầu ra được chuẩn hoá (chính tả, dấu câu, chữ số) trước khi đưa vào T2G.
2. **Text-to-Gloss tiếng Việt-VSL:** văn bản tiếng Việt được dịch sang chuỗi gloss VSL. Đây là khối mà bài báo tập trung đóng góp, dựa trên kiến trúc encoder–decoder kiểu Transformer [50] với các biến thể tiền huấn luyện đơn ngữ/đa ngữ.
3. **Gloss-to-Avatar:** gloss VSL được ánh xạ sang các dãy HamNoSys rồi sang SiGML [22,15], và cuối cùng được trực quan hoá bằng avatar 3D. Từ điển Vie–SiGML được xây dựng từ nguồn QIPEDC với trọng tâm là hệ thống ký hiệu miền Nam.




Fig. 1: System overview of Vietnamese speech-to-VSL translation with 3D avatar rendering.

Các nghiên cứu gần đây về SLT cho thấy pipeline có tầng gloss trung gian vẫn thường đạt chất lượng cao và dễ kiểm soát hơn so với các hệ thống text $\leftrightarrow$ video end-to-end, đặc biệt trong điều kiện dữ liệu hạn chế [56,57,59,13]. Hệ thống được xây dựng theo kiến trúc modular, trong đó tầng Text-to-Gloss là trọng tâm nghiên cứu, còn hai tầng ASR và Avatar 3D cung cấp ngữ cảnh ứng dụng và ràng buộc thực tế.

4 Methodology

4.1 Voice-to-Text

Trong quy trình chuyển đổi giọng nói sang Ngôn ngữ Ký hiệu Việt Nam, mô-đun Chuyển giọng nói thành Văn bản (Automatic Speech Recognition - ASR) có nhiệm vụ chuyển đổi giọng nói tiếng Việt thành văn bản, làm đầu vào cho bước chuyển đổi sang VSL. Do văn bản đóng vai trò là dữ liệu nguồn của mô-đun

Table 1: Kết quả WER (%) của PhoWhisper so với các mô hình ASR tiếng Việt trên các benchmark

Model	#Params	CMV-Vi	VIVOS	VLSP-1	VLSP-2
wav2vec2-base-vietnamese-250h	95M	102.04	10.83	21.02	50.35
wav2vec2-base-vi-vlsp2020	95M	103.71	9.90	16.82	44.91
wav2vec2-large-vi-vlsp2020	317M	101.41	8.61	15.18	36.75
PhoWhisper-tiny	39M	19.05	10.41	20.74	49.85
PhoWhisper-base	74M	16.19	8.46	19.70	43.01
PhoWhisper-small	244M	11.08	6.33	15.93	32.96
PhoWhisper-medium	769M	8.27	4.97	14.12	26.85
PhoWhisper-large	1.55B	8.14	4.67	13.75	26.68

dịch, các lỗi nhận dạng ở bước ASR thường lan truyền sang các giai đoạn sau và làm suy giảm chất lượng đầu ra của toàn bộ hệ thống. Bên cạnh độ chính xác từ vựng, chúng tôi cũng quan tâm đến cấu trúc bề mặt của văn bản đầu ra từ ASR. Các hệ thống ASR thường không khôi phục đầy đủ dấu câu, khiến phát ngôn dễ bị gộp thành một chuỗi dài và khó tách ý. Khi ranh giới câu và cụm nghĩa không rõ ràng, mô-đun dịch sang VSL có xu hướng hoạt động kém ổn định, đặc biệt trong các kịch bản ghi âm trực tiếp với tiếng ồn nền và độ dài phát ngôn thay đổi. Do đó, mục tiêu của mô-đun ASR trong nghiên cứu này là tạo ra transcript vừa đủ chính xác về nội dung, vừa đủ rõ ràng về cấu trúc để hỗ trợ hiệu quả cho bước chuyển đổi sang VSL.

4.1.1 Lựa chọn mô hình ASR

Chúng tôi lựa chọn PhoWhisper [28] làm mô hình ASR cho hệ thống vì đây là biến thể của Whisper được fine-tune chuyên biệt cho tiếng Việt. Theo bài báo gốc, PhoWhisper được huấn luyện trên khoảng 844 giờ dữ liệu, tổng hợp từ nhiều nguồn khác nhau bao gồm CMV-Vi (Common Voice tiếng Việt), VIVOS, các bộ dữ liệu thuộc VLSP và dữ liệu riêng nhằm tăng độ đa dạng người nói. Ngoài ra, một phần dữ liệu huấn luyện được tăng cường bằng cách bổ sung nhiễu môi trường thông qua audiomentations, và mô hình được fine-tune trong 48.000 bước.

Những đặc điểm này phù hợp với bối cảnh triển khai của chúng tôi, nơi âm thanh được thu trực tiếp từ người dùng và chất lượng thu âm có thể phụ thuộc vào thiết bị cũng như mức độ tiếng ồn nền. Để đặt PhoWhisper trong tương quan với các mô hình ASR tiếng Việt trước đó, Bảng 1 trích từ [28] tổng hợp Word Error Rate (WER) trên các benchmark chuẩn. Kết quả cho thấy các phiên bản PhoWhisper, đặc biệt từ cấu hình *small* trở lên, vượt trội so với các baseline wav2vec2 trên hầu hết các bộ đánh giá.

4.1.2 Đánh giá mô hình ASR

PhoWhisper cung cấp nhiều cấu hình kích thước mô hình khác nhau [28], do đó cần có sự cân bằng giữa độ chính xác và độ trễ trong thiết lập “nhân ghi âm rồi

nhận văn bản”. Chúng tôi tiến hành so sánh trực tiếp hai cấu hình PhoWhisper-medium (769M tham số) và PhoWhisper-large (1.55B tham số) trong cùng điều kiện suy luận để lựa chọn cấu hình phù hợp.

Thí nghiệm được thực hiện trên tập kiểm tra gồm 1.000 mẫu của bộ dữ liệu công khai ademax/vlsp-vie-speech2text. Audio đầu vào được chuẩn hóa về mono và resample về 16 kHz trước khi đưa vào mô hình. Cả hai cấu hình đều sử dụng greedy decoding với beam size bằng 1. Trước khi tính WER, transcript dự đoán và ground truth được chuẩn hóa theo cùng một quy tắc gồm Unicode NFC, chuyển chữ thường, loại bỏ dấu câu (thay bằng khoảng trắng) và chuẩn hóa khoảng trắng.

Chúng tôi báo cáo micro-average WER làm chỉ số đánh giá chính và đo Real-Time Factor (RTF) để phản ánh tốc độ suy luận, trong đó RTF được tính bằng tổng thời gian xử lý chia cho tổng thời lượng audio trong cùng môi trường chạy. Kết quả so sánh được trình bày trong Bảng 2.

Table 2: So sánh PhoWhisper-medium và PhoWhisper-large trên tập test 1.000 mẫu

Mô hình	Micro WER (%)	RTF
PhoWhisper-medium	3.19	2.81
PhoWhisper-large	3.92	1.53

Kết quả cho thấy PhoWhisper-medium đạt Micro WER thấp hơn PhoWhisper-large trên tập kiểm tra này, trong khi PhoWhisper-large có RTF thấp hơn trong điều kiện đo. Trong pipeline VSL, sai lệch nội dung ở văn bản đầu ra thường ảnh hưởng trực tiếp đến các bước sau, do đó chúng tôi ưu tiên lựa chọn PhoWhisper-medium làm cấu hình mặc định nhằm giảm lỗi nội dung. PhoWhisper-large được giữ như cấu hình đối chứng hoặc sử dụng trong các kịch bản ưu tiên độ trễ tùy theo môi trường triển khai.

4.2 Text-to-Gloss

4.2.1 Data Augmentation

Ngôn ngữ ký hiệu là ngôn ngữ nằm trong nguồn dữ liệu có tài nguyên rất ít ở rất nhiều quốc gia không chỉ riêng ở Việt Nam. Nhiều nghiên cứu đã đề xuất các phương pháp làm giàu dữ liệu cho ngôn ngữ ít tài nguyên này [1][44][34]. Các nghiên cứu gần đây cho thấy những phương pháp làm giàu dữ liệu hiện đại dựa trên mô hình học sâu và sinh dữ liệu tự động, vượt trội hơn so với các phương pháp truyền thống nhờ khả năng tạo ra tập huấn luyện có độ bao phủ và tính khái quát cao. Đặc biệt, công trình [34] đã chỉ ra rằng việc sinh nhiều biến thể câu, dù mỗi câu làm giàu có chất lượng thấp, đã giúp tăng độ đa dạng cấu trúc của dữ liệu huấn luyện và cải thiện mô hình. Bên cạnh đó, các phương pháp hiện đại tận dụng sức mạnh của mô hình ngôn ngữ lớn cũng đã được chứng minh

là hiệu quả trong làm giàu dữ liệu. Công trình [44] đề xuất kết hợp Retrieval-Augmented Generation (RAG) với few-shot prompting trên các mô hình ngôn ngữ lớn nhằm mở rộng tập dữ liệu huấn luyện, đồng thời duy trì tính liên quan ngữ cảnh và cấu trúc của dữ liệu sinh ra. Trong triển khai cụ thể của bài, chúng tôi tiến hành làm giàu lên 30,000 dữ liệu theo tỷ lệ 1:3 với hai hướng chính, kết hợp khả năng sinh dữ liệu linh hoạt của mô hình ngôn ngữ lớn với cơ chế truy hồi ví dụ ngữ cảnh nhằm kiểm soát chất lượng và độ đa dạng của dữ liệu sinh.

Data Augmentation with fewshot prompting: Chúng tôi áp dụng phương pháp làm giàu dữ liệu trên mô hình ngôn ngữ lớn GPT-4o thông qua cơ chế học theo ngữ cảnh. Một số cặp câu mẫu được đưa vào prompt nhằm giúp mô hình học được các mẫu cấu trúc biến đổi câu từ văn bản tiếng Việt sang VSL. Cách tiếp cận này cho phép mô hình tổng quát hóa tốt hơn trong những trường hợp mà tập luật chuyển đổi thủ công không thể bao phủ đầy đủ các dạng câu Tiếng Việt đa dạng.

Retrieval-Augmented Generation (RAG) : Để lựa chọn các ví dụ phù hợp cho quá trình fewshot prompting, chúng tôi sử dụng phương pháp RAG nhằm truy vấn các câu có mức độ tương đồng cao với câu đầu vào. Mặc dù RAG chủ yếu dựa trên độ tương đồng ngữ nghĩa, cách tiếp cận này vẫn phù hợp với bài toán chuyển đổi cấu trúc câu từ tiếng Việt sang ngôn ngữ ký hiệu, do các quy tắc chuyển đổi trong ngôn ngữ ký hiệu phần lớn phụ thuộc vào cấu trúc cú pháp và ngữ nghĩa của câu. Các nguyên tắc chuyển đổi như loại bỏ hư từ (“là”, “thì”), xác định vị trí của từ để hỏi (“đâu”, “mấy”), vị trí của số lượng, trạng ngữ chỉ thời gian và chỉ thì, cũng như cách xử lý giới từ, đều có mối liên hệ chặt chẽ với cấu trúc ngữ nghĩa tổng thể của câu. Từ đó, việc truy vấn các câu tương đồng về ngữ nghĩa giúp đảm bảo rằng các ví dụ được đưa vào prompt có giá trị định hướng hiệu quả cho mô hình trong quá trình sinh gloss.

Các quy tắc trong Bảng ??, được xây dựng dựa trên [?], được tích hợp vào prompt như các ràng buộc ngôn ngữ học nhằm định hướng quá trình sinh gloss theo cấu trúc cú pháp của Ngôn ngữ Ký hiệu Việt Nam.

Chúng tôi thiết kế và so sánh ba chiến lược prompting khác nhau thông qua các thí nghiệm kiểm định nhằm lựa chọn cấu hình phù hợp nhất cho bài toán sinh dữ liệu trong bối cảnh ít tài nguyên.

Chiến lược 1 - Rule-based Prompting: chiến lược sử dụng tập các quy tắc biến đổi do chuyên gia biên soạn kèm theo các ví dụ cố định tương ứng. Cách tiếp cận này đảm bảo tính diễn giải và ổn định của đầu ra, nhưng bị giới hạn khi các luật không bao phủ đầy đủ các biến thể câu trong thực tế.

Chiến lược 2 - RAG with Rule-based Fallback: chiến lược áp dụng truy hồi tăng cường để lựa chọn các ví dụ có độ tương đồng ngữ nghĩa cao; trong trường hợp không truy hồi được ví dụ phù hợp hoặc độ tin cậy thấp, hệ thống tự động chuyển sang prompting dựa trên luật. Cơ chế hai giai đoạn này giúp tận dụng thông tin ngữ cảnh khi có sẵn, đồng thời duy trì tính ổn định và kiểm soát cấu trúc gloss trong các trường hợp truy hồi kém.

Chiến lược 3 - Rule-guided RAG Prompting: chiến lược kết hợp mô tả luật và các ví dụ được lựa chọn bởi RAG trong cùng một prompt. Mặc dù thiết

kế này nhằm đồng thời khai thác tri thức luật và ví dụ ngữ cảnh, thực nghiệm cho thấy việc trộn hai nguồn thông tin trong cùng một prompt dễ gây nhiễu và làm suy giảm chất lượng đầu ra.

Với chiến lược thiết kế prompt, kết quả trong Bảng 3 cho thấy Chiến lược 1 và Chiến lược 2 đạt hiệu năng cao và ổn định nhất trên các chỉ số BLEU, TER và COMET. Ngược lại, Chiến lược 3 thể hiện chất lượng kém rõ rệt và do đó được loại khỏi các thiết lập thí nghiệm tiếp theo. Xét đến mục tiêu sinh dữ liệu huấn luyện với yêu cầu cao về tính ổn định và khả năng kiểm soát lỗi, chúng tôi ưu tiên sử dụng Chiến lược 2 làm cấu hình chính.

Table 3: Kết quả đánh giá các chiến lược prompting.

Chiến lược	BLEU	TER	COMET
Chiến lược 1	28.75	48.47	84.46
Chiến lược 2	77.77	12.44	96.29
Chiến lược 3	77.63	12.65	95.90

4.2.2 Model selection Từ tổng hợp literature về đặc trưng ngôn ngữ học cho NMT [4,14,13], chiến lược data-centric + pretraining trong Text-to-Gloss [11,59,1], và tích hợp LLM cho dịch low-resource [25,19,24], chúng tôi đặt ra ba câu hỏi nghiên cứu chính cho Vie-VSL:

- RQ1:** Trong điều kiện dữ liệu chỉ khoảng 10k cặp Vie-VSL, việc sử dụng các mô hình encoder-decoder tiền huấn luyện (đơn ngữ BARTPho, đa ngữ mBART) mang lại lợi ích như thế nào so với một Transformer huấn luyện từ đầu?
- RQ2:** Chiến lược làm giàu dữ liệu dựa trên luật VSL-aware và RAG với LLM giúp cải thiện chất lượng dịch Vie-VSL tới mức nào, khi so sánh giữa tập gốc 10k và tập mở rộng $\sim 40k$, dưới cùng một backbone (Transformer/BARTPho/mBART)?
- RQ3:** So với việc dùng LLM như một bộ dịch Vie $\rightarrow$ VSL trực tiếp bằng prompt (LLM-as-translator), việc dùng LLM như một máy sinh dữ liệu (LLM-as-data-generator) rồi huấn luyện các mô hình NMT chuyên biệt có đem lại các mô hình ổn định và phù hợp hơn cho bối cảnh VSL ít tài nguyên hay không?

Để trả lời các câu hỏi này, chúng tôi xây dựng một họ mô hình gồm: (i) Transformer baseline huấn luyện từ đầu, (ii) BARTPho encoder-decoder tiền huấn luyện đơn ngữ, (iii) mBART encoder-decoder tiền huấn luyện đa ngữ với hai cấu hình fine-tune đơn ngữ và đa ngữ, và (iv) một hệ thống LLM dùng prompt few-shot để dịch trực tiếp Vie sang VSL gloss như một hệ thống so sánh.

(i) *Transformer baseline huấn luyện từ đầu.* Mô hình chuẩn được sử dụng làm baseline là một Transformer encoder-decoder kích thước nhỏ, huấn luyện từ đầu trên tập Vie-VSL. Cấu hình (số lớp, số head, kích thước ẩn) được chọn theo thông lệ cho NMT ít tài nguyên. Mô hình này đóng vai trò mốc để đánh giá lợi ích của pretraining, multilinguality và làm giàu dữ liệu.

(ii) *Encoder-decoder tiền huấn luyện đơn ngữ (BARTPho)*. Để khai thác thông tin ngôn ngữ tiếng Việt ở mức độ sâu hơn, chúng tôi lựa chọn một mô hình BARTPho pretrain trên corpus tiếng Việt quy mô lớn, sau đó fine-tune cho bài toán T2G. Điều này tương tự hướng tiếp cận dùng BART/mBART cho NMT ít tài nguyên: encoder đã học được phân bố cú pháp-ngữ nghĩa của tiếng Việt, còn decoder được điều chỉnh để sinh ra chuỗi gloss VSL [29,32]. Chúng tôi kỳ vọng BARTPho sẽ xử lý tốt hơn các cấu trúc câu phức, đảo ngữ, chủ đề-bình luận trong tiếng Việt, từ đó cải thiện chất lượng biểu diễn nguồn cho T2G.

(iii) *Encoder-decoder tiền huấn luyện đa ngữ (mBART)*. Tiếp theo, chúng tôi xem xét khả năng tận dụng pretraining đa ngữ. Các mô hình encoder-decoder đa ngữ như mBART đã chứng minh hiệu quả trong dịch ít tài nguyên nhờ khả năng khởi tạo một không gian biểu diễn chung và các lớp Transformer đã học những mẫu chuyển đổi ngôn ngữ ở mức đại diện biểu diễn [32]. Trong nghiên cứu này, chúng tôi sử dụng một cấu hình *mBART-MultiT2G*, trong đó fine-tune mBART đồng thời trên Vie-VSL và một hoặc vài corpus T2G chất lượng công khai (ví dụ German-DGS, Chinese-CSL), tương tự ý tưởng trong [1]. Thiết lập này cho phép khảo sát ảnh hưởng của multilingual transfer: tri thức học được từ cặp ngôn ngữ khác (với cấu trúc gloss đã được nghiên cứu kỹ) liệu có giúp ích cho Vie-VSL hay không, và mức độ phụ thuộc vào khoảng cách loại hình (ví dụ: tiếng Trung có nhiều điểm tương đồng với VSL hơn tiếng Đức, hay ngược lại).

(iv) *Hệ thống LLM dùng prompt (LLM-as-translator, hệ thống so sánh)*. Song song với các mô hình NMT chuyên biệt, chúng tôi đưa vào một hệ thống LLM được prompt few-shot để dịch Vie sang VSL gloss trực tiếp, không fine-tune. Thiết kế này phản ánh xu hướng gần đây sử dụng LLM như một thành phần trong pipeline xử lý ngôn ngữ ký hiệu, ví dụ LLM được dùng để ánh xạ các biểu diễn giống ngôn ngữ của video ký hiệu sang văn bản tự nhiên [19], hoặc được multitask fine-tune cho nhiều tác vụ Sign Language Processing (SLP) như trong [24]. Đồng thời, các kết quả gần đây về LLM-MT cho low-resource chỉ ra rằng: (i) LLM-as-translator có thể cạnh tranh hoặc vượt NMT trên các cặp ngôn ngữ giàu tài nguyên, nhưng suy giảm rõ rệt trên các ngôn ngữ ít tài nguyên; và (ii) hiệu năng của LLM-MT ở thiết lập này vẫn phụ thuộc mạnh vào lượng và cách sử dụng dữ liệu song ngữ (bitext) trong giai đoạn continued pre-training (CPT) và supervised fine-tuning (SFT) [25].

Trong bối cảnh Vie-VSL cực kỳ ít tài nguyên, chúng tôi do đó xem LLM-as-translator chủ yếu là *hệ thống đối chiếu* để trả lời RQ3, thay vì một baseline chính thức. Vai trò trung tâm của LLM trong pipeline của chúng tôi là *LLM-as-data-generator*: LLM được dùng để sinh thêm cặp câu Vie-VSL (dưới ràng buộc luật VSL-aware và RAG với từ điển gloss) nhằm mở rộng tập huấn luyện từ khoảng 10k lên ~40k, sau đó các mô hình NMT chuyên biệt (Transformer, BARTPho, mBART-MultiT2G) được huấn luyện trên tập dữ liệu mở rộng này.

4.3 Gloss-to-Avatar

Tại Việt Nam, cộng đồng người khiếm thính sử dụng nhiều biến thể của ngôn ngữ ký hiệu, bao gồm ba hệ thống chính: miền Bắc, miền Trung và miền Nam. Sự khác biệt về ngữ âm và ngữ nghĩa giữa các hệ thống này [49,23] tạo ra thách thức lớn trong việc phát triển các công cụ công nghệ hỗ trợ giao tiếp mang tính thống nhất. Chính vì vậy, việc chuẩn hóa và xây dựng một bộ từ điển ký hiệu trở thành một yêu cầu cấp thiết.




Fig. 2: Gloss to Avatar processing

4.3.1 HamNoSys - Hệ thống Ký hiệu hóa Hamburg: Để số hóa ngôn ngữ ký hiệu, các nhà nghiên cứu quốc tế đã phát triển HamNoSys [22]. HamNoSys cho phép mô tả chi tiết các thông số của một động tác ký hiệu một cách trừu tượng, không phụ thuộc vào ngôn ngữ ký hiệu cụ thể nào. Đây là điểm mạnh giúp nó trở thành nền tảng cho việc sinh ra các ngôn ngữ đánh dấu như SiGML. Các thông số cơ bản mà HamNoSys mô tả bao gồm:




Fig. 3: Cấu trúc thành phần chính của Hamnosys

- Hình dạng bàn tay (Handshape): Định nghĩa cấu hình chính xác của các ngón tay và bàn tay khi thực hiện ký hiệu.
- Hướng bàn tay (Orientation): Mô tả cách bàn tay quay trong không gian.
- Vị trí (Location): Xác định vị trí của bàn tay so với cơ thể.
- Chuyển động (Movement): Mô tả các dạng chuyển động của tay, chẳng hạn như di chuyển theo đường thẳng, đường cong, xoay tròn hoặc lặp lại.
- Biểu cảm (Non-manual features): Bao gồm các yếu tố phi thủ công như gương mặt, ánh mắt, chuyển động của đầu hoặc vai, các yếu tố này ảnh hưởng lớn đến ngữ nghĩa của ký hiệu.

4.3.2 SiGML – Signing Gesture Markup Language: SiGML [15] là ngôn ngữ đánh dấu dựa trên XML, được phát triển để mô tả cử chỉ ngôn ngữ ký hiệu trên nền tảng máy tính. SiGML được **sinh ra tự động** từ HamNoSys [26]. Cấu trúc rõ ràng và chuẩn hóa của SiGML không chỉ giúp dễ dàng lưu trữ và chia sẻ dữ liệu mà còn cung cấp dữ liệu đầu vào có cấu trúc cho các công cụ đồ họa




Fig. 4: Định dạng từng phần của Hamnosys

và hoạt hình 3D (ví dụ: JA Signing) [15]. Khả năng này là chìa khóa để avatar 3D có thể tái hiện chính xác và trực quan các động tác ký hiệu, một mục tiêu chính của hệ thống.




Fig. 5: Biểu diễn ký hiệu cho từ “mạnh mẽ” trong HamNoSys (trái) và mã hóa của nó trong SiGML (phải)

4.3.3 eSign Editor: là một công cụ hỗ trợ quá trình biên soạn và quản lý từ điển ngôn ngữ ký hiệu. Công cụ này cung cấp môi trường cho phép người dùng xây dựng, chỉnh sửa và lưu trữ các mô tả ký hiệu dựa trên hệ thống ký pháp HamNoSys . Bên cạnh đó, eSign Editor hỗ trợ chuyển đổi các mô tả HamNoSys sang định dạng SiGML .




Fig. 6: Giao diện phần mềm eSign Editor

4.3.4 Nguồn Dữ Liệu Từ Điển (QIPEDC): Nguồn dữ liệu nền tảng để xây dựng được nhóm nghiên cứu lựa chọn từ danh mục ngôn ngữ ký hiệu QIPEDC (Quỹ Phát triển Giáo dục cho Người Khiếm thính). Bộ dữ liệu này bao gồm khoảng 4000 từ và câu ký hiệu được cộng đồng người khiếm thính tại Việt Nam sử dụng .[6]

4.3.5 Bộ từ điển Vie-SiGML Quá trình xây dựng bộ từ điển Vie-SiGML được thực hiện tuần tự các bước sau:

- Từ bộ danh mục 4000 từ/câu ký hiệu QIPEDC bao gồm cả 3 miền: Bắc, Trung, Nam. Nhóm tập trung chọn lọc các từ vựng thuộc hệ thống ký hiệu miền Nam, nhằm đảm bảo tính nhất quán và tránh sự pha trộn vùng miền.
- Mã hóa ký hiệu: Mỗi từ được biểu diễn dưới dạng ký pháp HamNoSys, mô tả chi tiết hình dạng bàn tay, hướng, vị trí và chuyển động, biểu cảm
- Xuất SiGML: Thông qua công cụ eSign Editor, các ký hiệu HamNoSys được chuyển đổi sang SiGML, đảm bảo tính chuẩn hóa và khả năng tích hợp với các hệ thống 3D avatar
- Kiểm định trực quan: Từng ký hiệu được hiển thị trên mô hình avatar 3D để kiểm tra tính chính xác, sự mượt mà của động tác, cũng như độ dễ hiểu đối với người dùng

5 Experimental Setting

trình bày môi trường thực nghiệm

5.1 Dataset

Vie-VSL-10k là bộ dữ liệu gồm khoảng 10,000 cặp câu tiếng Việt - Ngôn ngữ Ký hiệu Việt Nam, được xây dựng cho bài toán dịch từ câu tiếng Việt sang câu ngôn ngữ ký hiệu ở mức cấu trúc cú pháp. Khác với một số bộ dữ liệu quốc tế, trong đó các gloss được thiết kế và chuẩn hóa chủ yếu theo tiêu chuẩn từ vựng và cú pháp của ngôn ngữ ký hiệu tại từng quốc gia [1], [44], *Vie-VSL-10k* được phát triển với mục tiêu nhấn mạnh các đặc trưng ngữ pháp và trật tự câu riêng của VSL. Bộ dữ liệu tập trung mô tả những cấu trúc điển hình của VSL như rút gọn các từ chức năng và thay đổi trật tự thành phần câu khi chuyển từ tiếng Việt sang VSL. Bên cạnh đó, các gloss trong *Vie-VSL-10k* mang tính biểu diễn cấu trúc hơn là một chuẩn từ vựng hoàn thiện cho cộng đồng ký hiệu Việt.

Chúng tôi thực hiện bước tiền xử lý và loại bỏ bản sao trùng lặp, tập dữ liệu được giữ lại và chia cố định thành ba phần không giao nhau: tập huấn luyện (train) gồm 7,591 cặp, tập kiểm tra (test) gồm 1,042 cặp và tập phát triển (dev) gồm 346 cặp. Việc chia này tuân theo quy trình phân tách đảm bảo đa dạng cấu trúc và bảo toàn các lớp chất lượng.

PHOENIX-Weather 2014T (PHOENIX14-T) [17] là một bộ dữ liệu chất lượng cao được sử dụng rộng rãi trong nghiên cứu dịch ngôn ngữ ký hiệu, đặc biệt cho các bài toán Sign Language Translation và làm giàu dữ liệu [44,34,1]. Bộ dữ liệu được xây dựng từ các bản tin dự báo thời tiết bằng Ngôn ngữ Ký hiệu Đức (DGS), bao gồm các cặp song song giữa câu tiếng Đức và chuỗi gloss tương ứng. Trong nghiên cứu này, 7,096 mẫu trong tập huấn luyện (train) của *PHOENIX14-T* được sử dụng như một tập dữ liệu bổ trợ để thực hiện fine-tuning trung gian cho mô hình mBART, nhằm giúp mô hình thích nghi với tác vụ chuyển đổi từ cấu trúc ngôn ngữ nói sang cấu trúc ngôn ngữ ký hiệu trước khi fine-tuning cuối cùng trên bộ *Vie-VSL-10k*.

ASLG-PC12 [39] là một bộ dữ liệu song song giữa ngôn ngữ nói và chuỗi gloss của Ngôn ngữ Ký hiệu Mỹ (American Sign Language – ASL). *ASLG-PC12* được xây dựng cho các bài toán dịch và phân tích cấu trúc ngôn ngữ ký hiệu, bao gồm các cặp câu tiếng Anh và chuỗi gloss ASL tương ứng. Các gloss trong *ASLG-PC12* phản ánh những đặc trưng cú pháp và trật tự câu đặc thù của ASL, chẳng hạn như việc lược bỏ từ chức năng, sử dụng cấu trúc chủ đề-bình luận và các hình thức biểu đạt mang tính khái quát ngữ pháp. Bộ dữ liệu này đã được sử dụng rộng rãi trong các nghiên cứu về SLT và các mô hình dịch dựa trên chuỗi gloss, đặc biệt trong bối cảnh huấn luyện và đánh giá các mô hình đa ngôn ngữ và đa miền.

5.2 Models

5.2.1 Transformer Chúng tôi xây dựng baseline Transformer encoder-decoder bằng *Marian NMT* nhằm đảm bảo tính tái lập và sử dụng cấu hình huấn luyện/giải mã tiêu chuẩn trong dịch máy [?]. Baseline này đóng vai trò mốc

so sánh cho (i) lợi ích của tiền huấn luyện (BARTPho/mBART) và (ii) tác động của dữ liệu tổng hợp cũng như các chiến lược huấn luyện theo giai đoạn trong bối cảnh Vie→VSL gloss cực ít tài nguyên.

Khác với các mô hình tiền huấn luyện như BARTPho/mBART (tokenizer cố định theo mô hình), baseline Transformer yêu cầu tokenizer tự huấn luyện. Trong thí nghiệm so sánh quy mô dữ liệu (dữ liệu gốc so với dữ liệu làm giàu), thay đổi tokenizer sẽ làm thay đổi trực tiếp không gian biểu diễn (phân hoạch subword, ánh xạ token-id và phân bố độ dài chuỗi), khiến khác biệt kết quả không còn phản ánh thuần túy tác động của dữ liệu. Do đó, chúng tôi huấn luyện SentencePiece tokenizer một lần duy nhất trên tập train lớn nhất (bao gồm dữ liệu gốc và dữ liệu làm giàu) và tái sử dụng cùng tokenizer cho toàn bộ các thiết lập huấn luyện của Transformer nhằm cô lập ảnh hưởng của quy mô dữ liệu trong RQ2.

Khi huấn luyện với dữ liệu tổng hợp, chúng tôi gắn đầu mỗi câu nguồn nhãn miền bằng token đặc biệt: <real> cho dữ liệu thật và <syn> cho dữ liệu tổng hợp. Đây là một thực hành phổ biến trong MT để mô hình có thể điều kiện hóa theo nguồn gốc dữ liệu và giảm nhiễu do sai khác phân bố giữa dữ liệu sinh và dữ liệu thật [9,54]. Ở giai đoạn đánh giá, dữ liệu dev/test luôn được gắn <real> để phản ánh đúng miền đích.

Thiết lập huấn luyện. Trên cùng backbone Transformer, chúng tôi đánh giá bốn thiết lập nhằm tách bạch vai trò dữ liệu thật/tổng hợp và tác động của fine-tune cuối trên dữ liệu thật:

1. **Original-only:** Huấn luyện trực tiếp trên dữ liệu thật.
2. **Aug-Mix:** Huấn luyện một giai đoạn trên tập trộn gồm dữ liệu thật + dữ liệu tổng hợp (LLM synth), với nhãn miền ở phía nguồn.
3. **Aug-Mix** → **Real-FT:** Huấn luyện trên tập trộn, sau đó fine-tune ngắn trên dữ liệu thật để thích nghi về miền đích.
4. **Syn-only** → **Real-FT:** Huấn luyện khởi tạo trên dữ liệu tổng hợp, sau đó fine-tune ngắn trên dữ liệu thật.

Trong nhiều nghiên cứu SLT/SLP gần đây, dữ liệu tổng hợp hoặc pseudo-supervision thường được dùng để *khởi tạo* biểu diễn/học cấu trúc chung (pre-training), sau đó mô hình được *thích nghi* bằng fine-tuning trên dữ liệu gán nhãn thật nhằm tối ưu hiệu năng trên miền mục tiêu và hạn chế sai lệch phân bố do dữ liệu sinh [21,52,53]. Do đó, hai biến thể Real-FT trong nghiên cứu này nhằm kiểm chứng trực tiếp lợi ích của cơ chế thích nghi miền đích sau khi học từ dữ liệu tổng hợp.

Cấu hình mô hình và siêu tham số. Transformer baseline có cấu hình nhỏ phù hợp low-resource: $N_e = 2$ lớp encoder, $N_d = 2$ lớp decoder; kích thước ẩn $d_{\text{model}} = 512$; $h = 8$ attention heads; FFN $d_{\text{ff}} = 2048$; dropout 0.1; layer normalization. Hàm mất mát dùng cross-entropy theo từ (cost-type: **ce-mean-words**) với label smoothing 0.1.

Về tối ưu, chúng tôi cố định siêu tham số theo hai pha để đảm bảo so sánh công bằng:

- **Pha huấn luyện chính** (Original-only/Aug-Mix/Syn-only): Adam ($\beta_1=0.9, \beta_2=0.98$); learning rate 3×10^{-4} ; warmup 16k updates; mini-batch 64 (kèm gradient accumulation để phù hợp bộ nhớ); dropout 0.1; label smoothing 0.1; early stopping patience 10.
- **Pha fine-tune trên dữ liệu thật** (Real-FT): khởi tạo từ checkpoint tốt nhất Stage-1; learning rate 5×10^{-5} ; warmup 2k updates; early stopping patience 5; giới hạn số epoch/cập nhật để giảm quá khớp và hạn chế hiện tượng *catastrophic forgetting* khi thích nghi miền đích.

Trong giải mã, chúng tôi dùng beam size 6 với length normalization 0.6 và giữ cố định cho mọi thiết lập.

5.2.2 BARTpho Chúng tôi fine-tune toàn bộ mô hình BARTpho cho nhiệm vụ chuyển đổi từ văn bản tiếng Việt sang chuỗi gloss VSL (Text-to-Gloss). Encoder tiếp nhận câu nguồn tiếng Việt, trong khi decoder được huấn luyện để sinh ra chuỗi gloss tương ứng, vốn có cấu trúc cú pháp khác biệt đáng kể so với ngôn ngữ viết thông thường.

Quá trình huấn luyện được thực hiện theo hai chế độ:

- **Fine-tune trực tiếp:** mô hình BARTpho được fine-tune trực tiếp trên tập Vie-VSL-10k.
- **Fine-tune hai giai đoạn:** mô hình được fine-tune trước trên tập dữ liệu synthetic với 10 epoch giới hạn, sau đó tiếp tục fine-tune trên dữ liệu Vie-VSL10k thật với 20 epoch. Thiết lập này nhằm giúp mô hình học trước không gian biểu diễn của gloss và giảm nhiễu trong giai đoạn học từ dữ liệu thật.

Trong cả hai chế độ, chúng tôi sử dụng cùng một tập development để theo dõi quá trình huấn luyện và lựa chọn mô hình tốt nhất. Việc lựa chọn mô hình không sử dụng thông tin từ tập test nhằm đảm bảo tính khách quan trong đánh giá và sự rõ ràng dữ liệu. Các siêu tham số chính được lựa chọn thông qua thực nghiệm ban đầu và giữ cố định cho tất cả các cấu hình BARTpho nhằm đảm bảo so sánh công bằng. Cụ thể, chúng tôi sử dụng learning rate ở mức 5×10^{-5} , batch size 4 với gradient accumulation là 8 để phù hợp với giới hạn bộ nhớ, warm-up theo tỉ lệ, và huấn luyện trong tối đa 20 epoch cho giai đoạn và chế độ fine-tune trên dữ liệu thật, 10 epoch cho giai đoạn làm giàu. Tất cả các thí nghiệm được huấn luyện với seed cố định để đảm bảo khả năng tái lập.

5.2.3 mBart Đối với bài toán dịch Ngôn ngữ Ký hiệu tiếng Việt, dữ liệu huấn luyện có kích thước hạn chế và phân bố không đồng đều, trong khi mô hình mBART-large-50 được tiền huấn luyện trên các tập dữ liệu văn bản đa ngôn ngữ quy mô lớn. Trong bối cảnh này, fine-tuning trực tiếp mô hình tiền huấn luyện trên tập dữ liệu đích thường không đủ để khai thác hiệu quả, đồng thời dễ dẫn đến hiện tượng overfitting và khả năng tổng quát hóa kém trong môi trường tài nguyên ít. Các nghiên cứu gần đây về fine-tuning mBART cho dịch máy ngôn ngữ ít tài nguyên có thể cải thiện đáng kể hiệu năng mô hình

[38,47]. Thay vì fine-tuning mô hình mBART trên nhiều ngôn ngữ ký hiệu trong một giai đoạn duy nhất, chúng tôi lựa chọn chiến lược huấn luyện đa giai đoạn, trong đó mỗi giai đoạn chỉ sử dụng một hệ ngôn ngữ ký hiệu. Cách tiếp cận này giúp giảm thiểu hiện tượng negative transfer và sự thiên lệch tham số về các tập dữ liệu có kích thước lớn, đồng thời cho phép mô hình thích nghi dần với phân bố và cấu trúc cú pháp của ngôn ngữ ký hiệu tiếng Việt. Việc huấn luyện tuần tự theo từng miền dữ liệu cũng đóng vai trò như một hình thức curriculum learning, giúp ổn định quá trình tối ưu hóa và cải thiện khả năng tổng quát hóa trong bối cảnh dữ liệu hạn chế. Dựa trên các kết quả đó, chúng tôi thiết kế một quy trình thực nghiệm gồm năm chiến lược huấn luyện khác nhau, tương ứng với các giả thuyết nghiên cứu về tác động của: (i) huấn luyện cơ sở dựa trên vanilla fine-tuning với dữ liệu gốc, (ii) mở rộng dữ liệu thông qua làm giàu dữ liệu, (iii) học chuyển tiếp đa ngôn ngữ trực tiếp, (iv) học chuyển tiếp đa ngôn ngữ có giai đoạn thích nghi trung gian, và (v) học chuyển tiếp đa ngôn ngữ mở rộng với nhiều ngôn ngữ ký hiệu trung gian. Quy trình này cho phép đánh giá một cách có hệ thống mức độ mà các chiến lược huấn luyện fine-tuning có thể cải thiện hiệu năng của mô hình trên bài toán dịch Ngôn ngữ Ký hiệu tiếng Việt.

Cấu hình huấn luyện: Sau kiểm thử với 13 trials, chúng tôi đã chọn được tham số huấn luyện chính thức cho mô hình. Learning Rate = $3e - 5$, Warmup Ratio = 0.1, Gradient Accumulation = 4, Label Smoothing = 0.0, và dừng huấn luyện tại Epoch 5.

– **Chiến lược 1: Huấn luyện cơ sở**

Trong chiến lược cơ sở này, mô hình được huấn luyện trực tiếp trên tập dữ liệu gốc Vie-Vsl Corpus bao gồm 10,000 cặp câu. Mục đích của chiến lược này là thiết lập một đường cơ sở để đánh giá năng lực của mô hình khi chỉ tiếp xúc với nguồn dữ liệu thực tế, chưa qua can thiệp.

– **Chiến lược 2: Huấn luyện dữ liệu gốc với dữ liệu làm giàu.**

Chiến lược này tập trung vào việc mở rộng không gian mẫu. Chúng tôi kết hợp tập dữ liệu gốc với tập dữ liệu đã được làm giàu thông qua các kỹ thuật được nhắc đến ở mục 4.2.2. Việc gia tăng kích thước và độ đa dạng của dữ liệu huấn luyện giúp mô hình giảm thiểu nguy cơ quá khớp (overfitting) và học được các biểu diễn ngữ nghĩa bao quát hơn.

– **Chiến lược 3: Huấn luyện đa ngôn ngữ trực tiếp**

Chiến lược này nhằm đánh giá hiệu quả của việc chuyển giao tri thức từ tập dữ liệu lớn sang tập dữ liệu đích mà không thông qua bước đệm dữ liệu làm giàu. Quy trình bao gồm 2 giai đoạn:

- Giai đoạn 1: Huấn luyện mô hình trên bộ dữ liệu RWTH-PHOENIX-2014-T. Giai đoạn này giúp mô hình học các đặc trưng và tổng quát cấu trúc câu, từ một bộ dữ liệu chuẩn hóa quốc tế có kích thước lớn.
- Giai đoạn 2 : Tinh chỉnh trực tiếp trên tập dữ liệu gốc Vie-Vsl Corpus. Các trọng số đã học được từ Phoenix được điều chỉnh ngay lập tức để thích nghi với miền dữ liệu đích, giúp kiểm chứng khả năng tổng quát hóa trực tiếp giữa hai ngôn ngữ ký hiệu.

– **Chiến lược 4: Huấn luyện đa ngôn ngữ**

Chiến lược này mở rộng Chiến lược 3 bằng cách bổ sung một giai đoạn trung gian nhằm giảm khoảng cách miền giữa dữ liệu nguồn và dữ liệu đích:

- Giai đoạn 1: Huấn luyện mô hình trên bộ dữ liệu RWTH-PHOENIX-2014-T. Mặc dù khác biệt về ngôn ngữ, nhưng cấu trúc cú pháp không gian của ngôn ngữ ký hiệu có những nét tương đồng. Giai đoạn này giúp mô hình làm quen với đặc trưng của ngôn ngữ ký hiệu từ một bộ dữ liệu chuẩn hóa quốc tế.
- Giai đoạn 2: Tiếp tục huấn luyện trên tập dữ liệu làm giàu. Giai đoạn này đóng vai trò cầu nối, chuyển đổi dần trọng số của mô hình từ miền ngôn ngữ ký hiệu Đức sang ngôn ngữ tiếng Việt.
- Giai đoạn 3: Tinh chỉnh cuối cùng trên tập dữ liệu đích gốc. Lúc này, mô hình đã sở hữu các trọng số tốt, cho phép hội tụ nhanh và chính xác hơn trên tập dữ liệu mục tiêu.

– **Chiến lược 5: Huấn luyện đa ngôn ngữ mở rộng**

Chiến lược này nhằm đánh giá tác động của việc bổ sung thêm một ngôn ngữ ký hiệu trung gian trong quá trình học chuyển tiếp.

- Giai đoạn 1: Huấn luyện mô hình trên bộ dữ liệu RWTH-PHOENIX-2014-T.
- Giai đoạn 2: Tiếp tục huấn luyện trên ASLG-PC12.
- Giai đoạn 3: Tinh chỉnh cuối cùng trên tập dữ liệu đích gốc. Lúc này, mô hình đã sở hữu các trọng số tốt, cho phép hội tụ nhanh và chính xác hơn trên tập dữ liệu mục tiêu.

Mỗi giai đoạn chỉ sử dụng một ngôn ngữ ký hiệu duy nhất, cho phép mô hình lần lượt học các đặc trưng cú pháp và biểu diễn cấu trúc từ nhiều hệ thống ký hiệu khác nhau. Việc bổ sung ASL trong chiến lược này là 1 phép kiểm chứng sự thích nghi tham số trong quá trình huấn luyện, cho phép mô hình tiếp xúc với phân bố cấu trúc ký hiệu đa dạng hơn, từ đó hạn chế hiện tượng quá chuyên biệt hóa vào tập dữ liệu PHOENIX trước khi thích nghi với dữ liệu VSL có kích thước hạn chế.

5.3 Performance Metrics

Đánh giá chất lượng chuyển đổi từ văn bản tiếng Việt sang chuỗi gloss đặt ra những thách thức đặc thù như đầu ra vừa là một chuỗi ký hiệu vừa mang các biến đổi cú pháp khác với ngôn ngữ viết thông thường. Do đó, chúng tôi áp dụng chiến lược đánh giá đa chiều kết hợp các chỉ số tự động tiêu chuẩn trong dịch máy, tương tự các nghiên cứu Text-to-Gloss trước đây [14].

Các chỉ số tự động được sử dụng nhằm phản ánh các khía cạnh khác nhau của chất lượng dịch: bảo toàn tương đồng ngữ nghĩa, chi phí chỉnh sửa, cấu trúc chuỗi và mức bao phủ từ/cụm. Việc sử dụng đồng thời nhiều chỉ số nhằm tránh thiên lệch khi chỉ dựa trên một thước đo duy nhất, đặc biệt trong bối cảnh gloss không phải là biểu diễn ngôn ngữ tự nhiên đầy đủ.

- **sacreBLEU**: sacreBLEU [41] là một triển khai chuẩn hóa cho phép tính BLEU. Chỉ số dùng các bước tokenization/normalization cố định và sinh ra một chuỗi ngắn ghi lại cấu hình đo, giúp đảm bảo khả năng tái tạo và minh bạch khi so sánh điểm số giữa các công trình. BLEU tự thân đo mức trùng khớp n-gram giữa đầu ra và tham chiếu [40]. Ở cấp độ tập hợp corpus-level,

BLEU thường cho tương quan hợp lý với đánh giá con người về độ chính xác nội dung và mức độ phù hợp tổng thể.

- **Translation Edit Rate (TER):** TER [45] đo số thao tác nhỏ nhất để biến câu sinh ra thành đầu ra mong muốn. Chỉ số này phù hợp ở bài toán gloss vì các hoán vị và xóa/chèn thường xuất hiện.
- **ROUGE-L F1:** ROUGE-L [10] đo dựa trên độ dài của longest common subsequence (LCS) giữa chuỗi sinh và chuỗi tham chiếu. LCS phản ánh mức độ bảo toàn trật tự tương đối và cấu trúc chuỗi ở quy mô câu, nhờ vậy ROUGE-L đặc biệt thích hợp để phát hiện xem các thành phần quan trọng của một gloss có còn xuất hiện ở đúng trình tự tương đối hay không. Trong lĩnh vực sign language, F1-score được lựa chọn là một trong những thước đo đánh giá chuỗi gloss sinh ra [14,7].
- **COMET:** COMET [43] là một chỉ số đánh giá dựa trên mô hình học sâu, được huấn luyện trực tiếp từ dữ liệu đánh giá của con người nhằm ước lượng mức độ tương đương ngữ nghĩa giữa bản dịch sinh và bản tham chiếu. Khác với các metric dựa trên trùng khớp bề mặt như BLEU, COMET khai thác biểu diễn ngữ nghĩa ngữ cảnh để phản ánh tốt hơn mức độ phù hợp về ý nghĩa và tính chấp nhận của câu dịch. Trong bài toán sinh gloss, COMET được sử dụng như một thước đo bổ sung nhằm đánh giá mức độ bảo toàn ngữ nghĩa, trong khi sacreBLEU phản ánh mức độ phù hợp về mặt hình thức và cấu trúc chuỗi.

6 Results

6.1 mBART

Sau khi huấn luyện với 5 chiến lược được nêu ở mục 5.2.3, chúng tôi tiến hành phân tích kết quả đánh giá chi tiết như sau. Chúng tôi trình bày kết quả đánh giá toàn diện của các cấu hình mBART trên tập test Vie-VSL-10k.

6.1.1 Hiệu năng huấn luyện cơ sở - Tiếng Việt (Chiến lược 1) Trong chiến lược huấn luyện cơ sở, mô hình mBART-large-50 được fine-tune trực tiếp trên tập dữ liệu gốc Vie-VSL-10k. Kết quả cuối cùng đạt BLEU score 92.31, TER 5.32, ROUGE-L F1 0.9594 và COMET 0.9581.

Từ Hình ??, mô hình hội tụ nhanh chóng trong 2000 updates đầu tiên, với BLEU tăng từ khoảng 85 lên xấp xỉ 94, sau đó dao động ổn định quanh mức 95–96 trong suốt quá trình huấn luyện. Chỉ số TER (Hình ??) giảm đáng kể từ khoảng 10 xuống dưới 3 trong 2000 updates đầu và tiếp tục dao động ổn định ở mức thấp, phản ánh mức độ chỉnh sửa tối thiểu cần thiết. ROUGE-L (Hình ??) và COMET (Hình ??) cũng thể hiện xu hướng tương tự, đạt mức cao và ổn định sau giai đoạn khởi đầu.

Hiệu năng này thiết lập một đường cơ sở vững chắc, khẳng định rằng kiến trúc mBART với ưu thế từ quá trình tiền huấn luyện đa ngôn ngữ trên quy mô lớn cung cấp một không gian biểu diễn ngữ nghĩa hiệu quả cho bài toán text-to-gloss, ngay cả trong điều kiện dữ liệu thực tế hạn chế.

6.1.2 Tác động của làm giàu dữ liệu (Chiến lược 2) Việc kết hợp dữ liệu gốc với dữ liệu tổng hợp sinh bởi LLM (đường màu cam trong Hình 7) mang lại những cải thiện nhất định về hiệu năng. Kết quả cuối cùng cho thấy BLEU score tăng từ 92.31 lên 93.41, TER giảm từ 5.32 xuống 4.45, và ROUGE-L F1 tăng từ 0.9594 lên 0.9674. Đặc biệt, COMET đạt 0.9612, cho thấy sự cải thiện về chất lượng ngữ nghĩa.

Quan sát từ Hình ?? cho thấy cấu hình VieVSL10k + Synth (đường cam) có xu hướng đạt điểm BLEU cao hơn và ổn định hơn so với cấu hình baseline (đường xanh) trong giai đoạn đầu huấn luyện (0–2000 updates), với BLEU dao động quanh 94–96. Tương tự, chỉ số TER (Hình ??) của cấu hình có làm giàu dữ liệu giảm nhanh hơn và duy trì ở mức thấp hơn (~ 2.5 –3) so với baseline (~ 3 –5) trong giai đoạn đầu.

ROUGE-L (Hình ??) cũng thể hiện sự vượt trội tương tự trong giai đoạn khởi đầu. COMET (Hình ??) của cả hai cấu hình đều đạt mức cao (>0.98) và tương đối ổn định, cho thấy chất lượng ngữ nghĩa được bảo toàn tốt trong cả hai trường hợp. Các kết quả này chứng minh rằng dữ liệu tổng hợp không chỉ hỗ trợ mô hình hội tụ nhanh hơn mà còn giúp sinh ra các chuỗi gloss có cấu trúc chính xác hơn, đồng thời giảm thiểu số lượng thao tác chỉnh sửa cần thiết, đặc biệt trong giai đoạn đầu của quá trình fine-tuning.

6.1.3 Học chuyển tiếp đa ngôn ngữ (Chiến lược 3–5) Chiến lược 3: Chuyển tiếp từ PHOENIX14-T sang Tiếng Việt. Panel giữa của Hình 7 (German (PHOENIX14-T) + Vietnamese) trình bày kết quả của hai cấu hình học chuyển tiếp: (i) chuyển tiếp trực tiếp từ PHOENIX14-T sang Vie-VSL-10k (đường xanh), và (ii) chuyển tiếp có giai đoạn thích nghi qua dữ liệu làm giàu (đường cam).

Việc học chuyển tiếp trực tiếp từ bộ dữ liệu PHOENIX14-T sang Vie-VSL-10k đạt BLEU 92.79, TER 5.46, ROUGE-L F1 0.9604, và COMET 0.9610. Từ Hình ?? (panel giữa), cả hai cấu hình đều cho thấy quá trình hội tụ ban đầu khá dao động, với BLEU tăng từ khoảng 90 lên 95–96 trong 2000 updates đầu tiên. Sau đó, cấu hình không có làm giàu dữ liệu (đường xanh) duy trì xu hướng tăng nhẹ và ổn định hơn, trong khi cấu hình có giai đoạn thích nghi (đường cam) dao động nhiều hơn trong giai đoạn giữa (1000–2500 updates) trước khi ổn định.

Chỉ số TER (Hình ??, panel giữa) cho thấy cả hai cấu hình đều giảm mạnh từ mức cao (~ 6.5) xuống khoảng 2.5–3.5 trong 2000 updates đầu. Đáng chú ý, cấu hình có làm giàu dữ liệu đạt TER thấp hơn (~ 2.5 –3) trong giai đoạn cuối, so với cấu hình chuyển tiếp trực tiếp (~ 3 –3.5), phản ánh lợi ích của giai đoạn thích nghi trung gian trong việc giảm chi phí chỉnh sửa.

ROUGE-L (Hình ??, panel giữa) và COMET (Hình ??, panel giữa) của cả hai cấu hình đều đạt mức cao và tương đối ổn định (ROUGE-L ~ 0.985 –0.990, COMET ~ 0.982 –0.984), cho thấy cả hai chiến lược đều bảo toàn tốt cấu trúc chuỗi và ngữ nghĩa.

Chiến lược 4: Học chuyển tiếp có giai đoạn thích nghi. Để giảm khoảng cách miền (domain gap) giữa DGS và VSL, chúng tôi thiết kế một chiến lược huấn luyện ba giai đoạn: (1) fine-tune trên PHOENIX14-T, (2) tiếp tục

fine-tune trên dữ liệu làm giàu Vie-VSL (LLM synth), và (3) fine-tune cuối cùng trên dữ liệu thật Vie-VSL-10k. Cấu hình này đạt BLEU 93.41, TER 4.45, ROUGE-L F1 0.9674, và COMET 0.9612—tương đương với chiến lược 2 về hiệu năng tổng thể. Kết quả này cho thấy việc kết hợp học chuyển tiếp đa giai đoạn với dữ liệu tổng hợp mang lại tính ổn định cao và hiệu năng tối ưu.

Chiến lược 5: Chuyển tiếp từ ASL sang Tiếng Việt. Panel phải của Hình 7 (English (ASL) + Vietnamese) trình bày kết quả khi sử dụng ASLG-PC12 làm nguồn cho học chuyển tiếp. Hai cấu hình được so sánh là: (i) chuyển tiếp trực tiếp từ ASL sang Vie-VSL-10k (đường xanh), và (ii) chuyển tiếp có giai đoạn thích nghi qua dữ liệu làm giàu (đường cam).

Việc tích hợp ASLG-PC12 vào quy trình học chuyển tiếp đơn thuần (ASLG-PC12 $\rightarrow$ Vie-VSL-10k) đạt BLEU 91.99, TER 5.50, và ROUGE-L F1 0.9584, thấp hơn so với baseline. Kết quả BLEU (Hình ??, panel phải) cho thấy sự khác biệt rõ rệt giữa hai cấu hình. Cấu hình chuyển tiếp trực tiếp (đường xanh) ban đầu đạt BLEU cao (~ 96 – 97) nhưng giảm mạnh xuống ~ 93 ở khoảng 1500 updates, sau đó mới hồi phục và tăng trở lại lên ~ 97 ở cuối quá trình huấn luyện. Ngược lại, cấu hình có làm giàu dữ liệu (đường cam) khởi đầu thấp hơn (~ 95) nhưng tăng đều và ổn định hơn, đạt mức cao nhất ~ 97.5 ở cuối quá trình, vượt trội so với cấu hình chuyển tiếp trực tiếp.

Chỉ số TER (Hình ??, panel phải) cũng phản ánh xu hướng này: cấu hình chuyển tiếp trực tiếp dao động mạnh với TER tăng đột ngột lên ~ 4.5 ở khoảng 1500 updates (tương ứng với giai đoạn BLEU giảm mạnh), trong khi cấu hình có làm giàu dữ liệu giảm đều từ ~ 2.5 xuống ~ 1.5 , cho thấy sự ổn định và hiệu quả cao hơn trong việc giảm chi phí chỉnh sửa.

ROUGE-L (Hình ??, panel phải) cũng thể hiện pattern tương tự, với cấu hình có làm giàu dữ liệu đạt điểm cao hơn và ổn định hơn (~ 0.991 – 0.992) so với cấu hình chuyển tiếp trực tiếp có dao động mạnh (từ ~ 0.989 xuống ~ 0.976 rồi tăng trở lại ~ 0.991). COMET (Hình ??, panel phải) cũng cho thấy sự vượt trội của cấu hình có làm giàu dữ liệu, đạt đỉnh ~ 0.9865 so với ~ 0.9862 của cấu hình chuyển tiếp trực tiếp.

Tuy nhiên, khi kết hợp với dữ liệu tổng hợp (ASLG-PC12 $\rightarrow$ LLM synth $\rightarrow$ Vie-VSL-10k), hiệu năng đạt mức tốt nhất trong tất cả các chiến lược mBART với BLEU 93.68, TER 4.18, và ROUGE-L F1 0.9684. Điều này chứng minh vai trò quan trọng của dữ liệu tổng hợp trong việc làm cầu nối và giảm thiểu khoảng cách miền giữa ASL và VSL, giúp chuyển đổi hiện tượng “chuyển giao tiêu cực” (negative transfer) thành chuyển giao tích cực.

6.1.4 Tổng kết Kết quả từ các biểu đồ huấn luyện cho thấy:

- **Vai trò của dữ liệu làm giàu:** Dữ liệu tổng hợp đóng vai trò quan trọng trong việc tăng tốc hội tụ và cải thiện độ ổn định của quá trình huấn luyện, đặc biệt rõ rệt trong các chiến lược học chuyển tiếp đa ngôn ngữ.
- **Hiệu quả của giai đoạn thích nghi trung gian:** Việc bổ sung giai đoạn thích nghi qua dữ liệu làm giàu giữa ngôn ngữ nguồn và đích giúp làm mịn quá trình chuyển đổi, giảm dao động và cải thiện hiệu năng cuối cùng, đặc biệt trong trường hợp chuyển tiếp từ ASL.

Model	Training setting	BLEU TER ROUGE-L (F1) COMET			
Transformer	Vie-VSL-10k	62.00	27.12	0.8571	0.872
Transformer	Vie-VSL-10k + LLM synth	86.07	11.07	0.9423	0.958
BARTPho	Vie-VSL-10k	93.23	5.13	0.9631	0.958
BARTPho	Vie-VSL-10k + LLM synth	93.85	4.20	0.9613	0.961
mBART	Vie-VSL-10k	90.	3.88	0.9685	0.962
mBART	Vie-VSL-10k + LLM synth	88.76	3.66	0.9692	0.962
mBART	Vie-VSL-10k + PHOENIX14-T	93.39	4.56	0.9643	0.972
mBART	Vie-VSL-10k + LLM synth + PHOENIX14-T	93.46	4.21	0.9681	0.974
mBART	Vie-VSL-10k + ASLG-PC12	94.13	3.98	0.9672	0.974
mBART	Vie-VSL-10k + LLM synth + ASLG-PC12	90.56	6.04	0.9534	0.955

Table 4: Đánh giá trên tập kiểm tra Vie-VSL: sacreBLEU, TER, ROUGE-L F1 và COMET. Các giá trị in đậm biểu thị điểm tốt nhất theo từng chỉ số.

- **Tác động của khoảng cách ngôn ngữ:** Kết quả cho thấy học chuyển tiếp từ ASL gặp nhiều thách thức hơn so với PHOENIX14-T (có thể do ASL và VSL có cấu trúc cú pháp khác biệt lớn hơn), tuy nhiên việc sử dụng dữ liệu làm giàu như một “cầu nối” đã giúp chuyển đổi hiện tượng negative transfer thành positive transfer, mang lại hiệu năng tốt nhất trong tất cả các chiến lược.
- **Độ ổn định:** Các chỉ số đều cho thấy mô hình đạt được sự ổn định cao sau giai đoạn khởi đầu, phản ánh khả năng tổng quát hóa tốt của mBART trong bài toán text-to-gloss với dữ liệu ít tài nguyên.

Cần thảo luận kết quả đạt được + advs + challenges của framework đề xuất
+ ví dụ minh họa
Future work cần trao đổi các hướng phát triển

7 Conclusion

7.1 Trực Quan Hóa Bằng Avatar 3D

Một số công trình tiên phong đã tiến hành số hóa và trực quan hóa ngôn ngữ ký hiệu tiếng Việt bằng avatar 3D, điển hình là nghiên cứu của Ngôn và cộng sự [33], trong đó hơn 2558 từ diễn tả NNKH đã được xây dựng. Mặc dù các nghiên cứu này đã đạt được những kết quả quan trọng trong việc mô tả hình thái thủ công của ký hiệu (ví dụ: hình dạng bàn tay, hướng và chuyển động), các yếu tố phi thủ công, đặc biệt là biểu cảm khuôn mặt và hình thái cảm xúc, vẫn chưa được mô hình hóa một cách đầy đủ và có hệ thống. Trong khi đó, các đặc trưng phi thủ công đóng vai trò then chốt trong việc biểu đạt ngữ nghĩa, thái độ và cấu trúc cú pháp của ký hiệu [43]. Do đó, trong nghiên cứu này, nhóm chúng tôi tập trung xây dựng một bộ từ điển ký hiệu chỉ dành cho hệ thống ngôn ngữ ký hiệu miền Nam Việt Nam, đồng thời biểu diễn bao gồm các hình thái cảm xúc và cử chỉ khuôn mặt trong quá trình sinh SiGML và trực quan hóa bằng avatar 3D. Cụ thể, quá trình tổng hợp chuyển động được thực hiện thông qua cơ chế

truy vấn phân tầng ưu tiên. Với đầu vào là chuỗi gloss từ mô hình dịch máy, hệ thống thực hiện tìm kiếm theo ba bước tuần tự:

1. **Khớp chính xác (Exact matching):** Hệ thống tra cứu trực tiếp gloss trong bộ từ điển VieSIGML đã dựng trước đó để trích xuất đoạn mã SiGML tương ứng.
2. **Thay thế đồng nghĩa (Synonym Mapping):** Trong trường hợp từ khóa đầu vào không khớp chính xác với bất kỳ từ nào, hệ thống sẽ kích hoạt cơ chế tra cứu mở rộng trên cột dữ liệu từ đồng nghĩa (Gloss Synonyms) đã được tích hợp sẵn trong bộ từ điển VieSiGML. Cơ chế này hoạt động bằng cách tìm xem từ khóa có nằm trong danh sách đồng nghĩa của một gloss đích nào không (ví dụ: từ khóa "má" hoặc "u" được liệt kê là đồng nghĩa của gloss gốc "mẹ"). Nếu tìm thấy, hệ thống sẽ thực hiện ánh xạ về gloss gốc để truy xuất dữ liệu chuyển động tương ứng.
3. **Đánh vần ngón tay (Fingerspelling):** Nếu cả hai bước trên đều không trả về kết quả, hệ thống sẽ kích hoạt cơ chế dự phòng bằng cách chuyển đổi từ vựng sang dạng đánh vần từng chữ cái, đảm bảo thông tin không bị mất mát trong quá trình trực quan hóa.


References

1. Abdullah, S.M., Paul, A., Rayana, S., Kabir, A., Masud, Z.: State-of-the-art translation of text-to-gloss using mbart: A case study of bangla. arXiv preprint arXiv:2504.02293 (2025)
2. Alaghband, M., Maghroor, H.R., Garibay, I.: A survey on sign language literature. *Machine Learning with Applications* **14**, 100504 (2023)
3. Amodei, D., Ananthanarayanan, S., Anubhai, R., Bai, J., Battenberg, E., Case, C., Casper, J., Catanzaro, B., Cheng, Q., Chen, G., et al.: Deep speech 2: End-to-end speech recognition in english and mandarin. In: *International conference on machine learning*. pp. 173–182. PMLR (2016)
4. Armengol-Estapé, J., Costa-jussà, M.R.: Semantic and syntactic information for neural machine translation: Injecting features to the transformer. *Machine Translation* **35**(1), 3–17 (2021)
5. Baevski, A., Zhou, Y., Mohamed, A., Auli, M.: wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in neural information processing systems* **33**, 12449–12460 (2020)
6. Bộ Giáo dục và Đào tạo, Việt Nam: Danh mục ngôn ngữ ký hiệu. <https://qipcdc.moet.gov.vn/dictionary> (2026), truy cập ngày 05 tháng 01 năm 2026
7. Camgoz, N.C., Hadfield, S., Koller, O., Ney, H., Bowden, R.: Neural sign language translation. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 7784–7793 (2018)
8. Camgoz, N.C., Koller, O., Hadfield, S., Bowden, R.: Sign language transformers: Joint end-to-end sign language recognition and translation. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. pp. 10023–10033 (2020)
9. Caswell, I., Chelba, C., Grangier, D.: Tagged back-translation. In: *Proceedings of the Fourth Conference on Machine Translation (Volume 1: Research Papers)*. pp. 53–63. Association for Computational Linguistics (2019)


10. Chin-Yew, L.: Rouge: A package for automatic evaluation of summaries. In: Proceedings of the Workshop on Text Summarization Branches Out, 2004 (2004)
11. Chiruzzo, L., McGill, E., Egea-Gómez, S., Saggion, H.: Translating spanish into spanish sign language: Combining rules and data-driven approaches. In: Proceedings of the fifth workshop on technologies for machine translation of low-resource languages (LoResMT 2022). pp. 75–83 (2022)
12. De Sisto, M., Vandeghinste, V., Egea Gómez, S., De Coster, M., Shterionov, D., Saggion, H., Calzolari, N., Bechet, F., Blache, P., Choukri, K., et al.: Challenges with sign language datasets for sign language recognition and translation. In: Proceedings of the 13th International Conference on Language Resources and Evaluation (LREC). pp. 2478–2487. EUROPEAN LANGUAGE RESOURCES ASSOCIATION (ELRA) (2022)
13. Egea Gómez, S., Chiruzzo, L., McGill, E., Saggion, H.: Linguistically enhanced text to sign gloss machine translation. In: International Conference on Applications of Natural Language to Information Systems. pp. 172–183. Springer (2022)
14. Egea-Gómez, S., McGill, E., Saggion, H.: Syntax-aware transformers for neural machine translation: The case of text to sign gloss translation. In: Proceedings of the 14th workshop on building and using comparable corpora (BUCC 2021). pp. 18–27 (2021)
15. Elliott, R., Glauert, J., Jennings, V., Kennaway, R.: An overview of the sigml notation and sigmlsigning software system. *sign-lang@ LREC 2004* pp. 98–104 (2004)
16. Fang, S., Chen, C., Wang, L., Zheng, C., Sui, C., Tian, Y.: Signllm: Sign language production large language models. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 6622–6634 (2025)
17. Forster, J., Schmidt, C., Koller, O., Bellgardt, M., Ney, H.: Extensions of the sign language recognition and translation corpus rwth-phoenix-weather. In: LREC. pp. 1911–1916 (2014)
18. de Gibert, O., Attieh, J., Vahtola, T., Aulamo, M., Li, Z., Vázquez, R., Hu, T., Tiedemann, J.: Scaling low-resource mt via synthetic data generation with llms. *arXiv preprint arXiv:2505.14423* (2025)
19. Gong, J., Foo, L.G., He, Y., Rahmani, H., Liu, J.: Llms are good sign language translators. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 18362–18372 (2024)
20. Guo, J., Li, P., Cohn, T.: Bridging sign and spoken languages: Pseudo gloss generation for sign language translation. *arXiv preprint arXiv:2505.15438* (2025)
21. Guo, P., et al.: Pseudo gloss generation for sign language translation. *arXiv preprint* (2025)
22. Hanke, T.: Hamnosys—representing sign language data in language resources and language processing contexts. In: *sign-lang@ LREC 2004*. pp. 1–6. European Language Resources Association (ELRA) (2004)
23. Hương, N.T., Hà, T.L.P., Sương, N.T.: Một số Đặc Điểm về ngôn ngữ ký hiệu thành phố hồ chí minh
24. Inan, M., Sicilia, A., Alikhani, M.: Signalignlm: Integrating multimodal sign language processing into large language models. In: Findings of the Association for Computational Linguistics: ACL 2025. pp. 3691–3706 (2025)
25. Iyer, V., Malik, B., Stepachev, P., Chen, P., Haddow, B., Birch, A.: Quality or quantity? on data scale and diversity in adapting large language models for low-resource translation. *arXiv preprint arXiv:2408.12780* (2024)
26. Kaur, K., Kumar, P.: Hamnosys to sigml conversion system for sign language automation. *Procedia Computer Science* **89**, 794–803 (2016)

27. Khanh, D.: Visl model: The model automatically generates sentences of vietnamese sign language. *Journal Scientific and Technical Of Information Technologies, Mechanics and Optics* **157**(5), 779 (2024)
28. Le, T.T., Nguyen, L.T., Nguyen, D.Q.: Phowhisper: Automatic speech recognition for vietnamese. *arXiv preprint arXiv:2406.02555* (2024)
29. Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., Zettlemoyer, L.: Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In: *Proceedings of the 58th annual meeting of the association for computational linguistics*. pp. 7871–7880 (2020)
30. Liang, Z., Li, H., Chai, J.: Sign language translation: A survey of approaches and techniques. *Electronics* **12**(12), 2678 (2023)
31. Lin, K., Wang, X., Zhu, L., Sun, K., Zhang, B., Yang, Y.: Gloss-free end-to-end sign language translation. *arXiv preprint arXiv:2305.12876* (2023)
32. Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., Zettlemoyer, L.: Multilingual denoising pre-training for neural machine translation. *Transactions of the Association for Computational Linguistics* **8**, 726–742 (2020)
33. Moryossef, A., Müller, M., Göhring, A., Jiang, Z., Goldberg, Y., Ebling, S.: An open-source gloss-based baseline for spoken to signed language translation. In: *Proceedings of the Second International Workshop on Automatic Translation for Signed and Spoken Languages*. pp. 22–33 (2023)
34. Moryossef, A., Yin, K., Neubig, G., Goldberg, Y.: Data augmentation for sign language gloss translation. *arXiv preprint arXiv:2105.07476* (2021)
35. Najib, F.M.: Sign language interpretation using machine learning and artificial intelligence. *Neural Computing and Applications* **37**(2), 841–857 (2025)
36. Ngo, T.D., Nguyen, D.H.L., Luong, H.L.: Sign language representation using virtual characters with 3d animation. *VNU Journal of Science: Computer Science and Communication Engineering* **41**(1 (2025)) (2025)
37. Ngõn, N.C., Đa, Q.L.: Application of hamnosys and avatar 3d jasingning to construction of vietnamese sign language animations. *Tạp chí Khoa học và Công nghệ-Đại học Đà Nẵng* pp. 61–65 (2017)
38. Nwe, H.M., Shirai, K., Kertkeidkachorn, N., Theeramunkong, T., Thu, Y.K., Supnithi, T., Kaothanthong, N.: Enhancing translation of myanmar sign language by transfer learning and self-training. In: *Proceedings of Machine Translation Summit XIX, Vol. 1: Research Track*. pp. 111–122 (2023)
39. Othman, A., Jemni, M.: English-asl gloss parallel corpus 2012: Aslg-pc12. In: *sign-lang@ LREC 2012*. pp. 151–154. European Language Resources Association (ELRA) (2012)
40. Papineni, K., Roukos, S., Ward, T., Zhu, W.J.: Bleu: a method for automatic evaluation of machine translation. In: *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*. pp. 311–318 (2002)
41. Post, M.: A call for clarity in reporting bleu scores. *arXiv preprint arXiv:1804.08771* (2018)
42. Radford, A., Kim, J.W., Xu, T., Brockman, G., McLeavey, C., Sutskever, I.: Robust speech recognition via large-scale weak supervision. In: *International conference on machine learning*. pp. 28492–28518. PMLR (2023)
43. Rei, R., Stewart, C., Farinha, A.C., Lavie, A.: Comet: A neural framework for mt evaluation. *arXiv preprint arXiv:2009.09025* (2020)
44. Roudra, N.A., Saha, N., Shahriyar, R., Sakib, S.: Introducing a Bangla sentence gloss pair dataset for Bangla sign language translation and research. Ph.D. thesis, BRAC University (2025)


45. Snover, M., Dorr, B., Schwartz, R., Micciulla, L., Makhoul, J.: A study of translation edit rate with targeted human annotation. In: *Proceedings of the 7th Conference of the Association for Machine Translation in the Americas: Technical Papers*. pp. 223–231 (2006)
46. Tan, S., Khan, N., An, Z., Ando, Y., Kawakami, R., Nakadai, K.: A review of deep learning-based approaches to sign language processing. *Advanced Robotics* **38**(23), 1649–1667 (2024)
47. Thillainathan, S., Yuan, S., Lee, E.S.A., Jayasena, S., Ranathunga, S.: Beyond vanilla fine-tuning: Leveraging multistage, multilingual, and domain-specific methods for low-resource machine translation. *arXiv preprint arXiv:2503.22582* (2025)
48. Tran, A.V., Hoang, Q.H., Pham, T.V.H., et al.: Vietnamese sign language alphabet recognition using deep learning and mediapipe methods. *JST: Smart Systems and Devices* **35**(1), 10–19 (2025)
49. Đức Tồn, N., Phương, N.T.: *Mấy vấn Đề cú pháp của ngôn ngữ ký hiệu Ở việt nam*
50. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: Attention is all you need. *Advances in neural information processing systems* **30** (2017)
51. Vương, H.T.: *Đặc điểm biểu đạt ngôn ngữ ký hiệu của người điếc việt nam. Nghiên cứu Giáo dục Đặc biệt* (2011)
52. Walsh, H., Ivashechkin, M., Bowden, R.: Using sign language production as data augmentation to enhance sign language translation. *arXiv preprint arXiv:2506.09643* (2025)
53. Wong, R., Camgoz, N.C., Bowden, R.: Sign2gpt: Leveraging large language models for gloss-free sign language translation. *arXiv preprint arXiv:2405.04164* (2024)
54. Yao, H., et al.: Semi-supervised spoken language glossification. *arXiv preprint arXiv:2406.08173* (2024)
55. Ye, J., Jiao, W., Wang, X., Tu, Z., Xiong, H.: Cross-modality data augmentation for end-to-end sign language translation. *arXiv preprint arXiv:2305.11096* (2023)
56. Yin, K., Read, J.: Better sign language translation with stmc-transformer. *arXiv preprint arXiv:2004.00588* (2020)
57. Zhang, X., Duh, K.: Approaching sign language gloss translation as a low-resource machine translation task. In: *Proceedings of the 1st International Workshop on Automatic Translation for Signed and Spoken Languages (AT4SSL)*. pp. 60–70 (2021)
58. Zhou, B., Chen, Z., Clapés, A., Wan, J., Liang, Y., Escalera, S., Lei, Z., Zhang, D.: Gloss-free sign language translation: Improving from visual-language pretraining. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. pp. 20871–20881 (2023)
59. Zhu, D., Czehmann, V., Avramidis, E.: Neural machine translation methods for translating text to sign language glosses. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. pp. 12523–12541 (2023)




(a) BLEU Score



(b) ROUGE-L F1



(c) TER



(d) COMET

Fig. 7: Evolution of evaluation metrics during mBART fine-tuning under three language configurations: Vietnamese (left), German (PHOENIX14-T) + Vietnamese (middle), and English (ASL) + Vietnamese (right).