

Speech to Sign Language Translation with 3D Avatar Integration

Khang Nhut Lam¹✉, An Trong La¹, Van Lam Le¹, and Jugal Kalita²

¹ Can Tho University, Can Tho, Vietnam

² University of Colorado, Colorado Springs, USA

Abstract. Chuyển đổi giọng nói tiếng Việt sang Ngôn ngữ Ký hiệu Việt Nam (Vietnamese Sign Language - VSL) là một bài toán nhiều thách thức do sự khan hiếm dữ liệu cho học máy và sự khác biệt về cấu trúc cú pháp giữa hai ngôn ngữ. Trong nghiên cứu này, chúng tôi triển khai một hệ thống chuyển đổi từ giọng nói sang ngôn ngữ ký hiệu Việt Nam, trong đó các mô-đun bao gồm giọng nói tiếng Việt được nhận dạng và chuyển thành văn bản, văn bản sau đó được chuyển đổi sang cấu trúc ngôn ngữ ký hiệu ở mức gloss, và cuối cùng chuỗi gloss được ánh xạ sang biểu diễn SiGML để hiển thị bằng avatar 3D. Ở giai đoạn đầu, mô-đun nhận dạng giọng nói sử dụng PhoWhisper để chuyển đổi giọng nói sang văn bản có độ chính xác cao và ranh giới câu phù hợp, qua đó hạn chế sự lan truyền lỗi sang bước dịch. Đối với mô-đun chuyển văn bản sang câu cấu trúc ngôn ngữ ký hiệu, chúng tôi tập trung giải quyết bài toán dữ liệu ít tài nguyên thông qua các chiến lược tăng cường dữ liệu dựa trên mô hình ngôn ngữ lớn, kết hợp truy hồi ngữ nghĩa và prompting có điều hướng bởi luật cú pháp. Dữ liệu tổng hợp thu được được sử dụng để huấn luyện và so sánh nhiều mô hình dịch dựa trên kiến trúc Transformer trong các thiết lập kết hợp dữ liệu khác nhau, phản ánh đặc điểm và mục tiêu của từng mô hình. Cuối cùng, chuỗi gloss đầu ra được ánh xạ sang chuỗi SiGML và trực quan hóa bằng avatar 3D JASigning. Kết quả cho thấy việc kết hợp mô-đun ASR, tăng cường dữ liệu có kiểm soát và lựa chọn mô hình dịch phù hợp là một hướng tiếp cận triển vọng cho bài toán chuyển đổi giọng nói tiếng Việt sang Ngôn ngữ Ký hiệu Việt Nam trong bối cảnh tài nguyên hạn chế.

1 Introduction

Khả năng tiếp cận thông tin của cộng đồng người khiếm thính vẫn còn hạn chế do phần lớn nội dung giao tiếp hằng ngày tồn tại dưới dạng ngôn ngữ nói hoặc văn bản viết. Nhưng đối với người khiếm thính, ngôn ngữ ký hiệu là phương thức giao tiếp tự nhiên đối với họ, nhưng hiện nay vẫn chưa được tích hợp rộng rãi trong các hệ thống truyền tải thông tin. Theo Điều tra Quốc gia về Người khuyết tật 2016 do Tổng cục Thống kê Việt Nam phối hợp với UNICEF thực hiện [?], dựa trên tỷ lệ người trưởng thành gặp khó khăn về nghe được báo cáo trong khảo sát có 1,37% dân số từ 18 tuổi trở lên, số người khiếm thính hoặc suy giảm thính lực ảnh hưởng đáng kể đến giao tiếp tại Việt Nam được ước tính

khoảng 890.000 người. Thực tế này cho thấy một bộ phận đáng kể dân số đang đối mặt với rào cản nghiêm trọng trong tiếp cận thông tin, giáo dục và các dịch vụ công, đặc biệt khi ngôn ngữ ký hiệu vẫn chưa được tích hợp rộng rãi trong các hệ thống truyền thông và công nghệ hỗ trợ hiện nay.

Những tiến bộ gần đây của các mô hình học sâu, đặc biệt là các kiến trúc dựa trên Transformer, đã mang lại hiệu quả vượt trội cho nhiều bài toán xử lý ngôn ngữ như dịch máy thần kinh và sinh chuỗi văn bản [46]. Trong các hệ thống chuyển đổi từ giọng nói hoặc văn bản sang ngôn ngữ ký hiệu, kiến trúc pipeline nhiều tầng thường được áp dụng, trong đó gloss được sử dụng như một biểu diễn trung gian nhằm chuẩn hoá đầu ra và tách biệt xử lý ngôn ngữ khỏi giai đoạn tổng hợp ký hiệu [19].

Trong ngữ cảnh xử lý ngôn ngữ ký hiệu, gloss thường được dùng như một dạng chuẩn hoá bằng văn bản để ghi lại chuỗi đơn vị ký hiệu theo một quy ước nhất định.[?]. Gloss không nhằm mô tả đầy đủ các thành phần đồng thời của ngôn ngữ ký hiệu (ví dụ biểu cảm khuôn mặt, định vị không gian), mà chủ yếu đóng vai trò biểu diễn tuyến tính phục vụ cho học máy và cho bước ánh xạ sang các biểu diễn ký hiệu giàu thông tin hơn (ví dụ HamNoSys/SiGML) [?,31]. Ví dụ minh hoạ: (1) **English**: “I like red.” → gloss: “I RED LIKE”. (2) **Vietnamese**: “Tôi thích màu đỏ.” → gloss: “Tôi màu_đỏ thích”.

Trong nghiên cứu này, chúng tôi xây dựng một kiến trúc mô-đun cho bài toán chuyển đổi tiếng Việt nói sang Ngôn ngữ Ký hiệu Việt Nam trong điều kiện hạn chế tài nguyên. Hệ thống đầu vào là mô-đun nhận dạng tiếng nói tự động (ASR) để thu được văn bản tiếng Việt, tiếp đến mô hình sinh chuỗi dựa trên Transformer để tạo ra chuỗi gloss tuyến tính (structural gloss) phản ánh trật tự và cấu trúc cú pháp đặc trưng của Ngôn ngữ Ký hiệu Việt Nam. Chuỗi gloss này sau đó được ánh xạ từ vựng thông qua bộ từ điển Vie-SiGML, trong đó mỗi mục từ được liên kết với một biểu diễn SiGML tương ứng phục vụ cho quá trình tổng hợp hoạt ảnh. Chuỗi SiGML sau đó được đưa vào bộ tổng hợp để sinh hoạt ảnh avatar 3D, chẳng hạn như JASigning [15], [32]. Trong phạm vi bài báo này, ASR được xem là mô-đun đầu vào và trọng tâm nghiên cứu tập trung vào khối dịch cấu trúc câu tiếng Việt sang cấu trúc câu ngôn ngữ ký hiệu trong bối cảnh dữ liệu ít tài nguyên và cơ chế biểu diễn, kết xuất ngôn ngữ ký hiệu. Đầu ra của hệ thống được chuẩn hóa theo biến thể Ngôn ngữ Ký hiệu Việt Nam khu vực miền Nam nhằm đảm bảo tính nhất quán trong toàn bộ quá trình huấn luyện, ánh xạ và dựng hoạt ảnh, từ đó tạo điều kiện thuận lợi cho việc đánh giá tính khả thi của cách tiếp cận đề xuất.

Contributions. Bài báo đề xuất và đánh giá một hệ thống chuyển đổi *Vietnamese speech* → *VSL* theo kiến trúc mô-đun, trong đó trọng tâm là bài toán dịch *Text-to-Gloss* cho VSL ít tài nguyên. Các đóng góp chính gồm: (i) thiết kế pipeline từ ASR (PhoWhisper) đến kết xuất avatar 3D thông qua ánh xạ gloss→SiGML; (ii) đề xuất chiến lược làm giàu dữ liệu dựa trên LLM prompting kết hợp truy hồi ngữ nghĩa (RAG) và ràng buộc luật cú pháp theo quy ước VSL; (iii) xây dựng và so sánh có hệ thống nhiều backbone dịch encoder-decoder (Transformer huấn luyện từ đầu, BARTPho, mBART) dưới các thiết lập dữ liệu khác nhau;

(iv) triển khai trực quan hoá bằng avatar 3D (JASigning) để kiểm chứng tính khả dụng của đầu ra gloss trong ngữ cảnh ứng dụng.

Research questions. Dựa trên mục tiêu nghiên cứu và bối cảnh ít tài nguyên của Vie-VSL, chúng tôi đặt ra các câu hỏi:

RQ1: Trong điều kiện dữ liệu Vie-VSL quy mô nhỏ, các backbone tiền huấn luyện encoder-decoder (BARTPho, mBART) cải thiện chất lượng Text-to-Gloss như thế nào so với Transformer huấn luyện từ đầu?

RQ2: Chiến lược tăng cường dữ liệu dựa trên LLM prompting kết hợp RAG và luật cú pháp có giúp cải thiện chất lượng dịch hay không, và mức độ cải thiện có nhất quán giữa các backbone khác nhau không?

2 Related Work

2.1 Ngôn ngữ Ký Hiệu

Ngôn ngữ ký hiệu là phương tiện giao tiếp chính của cộng đồng người khiếm thính, sở hữu cấu trúc ngữ pháp và từ vựng độc lập, khác biệt căn bản so với ngôn ngữ nói. Trong nhiều thập kỷ qua, bài toán xử lý và dịch máy ngôn ngữ ký hiệu đã thu hút sự quan tâm rộng rãi của cộng đồng nghiên cứu trên thế giới [30]. Tuy nhiên, đây vẫn được xem là một trong những bài toán khó do tính đa dạng, sự phụ thuộc mạnh vào ngữ cảnh không gian-thời gian, cũng như những hạn chế về dữ liệu và công nghệ.

Những năm gần đây, đã xuất hiện nhiều khảo sát và nghiên cứu áp dụng các phương pháp tiên tiến, đặc biệt là học sâu và mô hình đa mô thức, giúp thúc đẩy mạnh mẽ quá trình xử lý ngôn ngữ ký hiệu trên thế giới [41,27]. Một số công trình ứng dụng học sâu trong nhận dạng và dịch ngôn ngữ ký hiệu cho kết quả hứa hẹn trên các benchmark quốc tế, ví dụ như nghiên cứu về dịch ngôn ngữ ký hiệu kết hợp tiền huấn luyện, cho thấy mức độ dịch được cải thiện đáng kể trên các tập dữ liệu chuẩn như PHOENIX14T hoặc CSL-Daily [52]. Theo khảo sát mới nhất [27], các nghiên cứu không chỉ dừng lại ở bài toán nhận diện ký hiệu đơn lẻ mà đang chuyển dịch sang bài toán dịch ngôn ngữ ký hiệu, cho phép chuyển đổi hai chiều giữa video ký hiệu và văn bản/giọng nói, từ đó giúp phá vỡ rào cản giao tiếp. Tuy nhiên, phần lớn các nghiên cứu tiên tiến vẫn tập trung vào các ngôn ngữ ký hiệu phổ biến (ASL, DGS, CSL) do sự sẵn có của dữ liệu, để lại khoảng trống lớn cho các ngôn ngữ ít tài nguyên như Ngôn ngữ Ký hiệu Việt Nam.

2.2 Ngôn ngữ Ký Hiệu Việt Nam

Trước khi đi sâu vào Ngôn ngữ Ký hiệu Việt Nam (VSL), một trong những sai lầm phổ biến mà nhiều người hay nhầm lẫn đó chính là ngôn ngữ ký hiệu mang tính toán cầu và là một phiên bản chỉ chuyển thể từ ngôn ngữ nói sang hình ảnh. Tuy nhiên, các nghiên cứu ngôn ngữ học đã chứng minh rằng mỗi ngôn ngữ ký hiệu là một hệ thống tự nhiên độc lập, phát triển gắn liền với văn hóa, xã hội

và cộng đồng người sử dụng của từng quốc gia. Ngay cả trên cùng một quốc gia, sự khác biệt vùng miền cũng dẫn đến nhiều biến thể khác nhau [2]. Do đó, việc sử dụng ngôn ngữ ký hiệu chung cho tiếng Việt là không khả thi. Tại Việt Nam, các nhà ngôn ngữ học đã ghi nhận sự tồn tại của nhiều biến thể VSL theo đặc điểm văn hóa từng vùng miền [21]. Trong những năm gần đây, nghiên cứu về VSL đã có những bước tiến, chủ yếu tập trung vào bài toán nhận dạng ngôn ngữ ký hiệu, tức là chuyển đổi từ dữ liệu video hoặc chuỗi khung xương (skeleton) sang văn bản hoặc ký hiệu [43]. Ngoài ra, một hướng nghiên cứu khác tại Việt Nam là sử dụng avatar 3D để biểu diễn ngôn ngữ ký hiệu, giúp mô phỏng giao tiếp ký hiệu trực quan và tự động [31]. Nghiên cứu này xây dựng chuyển động khung xương 3D cho ký hiệu từ văn bản, kết nối các chuyển động để biểu đạt cho câu, và được đánh giá khả thi khi áp dụng cho VSL. Ngược lại, các nghiên cứu theo hướng dịch ngôn ngữ, đặc biệt là chuyển đổi từ tiếng Việt nói hoặc văn bản sang ký hiệu, vẫn còn hạn chế [24]. Nguyên nhân chủ yếu là sự thiếu hụt dữ liệu song ngữ chú thích đầy đủ, cũng như thách thức trong việc mô hình hóa ngữ pháp đặc thù và các thành phần phi thủ công của ngôn ngữ ký hiệu. Khoảng trống này nhấn mạnh nhu cầu cấp thiết về các hệ thống dịch VSL nhằm hỗ trợ giao tiếp và hòa nhập xã hội cho cộng đồng người khiếm thính tại Việt Nam.

2.3 Nhân Diện Giọng Nói Tiếng Việt

Các mô hình nhận diện giọng nói đã tiến hóa từ các hệ thống truyền thống sang các kiến trúc học sâu. Các phương pháp dựa trên Sequence to Sequence (Seq2Seq) và Connectionist Temporal Classification (CTC), điển hình là nghiên cứu Deep Speech 2 [3], đã cải thiện đáng kể hiệu suất ASR bằng cách xử lý trực tiếp chuỗi âm thanh. Tuy nhiên, khi áp dụng cho Tiếng Việt - một ngôn ngữ phân lập, có tính thanh điệu phức tạp và sự đa dạng giọng nói vùng miền cao - các mô hình ASR truyền thống này thường gặp thách thức lớn trong việc xử lý tính bất đồng nhất về ngữ âm và sự phức tạp trong phân đoạn từ (word segmentation) của ngôn ngữ này. Điều này làm gia tăng nguy cơ lỗi tích lũy từ đầu ra ASR, ảnh hưởng đến chất lượng toàn bộ hệ thống dịch máy. Để giải quyết những hạn chế này và nâng cao chất lượng cho đầu vào văn bản, lĩnh vực ASR đã chuyển sang các mô hình tiền huấn luyện tự giám sát. Sự ra đời của kiến trúc wav2vec 2.0 [4] đã cách mạng hóa ASR bằng cách học các biểu diễn âm thanh từ dữ liệu không được gán nhãn. Tiếp theo, mô hình Whisper [37] đã thiết lập chuẩn mực mới về khả năng xử lý đa ngôn ngữ và tính mạnh mẽ nhờ được huấn luyện trên khối lượng dữ liệu khổng lồ.

2.4 Dịch Máy Ngôn Ngữ Ký Hiệu

Dịch máy ngôn ngữ ký hiệu (Sign Language Translation – SLT) là một hướng nghiên cứu nhằm chuyển đổi thông tin giữa ngôn ngữ nói và ngôn ngữ ký hiệu, với mục tiêu hỗ trợ giao tiếp cho cộng đồng người khiếm thính. Trong hầu hết các hệ thống SLT hiện đại, bài toán dịch từ văn bản ngôn ngữ nói sang chuỗi gloss được xem là một bước trung gian quan trọng, đặc biệt trong các hệ thống sinh ngôn ngữ ký hiệu dựa trên avatar hoặc hoạt hình 3D. Chuỗi gloss đóng vai

trò là biểu diễn ký hiệu mang tính ký hiệu học, giúp tách biệt bài toán dịch ngôn ngữ với bài toán tổng hợp chuyển động ký hiệu [?].

Một khảo sát hệ thống toàn diện [?] đã phân tích hơn một trăm công trình nghiên cứu về dịch máy ngôn ngữ ký hiệu và cho thấy rằng các hướng tiếp cận có thể được quy về ba nhóm phương pháp chính, bao gồm các hệ thống dựa trên luật, các phương pháp dựa trên corpus và các mô hình dịch máy neural. Kết quả khảo sát chỉ ra rằng các hệ thống dịch máy dựa trên luật có thể hoạt động trong điều kiện dữ liệu cực kỳ hạn chế, song gặp nhiều khó khăn trong việc mở rộng quy mô, phụ thuộc mạnh vào tri thức chuyên gia và thiếu tính linh hoạt khi áp dụng cho các ngôn ngữ ký hiệu mới. Trong khi đó, các phương pháp dựa trên corpus, chẳng hạn như dịch máy thống kê hoặc dịch máy dựa trên ví dụ, cải thiện khả năng tổng quát hóa so với RBMT nhưng lại cho thấy hiệu suất phụ thuộc đáng kể vào kích thước cũng như chất lượng của tập dữ liệu song song văn bản sang gloss. Các mô hình dịch máy neural được xem là một bước tiến quan trọng tiếp theo. Tuy nhiên, khảo sát cũng nhấn mạnh rằng hiệu quả của chúng vẫn bị hạn chế trong bối cảnh nguồn lực thấp, đặc biệt khi dữ liệu huấn luyện không đủ lớn. Sự xuất hiện của các kiến trúc học sâu, đặc biệt là Cơ chế Attention và Transformer, không chỉ cải thiện bài toán text-to-gloss mà còn mở ra hướng đi mới cho việc sản sinh trực tiếp chuỗi tư thế ký hiệu. Hiệu suất của Transformer trong bài toán text-to-gloss có thể được cải thiện một cách nhất quán khi tích hợp các kỹ thuật thường dùng trong dịch máy nguồn lực thấp, bao gồm tăng cường dữ liệu, học bán giám sát, transfer learning và dịch máy đa ngôn ngữ. Kết quả thực nghiệm trên nhiều corpus gloss cho thấy thiết lập Transformer encoder-decoder kết hợp multilingual NMT và data augmentation đạt cải thiện đáng kể cả về chỉ số tự động lẫn đánh giá của người dùng, qua đó củng cố vai trò trung tâm của Transformer trong các hệ thống text-to-gloss hiện đại [53].

Một phát triển quan trọng trong những năm gần đây là việc áp dụng các mô hình tiền huấn luyện theo kiến trúc Transformer encoder-decoder cho bài toán text-to-gloss translation. Các mô hình như BART và mBART, được tiền huấn luyện với mục tiêu denoising sequence-to-sequence, đã cho thấy khả năng chuyển giao tri thức hiệu quả trong các bài toán dịch máy nguồn lực thấp [26,28]. Trên cơ sở đó, nhiều nghiên cứu gần đây đã thực nghiệm trực tiếp mBART cho tác vụ text-to-gloss, và nhất quán chỉ ra rằng mBART mang lại cải thiện đáng kể trong bối cảnh dữ liệu gloss hạn chế nhờ khả năng học chuyển giao từ tiền huấn luyện đa ngôn ngữ [13,1]. Song song với hướng tiếp cận đa ngôn ngữ, các mô hình tiền huấn luyện chuyên biệt theo ngôn ngữ cũng thu hút sự quan tâm, đặc biệt trong các kịch bản mà ngôn ngữ nguồn có đặc trưng hình thái-cú pháp riêng biệt. Điển hình là BARTpho cho tiếng Việt, được tiền huấn luyện đơn ngữ trên dữ liệu quy mô lớn, cho phép khai thác tốt hơn các đặc trưng ngôn ngữ học của ngôn ngữ nguồn và qua đó cải thiện chất lượng dịch khi fine-tune trên các tập dữ liệu hạn chế [44]. Tuy nhiên, mức độ hiệu quả của các mô hình đơn ngữ này trong bài toán text-to-gloss—vốn có sự lệch đáng kể về cú pháp giữa văn bản nói và gloss vẫn cần được đánh giá thực nghiệm và so sánh trực tiếp với các mô hình đa ngôn ngữ như mBART.

Bên cạnh việc khai thác các mô hình tiền huấn luyện, một dòng công trình gần đây cho thấy rằng việc tích hợp thông tin ngữ pháp và các đặc trưng ngôn ngữ học tường minh, chẳng hạn như phân tích cú pháp, nhân từ loại hoặc các khuôn mẫu cú pháp, khi kết hợp với học chuyển giao và tăng cường dữ liệu, có thể mang lại cải thiện ổn định và đáng kể cho bài toán text-to-gloss translation trong điều kiện dữ liệu hạn chế [13,53,14].

Đối với ngôn ngữ ký hiệu Việt Nam, dữ liệu song song văn bản sang gloss hiện vẫn còn rất hạn chế và các nghiên cứu ứng dụng mô hình tiền huấn luyện mới chỉ ở giai đoạn đầu. Tuy nhiên, các bằng chứng bước đầu cho thấy rằng việc kết hợp các mô hình tiền huấn luyện chuyên biệt cho tiếng Việt, các kỹ thuật tăng cường dữ liệu như back-translation hoặc sinh gloss tổng hợp, cùng với pipeline dịch máy có tầng gloss trung gian là một hướng tiếp cận đầy triển vọng. Kiến trúc Transformer encoder-decoder được tiền huấn luyện và tích hợp trong pipeline text-to-gloss trung gian hiện là giải pháp cân bằng hiệu quả nhất giữa chất lượng dịch, khả năng mở rộng và mức độ kiểm soát cho bài toán dịch máy ngôn ngữ ký hiệu.

2.5 Tăng Cường Dữ Liệu Dịch Máy với Ngôn Ngữ Ít Tài Nguyên

Dịch máy ngôn ngữ ký hiệu đối với các ngôn ngữ ít tài nguyên như Ngôn ngữ Ký hiệu Việt Nam (VSL) đối mặt với thách thức nghiêm trọng do sự khan hiếm các cặp dữ liệu song song chất lượng cao. Khác với dịch máy giữa các ngôn ngữ nói, nơi tồn tại nhiều kho dữ liệu lớn và được chuẩn hóa, dữ liệu phục vụ cho dịch máy ngôn ngữ ký hiệu thường có quy mô nhỏ, thiếu tính đồng nhất và phụ thuộc mạnh vào bối cảnh thu thập. Nguyên nhân chủ yếu xuất phát từ chi phí cao của quá trình xây dựng dữ liệu, đặc biệt là yêu cầu chú giải và thẩm định ngữ pháp trực tiếp bởi các chuyên gia ngôn ngữ ký hiệu, khiến việc mở rộng quy mô dữ liệu trở nên khó khăn hơn nhiều so với dữ liệu văn bản thuần túy [12,49,53,10].

Sự thiếu hụt dữ liệu khiến bài toán tăng cường dữ liệu trong dịch máy ngôn ngữ ký hiệu trở nên phức tạp hơn đáng kể so với các bài toán xử lý ngôn ngữ tự nhiên truyền thống. Trong khi các kỹ thuật tăng cường dữ liệu cho văn bản, chẳng hạn như xáo trộn hoặc chèn từ, có thể được áp dụng tương đối an toàn, thì các phép biến đổi tương tự khó có thể áp dụng trực tiếp cho dữ liệu ngôn ngữ ký hiệu mà không làm sai lệch cấu trúc ngữ pháp hoặc ý nghĩa biểu đạt. Bên cạnh đó, ngôn ngữ ký hiệu mang tính đa phương thức và chứa nhiều thông tin phi tuyến trong không gian, khiến các chiến lược tăng cường dữ liệu tiêu chuẩn khó đảm bảo tính hợp lệ về mặt ngôn ngữ [12]. Ngoài ra, sự khác biệt căn bản về cấu trúc ngôn ngữ, bao gồm trật tự cú pháp, cách biểu đạt thông tin không gian và tính đồng thời của các thành phần ngôn ngữ, khiến việc ánh xạ trực tiếp từ câu văn bản sang biểu diễn ngôn ngữ ký hiệu, ngay cả dưới dạng gloss có cấu trúc, trở nên khó khăn hơn so với dịch giữa các ngôn ngữ nói có cấu trúc tuyến tính tương đồng [21].

Nhằm giảm thiểu tác động của sự thiếu hụt dữ liệu, nhiều nghiên cứu đã đề xuất các chiến lược tăng cường dữ liệu cho bối cảnh ngôn ngữ ít tài nguyên.

Back-translation là một hướng tiếp cận phổ biến trong dịch máy ngôn ngữ nói ít tài nguyên; tuy nhiên, các nghiên cứu cho thấy phương pháp này có hiệu quả hạn chế khi áp dụng cho dịch máy ngôn ngữ ký hiệu, do sự khác biệt cú pháp lớn giữa ngôn ngữ nói và gloss, cũng như yêu cầu một lượng dữ liệu song song tối thiểu để huấn luyện mô hình dịch ngược đủ tin cậy [10]. Nhận định này cũng phù hợp với các kết luận trong lĩnh vực dịch máy thống kê cho ngôn ngữ ít tài nguyên, nơi back-translation chỉ phát huy hiệu quả khi tồn tại dữ liệu nền đủ lớn.

Trong các kịch bản dữ liệu cực kỳ hạn chế, các phương pháp tăng cường dữ liệu dựa trên luật (rule-based augmentation) được xem là phù hợp hơn [10]. Các phương pháp này khai thác tri thức ngôn ngữ học về sự khác biệt có hệ thống giữa ngôn ngữ nói và ngôn ngữ ký hiệu, chẳng hạn như lược bỏ từ chức năng, chuẩn hóa hình thái hoặc điều chỉnh trật tự cú pháp theo đặc trưng của gloss. Moryossef và cộng sự cho thấy rằng việc sinh pseudo gloss dựa trên các luật ngôn ngữ tổng quát và đặc thù cho từng ngôn ngữ cho phép tiền huấn luyện mô hình hiệu quả ngay cả khi không có dữ liệu song song chất lượng cao, đồng thời cung cấp các ràng buộc cú pháp quan trọng cho mô hình trong giai đoạn huấn luyện [29].

Gần đây, sự phát triển của các mô hình LLMs đã mở ra những hướng tiếp cận mới cho bài toán tăng cường dữ liệu trong các ngôn ngữ ít tài nguyên. Trong lĩnh vực dịch máy cho ngôn ngữ nói ít tài nguyên, các nghiên cứu trên Bangla cho thấy việc kết hợp LLMs với back-translation và cơ chế Retrieval-Augmented Generation (RAG) cho phép khai thác hiệu quả các nguồn tri thức và dữ liệu hiện có, từ đó cải thiện chất lượng dữ liệu tổng hợp trong điều kiện dữ liệu hạn chế [?].

Song song với đó, trong bối cảnh dịch máy ngôn ngữ ký hiệu, Fang và cộng sự đề xuất khai thác LLMs thông qua prompting có hướng dẫn để sinh pseudo gloss từ dữ liệu văn bản. Cách tiếp cận này tận dụng kiến thức ngôn ngữ được tích hợp sẵn trong LLMs nhằm tạo ra dữ liệu tổng hợp có cấu trúc phù hợp hơn với ngữ pháp ngôn ngữ ký hiệu, ngay cả khi không sử dụng cơ chế truy hồi tri thức động như RAG [16].

Tổng hợp các nghiên cứu liên quan cho thấy rằng, đối với dịch máy ngôn ngữ ký hiệu cho các ngôn ngữ ít tài nguyên như VSL, tăng cường dữ liệu hiệu quả đòi hỏi sự kết hợp của nhiều chiến lược. Trong đó, pseudo gloss đóng vai trò quan trọng trong việc thu hẹp khoảng cách cú pháp giữa ngôn ngữ nói và ngôn ngữ ký hiệu, trong khi các phương pháp dựa trên luật và các kỹ thuật khai thác LLMs thông qua prompting hoặc truy hồi tri thức cung cấp các tín hiệu ngôn ngữ bổ sung, góp phần cải thiện khả năng tổng quát hóa của mô hình trong điều kiện dữ liệu hạn chế.

2.6 Đánh giá dữ liệu làm giàu

Trong những năm gần đây, các Mô hình Ngôn ngữ Lớn (Large Language Models – LLM) không chỉ được sử dụng cho mục tiêu sinh nội dung mà còn được khai thác như một công cụ đánh giá tự động, thường được gọi là LLM-as-a-Judge. Cách tiếp cận này cho phép LLM đánh giá đầu ra của hệ thống dựa trên các

tiêu chí được xác định trước, từ đó cung cấp một giải pháp thay thế có khả năng mở rộng cho các thước đo tự động truyền thống và giảm bớt chi phí đánh giá thủ công [?,?]. Ưu điểm chính của LLM-as-a-Judge nằm ở khả năng nắm bắt ngữ nghĩa và tính linh hoạt trong đánh giá. So với các chỉ số dựa trên bề mặt, phương pháp này có thể phản ánh tốt hơn mức độ bảo toàn ý nghĩa, tính trôi chảy và sự phù hợp theo ngữ cảnh nhiệm vụ. Nhiều nghiên cứu gần đây cho thấy, khi được thiết kế giao thức đánh giá phù hợp, kết quả đánh giá của LLM có tương quan cao với đánh giá của con người [?]. Tuy nhiên, LLM-as-a-Judge cũng tồn tại những hạn chế nhất định. Kết quả đánh giá có thể bị ảnh hưởng bởi thiết kế prompt, thiên lệch mô hình và kiến thức ngầm học được trong quá trình huấn luyện [?]. Đặc biệt, đối với các bài toán liên quan đến biểu diễn ngôn ngữ mang tính chuyên biệt cao - chẳng hạn như gloss trong ngôn ngữ ký hiệu, vốn tuân theo các quy ước ngôn ngữ học chặt chẽ — LLM có thể chưa nắm bắt đầy đủ các ràng buộc mang tính chuyên gia. Do đó, vai trò của chuyên gia lĩnh vực vẫn giữ vị trí then chốt trong việc xác định tiêu chí đánh giá và đảm bảo tính hợp lệ của kết quả [?]. Trong nghiên cứu này, LLM-as-a-Judge được sử dụng như một cơ chế đánh giá hỗ trợ, thay vì thay thế hoàn toàn đánh giá của chuyên gia [?]. Cách tiếp cận này tận dụng được khả năng mở rộng và tính nhất quán của LLM, đồng thời duy trì độ tin cậy ngôn ngữ thông qua các hướng dẫn và tiêu chí được xây dựng dựa trên kiến thức chuyên môn.

Theo các nghiên cứu đánh giá synthetic data gần đây [?,?,?], chất lượng dữ liệu tổng hợp thường được xem xét theo ba trụ cột: fidelity (mức độ bám sát phân bố thống kê của dữ liệu thật), utility (khả năng cải thiện hiệu năng trên tác vụ downstream), và privacy (giảm thiểu rủi ro rò rỉ thông tin nhạy cảm). Bộ ba tiêu chí này được đề xuất chủ yếu trong bối cảnh synthetic data được sử dụng cho các tập dữ liệu bảng và dữ liệu nhạy cảm (ví dụ dữ liệu y tế, tài chính), nơi synthetic data có thể được chia sẻ cho nhiều mục đích phân tích và huấn luyện khác nhau, và nơi rủi ro rò rỉ thông tin cá nhân là mối quan tâm trung tâm. Mục tiêu làm giàu dữ liệu ở bài nghiên cứu của chúng tôi là mở rộng tập huấn luyện để cải thiện model performance, utility được xem là tiêu chí quyết định. Fidelity cần thiết khi với mục tiêu để chia sẻ dữ liệu cho cộng đồng sử dụng cho các ứng dụng chưa biết [?], hay trong lĩnh vực y tế cần kiểm tra rò rỉ dữ liệu nhạy cảm liên quan trong lĩnh vực [?][?] và đặc biệt hơn là khi synthetic data thay thế hoàn toàn real data trong huấn luyện hoặc khi không có real test set để đánh giá utility trực tiếp.

2.7 Sinh Gloss Giả bằng Mô hình Ngôn ngữ Lớn (LLMs):

Trong bối cảnh nguồn lực thấp, các mô hình NMT truyền thống thường khó mô hình hóa đầy đủ sự phức tạp ngữ nghĩa của ngôn ngữ ký hiệu. Ngược lại, các mô hình ngôn ngữ lớn với khả năng suy luận ngữ nghĩa và ngữ pháp vượt trội có thể sinh ra các chuỗi gloss giả tự nhiên và nhất quán ngữ cảnh hơn. Nghiên cứu trên ngôn ngữ Bangla cho thấy việc sử dụng mô hình tiền huấn luyện đa ngôn ngữ mBART để sinh gloss tổng hợp mang lại hiệu quả rõ rệt cho nhiệm vụ text2gloss trong điều kiện thiếu dữ liệu song ngữ [1]. Gần đây, các LLM thậm chí cho chất lượng sinh gloss vượt trội so với các mô hình chuyên biệt truyền

thông qua prompt engineering, đặc biệt trong việc xử lý các biến thể từ vựng và cú pháp phức tạp [?].

Bên cạnh đó, SignLLM [16] đề xuất một framework đa ngôn ngữ kết hợp học tăng cường để tự động sinh chuỗi gloss và pose skeleton cho các ngôn ngữ ký hiệu khác nhau. Kết quả thực nghiệm cho thấy framework này đạt hiệu suất cao hơn các phương pháp hiện có trên nhiều benchmark đánh giá. Mặc dù các phương pháp dựa trên gloss đã chứng minh hiệu quả trong điều kiện dữ liệu hạn chế, một số nghiên cứu gần đây cũng khám phá hướng tiếp cận dịch không cần gloss cho dịch máy ngôn ngữ ký hiệu. [18] chứng minh rằng các LLM có thể được fine-tune để chuyển đổi trực tiếp từ video ngôn ngữ ký hiệu sang văn bản mà không cần biểu diễn gloss trung gian, đạt kết quả cao trên Phoenix-2014T và CSL-Daily datasets. Tuy nhiên, các phương pháp dựa trên gloss vẫn chiếm ưu thế trong các ngôn ngữ ký hiệu ít tài nguyên như VSL do khả năng kiểm soát và giải thích tốt hơn trong quá trình sinh ngôn ngữ ký hiệu [41].

2.8 Trực Quan Hóa Bằng Avatar 3D

Một số công trình tiên phong đã tiến hành số hóa và trực quan hóa ngôn ngữ ký hiệu tiếng Việt bằng avatar 3D, điển hình là nghiên cứu của Ngõn et al. [32], trong đó hơn 2558 từ diễn tả NNKH đã được xây dựng. Mặc dù các nghiên cứu này đã đạt được những kết quả quan trọng trong việc mô tả hình thái thủ công của ký hiệu (ví dụ: hình dạng bàn tay, hướng và chuyển động), các yếu tố phi thủ công, đặc biệt là biểu cảm khuôn mặt và hình thái cảm xúc, vẫn chưa được mô hình hóa một cách đầy đủ và có hệ thống. Trong khi đó, các đặc trưng phi thủ công đóng vai trò then chốt trong việc biểu đạt ngữ nghĩa, thái độ và cấu trúc cú pháp của ký hiệu [48].

Do đó, trong nghiên cứu này, nhóm chúng tôi tập trung xây dựng một bộ từ điển ký hiệu chỉ dành cho hệ thống ngôn ngữ ký hiệu miền Nam Việt Nam, đồng thời biểu diễn bao gồm các hình thái cảm xúc và cử chỉ khuôn mặt trong quá trình sinh SiGML và trực quan hóa bằng avatar 3D.

3 System Overview

Trong phần này, chúng tôi giới thiệu kiến trúc tổng thể của hệ thống hỗ trợ giao tiếp tiếng Việt - (VSL), cũng như các quyết định thiết kế chính cho mô-đun dịch văn bản tiếng Việt sang gloss VSL trong bối cảnh dữ liệu cực kỳ ít tài nguyên.

Tương tự các hệ thống dịch nói sang ký hiệu kinh điển cho Spanish–LSE và German–DGS, chúng tôi áp dụng kiến trúc *modular* với các tầng biểu diễn trung gian, thay vì một mô hình end-to-end duy nhất [7,53].

Pipeline tổng thể gồm ba khối:

1. **ASR tiếng Việt (Voice-to-Text):** giọng nói tiếng Việt được chuyển thành văn bản thông qua một mô hình nhận diện giọng nói tiền huấn luyện tự giám sát như wav2vec 2.0 hoặc Whisper [4,37]. Đầu ra được chuẩn hoá (chính tả, dấu câu, chữ số) trước khi đưa vào T2G.




Fig. 1: System overview of Vietnamese speech-to-VSL translation with 3D avatar rendering.

2. **Text-to-Gloss tiếng Việt-VSL:** văn bản tiếng Việt được dịch sang chuỗi gloss VSL. Đây là khối mà bài báo tập trung đóng góp, dựa trên kiến trúc encoder-decoder kiểu Transformer [46] với các biến thể tiền huấn luyện đơn ngữ/đa ngữ.
3. **Gloss-to-Avatar:** gloss VSL được ánh xạ sang các dãy HamNoSys rồi sang SiGML [20,15], và cuối cùng được trực quan hoá bằng avatar 3D. Từ điển Vie-SiGML được xây dựng từ nguồn QIPEDC với trọng tâm là hệ thống ký hiệu miền Nam.

Các nghiên cứu gần đây về SLT cho thấy pipeline có tầng gloss trung gian vẫn thường đạt chất lượng cao và dễ kiểm soát hơn so với các hệ thống text $\leftrightarrow$ video end-to-end, đặc biệt trong điều kiện dữ liệu hạn chế [50,51,53,13]. Hệ thống được xây dựng theo kiến trúc modular, trong đó tầng Text-to-Gloss là trọng tâm nghiên cứu, còn hai tầng ASR và Avatar 3D cung cấp ngữ cảnh ứng dụng và ràng buộc thực tế.

4 Methodology

4.1 Voice-to-Text

Trong quy trình chuyển đổi giọng nói sang Ngôn ngữ Ký hiệu Việt Nam, mô-đun Chuyển giọng nói thành Văn bản (Automatic Speech Recognition - ASR) có nhiệm vụ chuyển đổi giọng nói tiếng Việt thành văn bản, làm đầu vào cho bước chuyển đổi sang VSL. Do văn bản đóng vai trò là dữ liệu nguồn của mô-đun dịch, các lỗi nhận dạng ở bước ASR thường lan truyền sang các giai đoạn sau và làm suy giảm chất lượng đầu ra của toàn bộ hệ thống. Bên cạnh độ chính xác từ vựng, chúng tôi cũng quan tâm đến cấu trúc bề mặt của văn bản đầu

Table 1: Kết quả WER (%) của PhoWhisper so với các mô hình ASR tiếng Việt trên các benchmark

Model	#Params	CMV-Vi	VIVOS	VLSP-1	VLSP-2
wav2vec2-base-vietnamese-250h	95M	102.04	10.83	21.02	50.35
wav2vec2-base-vi-vlsp2020	95M	103.71	9.90	16.82	44.91
wav2vec2-large-vi-vlsp2020	317M	101.41	8.61	15.18	36.75
PhoWhisper-tiny	39M	19.05	10.41	20.74	49.85
PhoWhisper-base	74M	16.19	8.46	19.70	43.01
PhoWhisper-small	244M	11.08	6.33	15.93	32.96
PhoWhisper-medium	769M	8.27	4.97	14.12	26.85
PhoWhisper-large	1.55B	8.14	4.67	13.75	26.68

ra từ ASR. Các hệ thống ASR thường không khôi phục đầy đủ dấu câu, khiến phát ngôn dễ bị gộp thành một chuỗi dài và khó tách ý. Khi ranh giới câu và cụm nghĩa không rõ ràng, mô-đun dịch sang VSL có xu hướng hoạt động kém ổn định, đặc biệt trong các kịch bản ghi âm trực tiếp với tiếng ồn nền và độ dài phát ngôn thay đổi. Do đó, mục tiêu của mô-đun ASR trong nghiên cứu này là tạo ra transcript vừa đủ chính xác về nội dung, vừa đủ rõ ràng về cấu trúc để hỗ trợ hiệu quả cho bước chuyển đổi sang VSL.

4.1.1 Lựa chọn mô hình ASR

Chúng tôi lựa chọn PhoWhisper [25] làm mô hình ASR cho hệ thống vì đây là biến thể của Whisper được fine-tune chuyên biệt cho tiếng Việt. Theo bài báo gốc, PhoWhisper được huấn luyện trên khoảng 844 giờ dữ liệu, tổng hợp từ nhiều nguồn khác nhau bao gồm CMV-Vi (Common Voice tiếng Việt), VIVOS, các bộ dữ liệu thuộc VLSP và dữ liệu riêng nhằm tăng độ đa dạng người nói. Ngoài ra, một phần dữ liệu huấn luyện được tăng cường bằng cách bổ sung nhiễu môi trường thông qua audiomentations, và mô hình được fine-tune trong 48.000 bước.

Những đặc điểm này phù hợp với bối cảnh triển khai của chúng tôi, nơi âm thanh được thu trực tiếp từ người dùng và chất lượng thu âm có thể phụ thuộc vào thiết bị cũng như mức độ tiếng ồn nền. Để đặt PhoWhisper trong tương quan với các mô hình ASR tiếng Việt trước đó, Bảng 1 trích từ [25] tổng hợp Word Error Rate (WER) trên các benchmark chuẩn. Kết quả cho thấy các phiên bản PhoWhisper, đặc biệt từ cấu hình *small* trở lên, vượt trội so với các baseline wav2vec2 trên hầu hết các bộ đánh giá.

4.1.2 Đánh giá mô hình ASR

PhoWhisper cung cấp nhiều cấu hình kích thước mô hình khác nhau [25], do đó cần có sự cân bằng giữa độ chính xác và độ trễ trong thiết lập “nhấn ghi âm rồi nhận văn bản”. Chúng tôi tiến hành so sánh trực tiếp hai cấu hình PhoWhisper-medium (769M tham số) và PhoWhisper-large (1.55B tham số) trong cùng điều kiện suy luận để lựa chọn cấu hình phù hợp.

Thí nghiệm được thực hiện trên tập kiểm tra gồm 1.000 mẫu của bộ dữ liệu công khai ademax/vlsp-vie-speech2text. Audio đầu vào được chuẩn hóa về mono và resample về 16 kHz trước khi đưa vào mô hình. Cả hai cấu hình đều sử dụng greedy decoding với beam size bằng 1. Trước khi tính WER, transcript dự đoán và ground truth được chuẩn hóa theo cùng một quy tắc gồm Unicode NFC, chuyển chữ thường, loại bỏ dấu câu (thay bằng khoảng trắng) và chuẩn hóa khoảng trắng.

Chúng tôi báo cáo micro-average WER làm chỉ số đánh giá chính và đo Real-Time Factor (RTF) để phản ánh tốc độ suy luận, trong đó RTF được tính bằng tổng thời gian xử lý chia cho tổng thời lượng audio trong cùng môi trường chạy. Kết quả so sánh được trình bày trong Bảng 2.

Table 2: So sánh PhoWhisper-medium và PhoWhisper-large trên tập test 1.000 mẫu

Mô hình	Micro WER (%)	RTF
PhoWhisper-medium	3.19	2.81
PhoWhisper-large	3.92	1.53

Kết quả cho thấy PhoWhisper-medium đạt Micro WER thấp hơn PhoWhisper-large trên tập kiểm tra này, trong khi PhoWhisper-large có RTF thấp hơn trong điều kiện đo. Trong pipeline VSL, sai lệch nội dung ở văn bản đầu ra thường ảnh hưởng trực tiếp đến các bước sau, do đó chúng tôi ưu tiên lựa chọn PhoWhisper-medium làm cấu hình mặc định nhằm giảm lỗi nội dung. PhoWhisper-large được giữ như cấu hình đối chứng hoặc sử dụng trong các kịch bản ưu tiên độ trễ tùy theo môi trường triển khai.

4.2 Data Augmentation

Ngôn ngữ ký hiệu là ngôn ngữ nằm trong nguồn dữ liệu có tài nguyên rất ít ở rất nhiều quốc gia không chỉ riêng ở Việt Nam. Nhiều nghiên cứu đã đề xuất các phương pháp làm giàu dữ liệu cho ngôn ngữ ít tài nguyên này [1][39][29]. Các nghiên cứu gần đây cho thấy những phương pháp làm giàu dữ liệu hiện đại dựa trên mô hình học sâu và sinh dữ liệu tự động, vượt trội hơn so với các phương pháp truyền thống nhờ khả năng tạo ra tập huấn luyện có độ bao phủ và tính khái quát cao. Đặc biệt, công trình [29] đã chỉ ra rằng việc sinh nhiều biến thể câu, dù mỗi câu làm giàu có chất lượng thấp, đã giúp tăng độ đa dạng cấu trúc của dữ liệu huấn luyện và cải thiện mô hình. Bên cạnh đó, các phương pháp hiện đại tận dụng sức mạnh của mô hình ngôn ngữ lớn cũng đã được chứng minh là hiệu quả trong làm giàu dữ liệu. Công trình [39] đề xuất kết hợp Retrieval-Augmented Generation (RAG) với few-shot prompting trên các mô hình ngôn ngữ lớn nhằm mở rộng tập dữ liệu huấn luyện, đồng thời duy trì tính liên quan ngữ cảnh và cấu trúc của dữ liệu sinh ra. Trong triển khai cụ thể của bài, chúng tôi tiến hành làm giàu lên 30,000 dữ liệu theo tỷ lệ 1:3 với hai hướng chính, kết

hợp khả năng sinh dữ liệu linh hoạt của mô hình ngôn ngữ lớn với cơ chế truy hồi ví dụ ngữ cảnh nhằm kiểm soát chất lượng và độ đa dạng của dữ liệu sinh.

Data Augmentation with fewshot prompting: Chúng tôi áp dụng phương pháp làm giàu dữ liệu trên mô hình ngôn ngữ lớn GPT-4o thông qua cơ chế học theo ngữ cảnh. Một số cặp câu mẫu được đưa vào prompt nhằm giúp mô hình học được các mẫu cấu trúc biến đổi câu từ văn bản tiếng Việt sang VSL. Cách tiếp cận này cho phép mô hình tổng quát hóa tốt hơn trong những trường hợp mà tập luật chuyển đổi thủ công không thể bao phủ đầy đủ các dạng câu Tiếng Việt đa dạng.

Retrieval-Augmented Generation (RAG) : Để lựa chọn các ví dụ phù hợp cho quá trình fewshot prompting, chúng tôi sử dụng phương pháp RAG nhằm truy vấn các câu có mức độ tương đồng cao với câu đầu vào. Mặc dù RAG chủ yếu dựa trên độ tương đồng ngữ nghĩa, cách tiếp cận này vẫn phù hợp với bài toán chuyển đổi cấu trúc câu từ tiếng Việt sang ngôn ngữ ký hiệu, do các quy tắc chuyển đổi trong ngôn ngữ ký hiệu phần lớn phụ thuộc vào cấu trúc cú pháp và ngữ nghĩa của câu. Các nguyên tắc chuyển đổi như loại bỏ hư từ (“là”, “thì”), xác định vị trí của từ để hỏi (“đâu”, “mấy”), vị trí của số lượng, trạng ngữ chỉ thời gian và chỉ thì, cũng như cách xử lý giới từ, đều có mối liên hệ chặt chẽ với cấu trúc ngữ nghĩa tổng thể của câu. Từ đó, việc truy vấn các câu tương đồng về ngữ nghĩa giúp đảm bảo rằng các ví dụ được đưa vào prompt có giá trị định hướng hiệu quả cho mô hình trong quá trình sinh gloss.

Các quy tắc trong Bảng 3, được xây dựng dựa trên [?], được tích hợp vào prompt như các ràng buộc ngôn ngữ học nhằm định hướng quá trình sinh gloss theo cấu trúc cú pháp của Ngôn ngữ Ký hiệu Việt Nam.

4.2.1 Các chiến lược tạo prompts Chúng tôi thiết kế và so sánh ba chiến lược prompting khác nhau thông qua thí nghiệm kiểm định nhằm lựa chọn cấu hình phù hợp nhất cho bài toán sinh dữ liệu trong bối cảnh ít tài nguyên.

Chiến lược 1 - Rule-based Prompting: chiến lược sử dụng tập các quy tắc biến đổi do chuyên gia biên soạn kèm theo các ví dụ cố định tương ứng. Cách tiếp cận này đảm bảo tính diễn giải và ổn định của đầu ra, nhưng bị giới hạn khi các luật không bao phủ đầy đủ các biến thể câu trong thực tế.

Chiến lược 1: Rule-based Prompting

[System Instruction]

Chuyển đổi Ngôn ngữ Ký hiệu Việt Nam (VSL).

Vai trò: Bạn là chuyên gia chuyển đổi ngôn ngữ tự nhiên sang cấu trúc VSL Gloss. Hãy chuyển đổi câu theo đúng các quy tắc và các ví dụ của từng quy tắc sau:

Quy tắc ngữ pháp cốt lõi: *{rules_and_examples}*

[User Input]

Hãy chuyển câu sau sang cấu trúc VSL: *{input_sentence}*




Fig. 2: Data augmentation pipeline

Chiến lược 2: RAG with Fallback Prompting (Examples)

[User Input]

Chuyển đổi Ngôn ngữ Ký hiệu Việt Nam (VSL). Vai trò: Bạn là chuyên gia chuyển đổi ngôn ngữ tự nhiên sang cấu trúc VSL Gloss. Hãy chuyển đổi câu Tiếng Việt sang cấu trúc Ngôn ngữ ký hiệu dựa vào các ví dụ tham chiếu biến đổi cấu trúc câu dưới đây:

Vie: $\{retrieved_sources\} \rightarrow$ VSL: $\{retrieved_targets\}$

...

Hãy chuyển câu sau sang cấu trúc VSL: $\{input_sentence\}$.

Chỉ trả về câu cấu trúc VSL, không thêm gì khác.

Chiến lược 2: RAG with Fallback Prompting (Rules)

[System Instruction]

Chuyển đổi Ngôn ngữ Ký hiệu Việt Nam (VSL). Vai trò: Bạn là chuyên gia chuyển đổi ngôn ngữ tự nhiên sang cấu trúc VSL Gloss. Hãy chuyển đổi câu theo đúng các quy tắc dưới đây:

$\{rules\}$

[User Input]

Hãy chuyển câu sau sang cấu trúc VSL: $\{input_sentence\}$.

Chỉ trả về câu cấu trúc VSL, không thêm gì khác.

Chiến lược 3 - Rule-guided RAG Prompting: chiến lược kết hợp mô tả luật và các ví dụ được lựa chọn bởi RAG trong cùng một prompt. Mặc dù thiết kế này nhằm đồng thời khai thác tri thức luật và ví dụ ngữ cảnh, thực nghiệm cho thấy việc trộn hai nguồn thông tin trong cùng một prompt dễ gây nhiễu và làm suy giảm chất lượng đầu ra.

Chiến lược 3: Rule-guided RAG Prompting

[System Instruction]

Bạn là chuyên gia VSL. Hãy tuân thủ các quy tắc sau và tham khảo các ví dụ ngữ cảnh:
 $\{rules\}$

[User Input]

Dưới đây là ví dụ tham chiếu:

Vie: $\{retrieved_sources\} \rightarrow$ VSL: $\{retrieved_targets\}$

...

Hãy chuyển câu sau sang cấu trúc VSL: $\{input_sentence\}$

Chỉ trả về câu cấu trúc VSL, không thêm gì khác

4.2.2 Kiểm định dữ liệu làm giàu

Chúng tôi đánh giá chất lượng dữ liệu tổng hợp được sinh bằng Chiến lược 2 ở Mục 4.2 theo hướng *utility-driven evaluation*, tập trung vào mức độ mà dữ liệu tổng hợp hỗ trợ cải thiện hiệu năng mô hình trên dữ liệu thực trong tác vụ Text-to-Gloss. Cách tiếp cận này phù hợp với mục tiêu data augmentation của nghiên cứu, trong đó dữ liệu tổng hợp được sử dụng để mở rộng tập huấn luyện nhằm cải thiện hiệu năng downstream, thay vì thay thế hoàn toàn dữ liệu thật hoặc phục vụ mục tiêu chia sẻ dữ liệu. Chúng tôi áp dụng giao thức đánh giá dựa trên ba cấu hình huấn luyện, trong đó mỗi cấu hình trả lời một mục tiêu kiểm định khác nhau liên quan đến vai trò của dữ liệu tổng hợp trong pipeline downstream: **TRTR** (train on real, test on real) làm baseline và **TSTR** (train on synthetic, test on real) để kiểm định utility nội tại của dữ liệu tổng hợp.

Cấu hình TSTR trong nghiên cứu này không nhằm kiểm tra khả năng thay thế dữ liệu thật của dữ liệu tổng hợp trong kịch bản triển khai thực tế. Thay vào đó, TSTR được sử dụng như một phép kiểm định có kiểm soát để đánh giá tính hữu dụng của dữ liệu làm giàu, tức là xác định xem dữ liệu tổng hợp có tự thân chứa đủ tín hiệu huấn luyện liên quan đến tác vụ để mô hình có thể tổng quát hoá từ dữ liệu tổng hợp sang dữ liệu thực hay không và khiến nó trở thành một dữ liệu hữu ích cho việc huấn luyện[?, ?, ?]. Nếu mô hình huấn luyện hoàn toàn trên dữ liệu tổng hợp đạt hiệu năng tiệm cận hoặc vượt baseline huấn luyện trên dữ liệu thật, điều này cung cấp bằng chứng mạnh rằng dữ liệu tổng hợp đã học được các ánh xạ và cấu trúc cú pháp-ngữ nghĩa có giá trị cho tác vụ Text-to-Gloss, và do đó là nguồn dữ liệu làm giàu hợp lệ cho downstream learning. Với thực nghiệm trên TSTR vs TRTR cho phép chúng tôi trả lời câu hỏi :

Dữ liệu tổng hợp được sinh bằng phương pháp RAG-enhanced LLM prompting có đủ chất lượng (utility) để mô hình huấn luyện trên dữ liệu tổng hợp có thể tổng quát hóa tốt sang dữ liệu thực trong tác vụ Text-to-Gloss hay không?

Nếu TSTR performance tiệm cận hoặc vượt TRTR performance, điều này chứng tỏ dữ liệu tổng hợp đã capture được các pattern cấu trúc và ngữ nghĩa quan trọng của dữ liệu thực, và do đó có utility cao cho tác vụ dịch VSL. Thiết lập TSTR được sử dụng như một công cụ chẩn đoán nhằm đánh giá mức độ tin hiệu huấn luyện mà dữ liệu tổng hợp có thể cung cấp cho tác vụ Text-to-Gloss, thay vì được xem như bằng chứng cho thấy dữ liệu tổng hợp có thể thay thế hoàn toàn dữ liệu chú giải VSL thực.

4.3 Text-to-Gloss

4.4 Text-to-Gloss

4.4.1 Model selection Mục tiêu của khối Text-to-Gloss là đánh giá có hệ thống ảnh hưởng của tiền huấn luyện, transfer đa ngôn ngữ, và dữ liệu làm giàu trong bối cảnh Vie-VSL cực ít tài nguyên. Do đó, chúng tôi lựa chọn một họ backbone encoder-decoder đại diện, gồm Transformer huấn luyện từ đầu và các mô hình tiền huấn luyện (đơn ngữ và đa ngữ), để đo lường lợi ích của từng lựa chọn theo cùng giao thức.

(i) *Transformer baseline huấn luyện từ đầu.* Mô hình chuẩn được sử dụng làm baseline là một Transformer encoder-decoder kích thước nhỏ, huấn luyện từ đầu trên tập Vie-VSL. Cấu hình (số lớp, số head, kích thước ẩn) được chọn theo thông lệ cho NMT ít tài nguyên. Mô hình này đóng vai trò mốc để đánh giá lợi ích của pretraining, multilinguality và làm giàu dữ liệu.

(ii) *Encoder-decoder tiền huấn luyện đơn ngữ (BARTPho).* Để khai thác thông tin ngôn ngữ tiếng Việt ở mức độ sâu hơn, chúng tôi lựa chọn một mô hình BARTPho pretrain trên corpus tiếng Việt quy mô lớn, sau đó fine-tune cho bài toán T2G. Điều này tương tự hướng tiếp cận dùng BART/mBART cho NMT ít tài nguyên: encoder đã học được phân bố cú pháp-ngữ nghĩa của tiếng Việt, còn decoder được điều chỉnh để sinh ra chuỗi gloss VSL [26,28]. Chúng tôi kỳ vọng BARTPho sẽ xử lý tốt hơn các cấu trúc câu phức, đảo ngữ, chủ ngữ - vị ngữ trong tiếng Việt, từ đó cải thiện chất lượng biểu diễn nguồn cho T2G.

(iii) *Encoder-decoder tiền huấn luyện đa ngữ (mBART).* Tiếp theo, chúng tôi xem xét khả năng tận dụng pretraining đa ngữ. Các mô hình encoder-decoder đa ngữ như mBART đã chứng minh hiệu quả trong dịch ít tài nguyên nhờ khả năng khởi tạo một không gian biểu diễn chung và các lớp Transformer đã học những mẫu chuyển đổi ngôn ngữ ở mức đại diện biểu diễn [28]. Trong nghiên cứu này, chúng tôi sử dụng một cấu hình *mBART-MultiT2G*, trong đó fine-tune mBART đồng thời trên Vie-VSL và một hoặc vài corpus T2G chất lượng công




Fig. 3: Model architecture

khai (ví dụ German–DGS, Chinese–CSL), tương tự ý tưởng trong [1]. Thiết lập này cho phép khảo sát ảnh hưởng của multilingual transfer: tri thức học được từ cặp ngôn ngữ khác (với cấu trúc gloss đã được nghiên cứu kỹ) liệu có giúp ích cho Vie–VSL hay không, và mức độ phụ thuộc vào khoảng cách loại hình (ví dụ: tiếng Trung có nhiều điểm tương đồng với VSL hơn tiếng Đức, hay ngược lại).

4.5 Gloss-to-Avatar

Tại Việt Nam, cộng đồng người khiếm thính sử dụng nhiều biến thể của ngôn ngữ ký hiệu, bao gồm ba hệ thống chính: miền Bắc, miền Trung và miền Nam. Sự khác biệt về ngữ âm và ngữ nghĩa giữa các hệ thống này [45,21] tạo ra thách thức lớn trong việc phát triển các công cụ công nghệ hỗ trợ giao tiếp mang tính thống nhất. Chính vì vậy, việc chuẩn hóa và xây dựng một bộ từ điển ký hiệu trở thành một yêu cầu cấp thiết. Cụ thể, quá trình tổng hợp chuyển động được thực hiện thông qua cơ chế truy vấn phân tầng ưu tiên. Với đầu vào là chuỗi gloss từ mô hình dịch máy, hệ thống thực hiện tìm kiếm theo ba bước tuần tự:

1. **Khớp chính xác (Exact matching):** Hệ thống tra cứu trực tiếp gloss trong bộ từ điển VieSIGML đã dựng trước đó để trích xuất đoạn mã SiGML tương ứng.
2. **Thay thế đồng nghĩa (Synonym Mapping):** Trong trường hợp từ khóa đầu vào không khớp chính xác với bất kỳ từ nào, hệ thống sẽ kích hoạt cơ chế tra cứu mở rộng trên cột dữ liệu từ đồng nghĩa (Gloss Synonyms) đã được tích hợp sẵn trong bộ từ điển Vie-SiGML. Cơ chế này hoạt động bằng cách tìm xem từ khóa có nằm trong danh sách đồng nghĩa của một gloss đích nào không (ví dụ: từ khóa "má" hoặc "u" được liệt kê là đồng nghĩa của gloss gốc "mẹ"). Nếu tìm thấy, hệ thống sẽ thực hiện ánh xạ về gloss gốc để truy xuất dữ liệu chuyển động tương ứng.
3. **Đánh vần ngón tay (Fingerspelling):** Nếu cả hai bước trên đều không trả về kết quả, hệ thống sẽ kích hoạt cơ chế dự phòng bằng cách chuyển đổi từ vựng sang dạng đánh vần từng chữ cái, đảm bảo thông tin không bị mất mát trong quá trình trực quan hóa.




Fig. 4: Gloss to Avatar processing

4.5.1 HamNoSys - Hệ thống Ký hiệu hóa Hamburg: Để số hóa ngôn ngữ ký hiệu, các nhà nghiên cứu quốc tế đã phát triển HamNoSys [20]. HamNoSys cho phép mô tả chi tiết các thông số của một động tác ký hiệu một cách trừu tượng, không phụ thuộc vào ngôn ngữ ký hiệu cụ thể nào. Đây là điểm mạnh giúp nó trở thành nền tảng cho việc sinh ra các ngôn ngữ đánh dấu như SiGML. Các thông số cơ bản mà HamNoSys mô tả bao gồm:

- Hình dạng bàn tay (Handshape): Định nghĩa cấu hình chính xác của các ngón tay và bàn tay khi thực hiện ký hiệu.
- Hướng bàn tay (Orientation): Mô tả cách bàn tay quay trong không gian.
- Vị trí (Location): Xác định vị trí của bàn tay so với cơ thể.
- Chuyển động (Movement): Mô tả các dạng chuyển động của tay, chẳng hạn như di chuyển theo đường thẳng, đường cong, xoay tròn hoặc lặp lại.
- Biểu cảm (Non-manual features): Bao gồm các yếu tố phi thủ công như gương mặt, ánh mắt, chuyển động của đầu hoặc vai, các yếu tố này ảnh hưởng lớn đến ngữ nghĩa của ký hiệu.

4.5.2 SiGML – Signing Gesture Markup Language: SiGML [15] là ngôn ngữ đánh dấu dựa trên XML, được phát triển để mô tả cử chỉ ngôn ngữ ký hiệu trên nền tảng máy tính. SiGML được **sinh ra tự động** từ HamNoSys [23]. Cấu trúc rõ ràng và chuẩn hóa của SiGML không chỉ giúp dễ dàng lưu trữ và chia sẻ dữ liệu mà còn cung cấp dữ liệu đầu vào có cấu trúc cho các công cụ đồ họa và hoạt hình 3D (ví dụ: JA Signing) [15]. Khả năng này là chìa khóa để avatar




Fig. 5: Cấu trúc thành phần chính của Hamnosys




Fig. 6: Định dạng từng phần của Hamnosys

3D có thể tái hiện chính xác và trực quan các động tác ký hiệu, một mục tiêu chính của hệ thống.

Hamnosys	SigML Tag
Gloss: mạnh_mẽ	<sigml> <hns_sign gloss="mạnh_mẽ"> <hamnosys_nonmanual> <hnm_mouthgesture tag="L31"/> </hamnosys_nonmanual> <hamnosys_manual> <hamsymmlr/> <hamfist/> <hamthumbacrossmod/> <hamextfingero/> <hampalm/> <hamhead/> <hamlrat/> <hambetween/> <hamshouldertop/> <hamparbegin/> <hamfusionbegin/> <hammoved/> <hamfast/> <hamchest/> <hamfusionend/> <hamreplace/> <hamextfingero/> <hamparend/> </hamnosys_manual> </hns_sign> </sigml>
Handedness: ●●	
Hand Shape:	
Finger Direction:	
Orientation:	
Location:	
Movement:	

Fig. 7: Biểu diễn ký hiệu cho từ “mạnh mẽ” trong HamNoSys (trái) và mã hóa của nó trong SiGML (phải)

4.5.3 eSign Editor: là một công cụ hỗ trợ quá trình biên soạn và quản lý từ điển ngôn ngữ ký hiệu. Công cụ này cung cấp môi trường cho phép người dùng xây dựng, chỉnh sửa và lưu trữ các mô tả ký hiệu dựa trên hệ thống ký pháp HamNoSys . Bên cạnh đó, eSign Editor hỗ trợ chuyển đổi các mô tả HamNoSys sang định dạng SiGML .




Fig. 8: Giao diện phần mềm eSign Editor

4.5.4 Nguồn Dữ Liệu Từ Điển (QIPEDC): Nguồn dữ liệu nền tảng để xây dựng được nhóm nghiên cứu lựa chọn từ danh mục ngôn ngữ ký hiệu QIPEDC (Quỹ Phát triển Giáo dục cho Người Khiếm thính). Bộ dữ liệu này bao gồm khoảng 4000 từ và câu ký hiệu được cộng đồng người khiếm thính tại Việt Nam sử dụng .[5]

4.5.5 Bộ từ điển Vie-SiGML Quá trình xây dựng bộ từ điển Vie-SiGML được thực hiện tuần tự các bước sau:

- Từ bộ danh mục 4000 từ/câu ký hiệu QIPEDC bao gồm cả 3 miền: Bắc, Trung, Nam. Nhóm tập trung chọn lọc các từ vựng thuộc hệ thống ký hiệu miền Nam, nhằm đảm bảo tính nhất quán và tránh sự pha trộn vùng miền.
- Xây dựng tập đồng nghĩa: Để tối ưu hóa khả năng tra cứu, mỗi từ trong từ điển sẽ được gán thêm một danh sách các từ đồng nghĩa. Giảm thiểu tình trạng không tìm thấy gloss khi nhận gloss từ mô hình dịch máy chuyển sang avatar 3D.
- Mã hóa ký hiệu: Mỗi từ được biểu diễn dưới dạng ký pháp HamNoSys, mô tả chi tiết hình dạng bàn tay, hướng, vị trí và chuyển động, biểu cảm
- Xuất SiGML: Thông qua công cụ eSign Editor, các ký hiệu HamNoSys được chuyển đổi sang SiGML, đảm bảo tính chuẩn hóa và khả năng tích hợp với các hệ thống 3D avatar
- Kiểm định trực quan: Từng ký hiệu được hiển thị trên mô hình avatar 3D để kiểm tra tính chính xác, sự mượt mà của động tác, cũng như độ dễ hiểu đối với người dùng

5 Experimental Setting

5.1 Môi trường thực nghiệm

Tất cả các thí nghiệm được thực hiện trên hai loại môi trường tính toán để cân bằng giữa khả năng huấn luyện từ đầu và hiệu năng fine-tuning. Các mô hình

tiền huấn luyện và các thử nghiệm fine-tuning chính được thực hiện trên môi trường của Google Colab; trong khi đó các thử nghiệm huấn luyện transformer gốc (training from scratch) được chạy trên máy local của nhóm nghiên cứu.

Cụ thể, môi trường tính toán và phần mềm được tóm tắt như sau:

- **Cloud (Google Colab):** Sử dụng runtime GPU với NVIDIA Tesla T4 (15 GB GPU memory), bộ nhớ RAM hệ thống khoảng 12.7 GB, và dung lượng lưu trữ khả dụng xấp xỉ 235 GB. Môi trường này được dùng cho việc fine-tune các mô hình đã được pretrained, đánh giá nhanh các cấu hình hyperparameter, và chạy inference cho tập kiểm thử.
- **Local workstation:** Các thí nghiệm huấn luyện mô hình Transformer gốc (training from scratch) và một số phép thử ablation được thực hiện trên laptop Lenovo Legion R9000P ARX8 (Legion 5 Pro 16ARX8). Hệ thống được trang bị CPU AMD Ryzen 9 7945HX, GPU NVIDIA GeForce RTX 4060 Laptop (8 GB VRAM), RAM 16 GB, và SSD NVMe 1 TB.

5.2 Training Setting

Để đảm bảo so sánh công bằng giữa các backbone và các chiến lược dữ liệu, chúng tôi chuẩn hoá giao thức huấn luyện và suy luận như sau. Tất cả thí nghiệm sử dụng cùng seed (42) và cùng chiến lược giải mã với beam size = 6 và length normalization = 0.6.

Chọn checkpoint. Mô hình được chọn là checkpoint có *cross-entropy loss* thấp nhất trên tập phát triển (dev). Tiêu chí này giúp tránh việc tối ưu hoá quá mức theo một metric duy nhất và thường tương quan tốt với chất lượng sinh chuỗi đầu ra trong các bài toán NMT.

Giao thức hai giai đoạn. Quá trình huấn luyện được tổ chức theo hai giai đoạn nhằm phản ánh bản chất (i) *học biểu diễn/khởi tạo* và (ii) *thích nghi miền đích*:

- **Stage 1 – Base training / intermediate adaptation.** Giai đoạn này áp dụng cho tất cả cấu hình. Với mô hình huấn luyện từ đầu (Transformer), đây là huấn luyện cơ sở trên tập real-only hoặc các biến thể dữ liệu (trộn / synthetic). Với các mô hình tiền huấn luyện (BARTPho, mBART), Stage 1 đóng vai trò *continued pretraining* hoặc *domain/task adaptation* trên dữ liệu synthetic và/hoặc corpora Text-to-Gloss công khai. Để đảm bảo so sánh công bằng giữa các kiến trúc, chúng tôi cũng huấn luyện BARTPho và mBART theo chế độ real-only với cùng giao thức Stage 1. Ngân sách Stage 1 cố định ở 50,000 updates; validation mỗi 500 updates; early stopping với patience 20 lần validation không cải thiện; riêng các thí nghiệm sử dụng tập PHOENIX-Weather 2014T (PHOENIX14-T) và ASLG-PC12 (ASL), chúng tôi giảm ngưỡng patience xuống còn 10 do đặc tính hội tụ nhanh hơn và để giảm thiểu hiện tượng overfitting khi huấn luyện trên các bộ dữ liệu này.
- **Stage 2 – Task-specific fine-tuning on Vie-VSL.** Giai đoạn này chỉ áp dụng cho các cấu hình có fine-tune cuối trên dữ liệu thật Vie-VSL. Mô hình được khởi tạo từ checkpoint tốt nhất của Stage 1, huấn luyện tối đa 8,000 updates; validation mỗi 400 updates; early stopping với patience 5.

Thiết kế huấn luyện nhiều giai đoạn này có thể được xem như một dạng curriculum ngầm, giúp mô hình từng bước thích nghi từ các cấu trúc ngôn ngữ ký hiệu tổng quát sang các biểu đạt đặc thù của Ngôn ngữ Ký hiệu Việt Nam.

Đảm bảo nhất quán khi đánh giá. Tập dev/test luôn thuộc miền real Vie-VSL và được suy luận bằng cùng cấu hình decode để đảm bảo mọi khác biệt trong kết quả phản ánh tác động của backbone và chiến lược dữ liệu, thay vì thay đổi trong decoding.

5.3 Dataset

Vie-VSL-10k là bộ dữ liệu gồm khoảng 10,000 cặp câu tiếng Việt - Ngôn ngữ Ký hiệu Việt Nam, được xây dựng cho bài toán dịch từ câu tiếng Việt sang câu ngôn ngữ ký hiệu ở mức cấu trúc cú pháp. Khác với một số bộ dữ liệu quốc tế, trong đó các gloss được thiết kế và chuẩn hóa chủ yếu theo tiêu chuẩn từ vựng và cú pháp của ngôn ngữ ký hiệu tại từng quốc gia [1], [39], Vie-VSL-10k được phát triển với mục tiêu nhấn mạnh các đặc trưng ngữ pháp và trật tự câu riêng của VSL. Bộ dữ liệu tập trung mô tả những cấu trúc điển hình của VSL như rút gọn các từ chức năng và thay đổi trật tự thành phần câu khi chuyển từ tiếng Việt sang VSL. Bên cạnh đó, các gloss trong Vie-VSL-10k mang tính biểu diễn cấu trúc hơn là một chuẩn từ vựng hoàn thiện cho cộng đồng ký hiệu Việt.

Chúng tôi thực hiện bước tiền xử lý và loại bỏ bản sao trùng lặp, tập dữ liệu được giữ lại và chia cố định thành ba phần không giao nhau: tập huấn luyện (train) gồm 7,591 cặp, tập kiểm tra (test) gồm 1,042 cặp và tập phát triển (dev) gồm 346 cặp. Việc chia này tuân theo quy trình phân tách đảm bảo đa dạng cấu trúc và bảo toàn các lớp chất lượng.

PHOENIX-Weather 2014T (PHOENIX14-T) [17] là một bộ dữ liệu chất lượng cao được sử dụng rộng rãi trong nghiên cứu dịch ngôn ngữ ký hiệu, đặc biệt cho các bài toán Sign Language Translation và làm giàu dữ liệu [39, 29, 1]. Bộ dữ liệu được xây dựng từ các bản tin dự báo thời tiết bằng Ngôn ngữ Ký hiệu Đức (DGS), bao gồm các cặp song song giữa câu tiếng Đức và chuỗi gloss tương ứng. Trong nghiên cứu này, 7,096 mẫu trong tập huấn luyện (train) và 519 mẫu trong tập phát triển (dev) của PHOENIX14-T được sử dụng như một tập dữ liệu bổ trợ để thực hiện fine-tuning trung gian cho mô hình mBART, nhằm giúp mô hình thích nghi với tác vụ chuyển đổi từ cấu trúc ngôn ngữ nói sang cấu trúc ngôn ngữ ký hiệu trước khi fine-tuning cuối cùng trên bộ Vie-VSL-10k.

ASLG-PC12 [34] là một bộ dữ liệu song song giữa ngôn ngữ nói và chuỗi gloss của Ngôn ngữ Ký hiệu Mỹ ASL. ASLG-PC12 được xây dựng cho các bài toán dịch và phân tích cấu trúc ngôn ngữ ký hiệu, bao gồm các cặp câu tiếng Anh và chuỗi gloss ASL tương ứng. Các gloss trong ASLG-PC12 phản ánh những đặc trưng cú pháp và trật tự câu đặc thù của ASL như lược bỏ từ chức năng, sử dụng cấu trúc chủ đề-bình luận và các hình thức biểu đạt mang tính khái quát ngữ pháp. Bộ dữ liệu này cũng đã được sử dụng rộng rãi trong các nghiên cứu

về SLT và các mô hình dịch dựa trên chuỗi gloss [29]. Bộ dữ liệu có sẵn bao gồm 87,710 mẫu dữ liệu. Chúng tôi đã thực hiện bước tiền xử lý và loại bỏ bản sao trùng lặp và chia dữ liệu theo tỷ lệ 9:1 cho huấn luyện (train) và đánh giá (dev).

DailyDialog-VI [47] là bộ dữ liệu hội thoại tiếng Việt được công bố trên Hugging Face, tập trung vào các tình huống giao tiếp thường ngày trong ngữ cảnh sử dụng tiếng Việt. Bộ dữ liệu bao gồm các đoạn hội thoại nhiều lượt với nội dung đời sống hàng ngày, trải rộng trên nhiều chủ đề giao tiếp thực tế. Từ tập train chứa khoảng 11.100 đối thoại, chúng tôi trích xuất các phát ngôn và chuyển đổi chúng thành các câu độc lập, sau đó tiến hành tiền xử lý như chuẩn hóa văn bản, khử trùng lặp và lọc theo độ dài để xây dựng một tập làm giàu gồm khoảng 30.000 câu phù hợp với mục tiêu nghiên cứu. Việc sử dụng các utterance đơn lẻ phản ánh quyết định thiết kế của chúng tôi là ưu tiên mở rộng ngữ liệu câu đơn nhằm tăng cường khả năng mô hình hóa giao tiếp đời thường trong các tác vụ sinh chuỗi và supervised fine-tuning (SFT).

5.4 Models

5.4.1 Transformer Chúng tôi xây dựng baseline Transformer encoder-decoder bằng *Marian NMT* [22] nhằm đảm bảo tính tái lập và sử dụng pipeline huấn luyện/giải mã chuẩn trong dịch máy. Transformer from-scratch đóng vai trò mốc so sánh để (i) định lượng lợi ích của tiền huấn luyện (BARTPho/mBART) và (ii) phân tích tác động của dữ liệu tổng hợp trong bối cảnh bài toán cực ít tài nguyên.

Kiến trúc. Transformer baseline được cấu hình theo thiết lập nhỏ phù hợp low-resource: $N_e=2$ lớp encoder, $N_d=2$ lớp decoder; $d_{\text{model}}=512$; $h=8$ heads; $d_{\text{ff}}=2048$; dropout 0.1; label smoothing 0.1. Hàm mất mát dùng cross-entropy.

Tokenizer và tính nhất quán giữa các thiết lập dữ liệu. Khác với BARTPho/mBART (tokenizer cố định theo mô hình), Transformer yêu cầu tokenizer tự huấn luyện. Để cô lập ảnh hưởng của *quy mô dữ liệu*, chúng tôi huấn luyện SentencePiece một lần trên tập train lớn nhất (real + synthetic) và tái sử dụng *cùng tokenizer* cho mọi thiết lập Transformer. Việc giữ cố định tokenizer giúp tránh thay đổi không gian biểu diễn (phân hoạch subword và độ dài chuỗi), vốn có thể gây nhiễu khi so sánh hiệu năng giữa các cấu hình.

Miền dữ liệu và domain tags. Khi huấn luyện với dữ liệu tổng hợp, chúng tôi gắn token đặc biệt ở đầu câu nguồn để biểu thị miền: `<real>` cho dữ liệu thật và `<syn>` cho dữ liệu tổng hợp. Cách làm này là một thực hành phổ biến trong MT để giảm sai lệch phân bố giữa dữ liệu sinh và dữ liệu thật, đồng thời cho phép mô hình điều kiện hoá theo nguồn gốc dữ liệu [8,11]. Trong đánh giá, dev/test luôn gắn `<real>` để phản ánh đúng miền đích.

Các thiết lập huấn luyện. Trên cùng backbone Transformer, chúng tôi xem xét bốn cấu hình để tách bạch vai trò của dữ liệu thật/tổng hợp và hiệu quả thích nghi miền đích:

1. **Real-only:** Huấn luyện Stage 1 trên Vie-VSL-10k (Real).
2. **Syn-only:** Huấn luyện Stage 1 trên dữ liệu tổng hợp (Syn) với domain tags.
3. **Mix:** Huấn luyện Stage 1 trên tập trộn Real+Syn với domain tags.
4. **Mix→RealFT:** Stage 1 trên Mix, sau đó Stage 2 fine-tune ngắn trên Real.
5. **Syn→RealFT:** Stage 1 trên Syn, sau đó Stage 2 fine-tune ngắn trên Real.

Hai biến thể có Real-FT phản ánh chiến lược thường dùng: mô hình học tín hiệu rộng từ dữ liệu sinh/pseudo, sau đó thích nghi về miền mục tiêu bằng fine-tuning trên dữ liệu gán nhãn thật [29,8].

5.4.2 BARTpho Chúng tôi fine-tune toàn bộ mô hình BARTpho cho nhiệm vụ chuyển đổi từ văn bản tiếng Việt sang cấu trúc ngôn ngữ ký hiệu. Encoder tiếp nhận câu nguồn tiếng Việt, trong khi decoder được huấn luyện để sinh ra chuỗi gloss tương ứng, vốn có cấu trúc cú pháp khác biệt đáng kể so với ngôn ngữ viết thông thường.

Quá trình huấn luyện được thực hiện theo hai chế độ:

- **Fine-tune trực tiếp (real-only):** mô hình BARTpho được fine-tune trực tiếp trên tập Vie-VSL-10k với các siêu tham số chính gồm learning rate 3×10^{-5} , warm-up ratio = 0.2, batch size 4 với gradient accumulation = 8 và ngân sách huấn luyện theo cấu hình Stage 1.
- **Fine-tune hai giai đoạn:** ở giai đoạn 1, mô hình được huấn luyện trên dữ liệu synthetic để làm giàu với Learning rate 2×10^{-5} và warm-up ratio 0.2. Giai đoạn 2 mô hình được khởi tạo từ checkpoint tốt nhất của giai đoạn 1 và tiếp tục fine-tune trên Vie-VSL-10k với learning rate 3×10^{-5} và warm-up ratio 0.2, với ngân sách huấn luyện theo cấu hình Stage 2.

Trong cả hai chế độ, chúng tôi sử dụng tập dev của bộ Vie-VSL-10k để theo dõi quá trình huấn luyện và lựa chọn mô hình tốt nhất; việc lựa chọn mô. Các thiết lập decode để đánh giá với num beams 6, length penalty 0.6, max length 128 được giữ cố định giữa các thử nghiệm để đảm bảo so sánh công bằng nội bộ. Tất cả các thí nghiệm dùng seed cố định để đảm bảo khả năng tái lập.

5.4.3 mBart Đối với bài toán dịch Ngôn ngữ Ký hiệu tiếng Việt, dữ liệu huấn luyện có kích thước hạn chế và phân bố không đồng đều, trong khi mô hình mBART-large-50 được tiền huấn luyện trên các tập dữ liệu văn bản đa ngôn ngữ quy mô lớn. Trong bối cảnh này, fine-tuning trực tiếp mô hình tiền huấn luyện trên tập dữ liệu đích thường không đủ để khai thác hiệu quả, đồng thời dễ dẫn đến hiện tượng overfitting và khả năng tổng quát hóa kém trong môi trường tài nguyên ít. Các nghiên cứu gần đây về fine-tuning mBART cho dịch máy ngôn ngữ ít tài nguyên có thể cải thiện đáng kể hiệu năng mô hình [33,42]. Thay vì fine-tuning mô hình mBART trên nhiều ngôn ngữ ký hiệu trong một

giai đoạn duy nhất, chúng tôi lựa chọn chiến lược huấn luyện đa giai đoạn, trong đó mỗi giai đoạn chỉ sử dụng một hệ ngôn ngữ ký hiệu. Cách tiếp cận này giúp giảm thiểu hiện tượng negative transfer và sự thiên lệch tham số về các tập dữ liệu có kích thước lớn, đồng thời cho phép mô hình thích nghi dần với phân bố và cấu trúc cú pháp của ngôn ngữ ký hiệu tiếng Việt. Việc huấn luyện tuần tự theo từng miền dữ liệu cũng đóng vai trò như một hình thức curriculum learning, giúp ổn định quá trình tối ưu hóa và cải thiện khả năng tổng quát hóa trong bối cảnh dữ liệu hạn chế. Dựa trên các kết quả đó, chúng tôi thiết kế một quy trình thực nghiệm gồm năm chiến lược huấn luyện khác nhau, tương ứng với các giả thuyết nghiên cứu về tác động của: (i) huấn luyện cơ sở với dữ liệu gốc, (ii) mở rộng dữ liệu thông qua làm giàu dữ liệu, (iii) học chuyển tiếp đa ngôn ngữ trực tiếp, (iv) học chuyển tiếp đa ngôn ngữ có giai đoạn thích nghi trung gian, và (v) học chuyển tiếp đa ngôn ngữ mở rộng. Quy trình này cho phép đánh giá một cách có hệ thống mức độ mà các chiến lược huấn luyện fine-tuning có thể cải thiện hiệu năng của mô hình trên bài toán dịch Ngôn ngữ Ký hiệu tiếng Việt.

Cấu hình huấn luyện: Sau khi kiểm thử với 13 thí nghiệm khác nhau, chúng tôi lựa chọn bộ siêu tham số chính thức cho mô hình. Mô hình mBART-large-50 được fine-tune theo chiến lược nhiều giai đoạn, với độ dài chuỗi tối đa là 128. Batch size trên mỗi thiết bị được thiết lập là 4 cho cả huấn luyện và đánh giá, kết hợp với gradient accumulation bằng 8 và warm-up ratio = 0.2. Quá trình đánh giá được thực hiện định kỳ sau mỗi 500 bước cập nhật, sử dụng tập dev VieVSL để theo dõi quá trình hội tụ; mô hình tốt nhất được lựa chọn dựa trên best evaluate loss, và cơ chế early stopping được áp dụng nhằm hạn chế hiện tượng overfitting.

Quá trình huấn luyện gồm ba pha liên tiếp. Ở Phase 1, mô hình được fine-tune trên dữ liệu ASL/PHOENIX nhằm thích nghi ban đầu với cấu trúc ngôn ngữ ký hiệu, sử dụng learning rate 2×10^{-5} và warm-up ratio 0.2. Ở Phase 2, sử dụng mô hình tốt nhất dựa trên eval loss của phase 1 để tiếp tục được huấn luyện trên dữ liệu tăng cường với cùng learning rate và warm-up ratio. Cuối cùng, ở Phase 3, mô hình được khởi tạo từ mô hình tốt nhất của Phase 2 và fine-tune trên dữ liệu thực tiếng Việt với learning rate 3×10^{-5} và warm-up ratio 0.2.

Chiến lược huấn luyện: nhóm chúng tôi thiết kế một quy trình thực nghiệm bao gồm năm chiến lược huấn luyện riêng biệt. Mục tiêu là khảo sát tác động của việc làm giàu dữ liệu và học chuyển tiếp đối với hiệu năng của mô hình mbart-large-50.

– **Chiến lược 1: Huấn luyện cơ sở**

Trong chiến lược cơ sở này, mô hình được huấn luyện trực tiếp trên tập dữ liệu gốc Vie-Vsl Corpus bao gồm 10,000 cặp câu. Mục đích của chiến lược này là thiết lập một đường cơ sở để đánh giá năng lực của mô hình khi chỉ tiếp xúc với nguồn dữ liệu thực tế, chưa qua can thiệp.

– **Chiến lược 2: Huấn luyện dữ liệu gốc với dữ liệu làm giàu.**

Chiến lược này tập trung vào việc mở rộng không gian mẫu. Chúng tôi kết hợp tập dữ liệu gốc với tập dữ liệu đã được làm giàu thông qua các kỹ thuật được nhắc đến ở mục 4.2.2. Việc gia tăng kích thước và độ đa dạng của dữ

liệu huấn luyện giúp mô hình giảm thiểu nguy cơ quá khớp (overfitting) và học được các biểu diễn ngữ nghĩa bao quát hơn.

– **Chiến lược 3: Học chuyển tiếp đơn nguồn (Phoenix -> VSL)**

Chiến lược này nhằm đánh giá hiệu quả của việc chuyển giao tri thức từ tập dữ liệu lớn sang tập dữ liệu đích mà không thông qua bước đệm dữ liệu làm giàu. Quy trình bao gồm 2 giai đoạn:

- Giai đoạn 1: Huấn luyện mô hình trên bộ dữ liệu RWTH-PHOENIX-2014-T. Giai đoạn này giúp mô hình học các đặc trưng và tổng quát cấu trúc câu, từ một bộ dữ liệu chuẩn hóa quốc tế có kích thước lớn.
- Giai đoạn 2 : Tinh chỉnh trực tiếp trên tập dữ liệu gốc Vie-Vsl Corpus. Các trọng số đã học được từ Phoenix được điều chỉnh ngay lập tức để thích nghi với miền dữ liệu đích, giúp kiểm chứng khả năng tổng quát hóa trực tiếp giữa hai ngôn ngữ ký hiệu.

– **Chiến lược 4: Học chuyển tiếp có giai đoạn thích nghi**

Chiến lược này mở rộng Chiến lược 3 bằng cách bổ sung một giai đoạn huấn luyện trung gian trên dữ liệu làm giàu tiếng Việt, nhằm giảm khoảng cách ngôn ngữ giữa hai hệ thống ký hiệu khác nhau.

- Giai đoạn 1: Huấn luyện mô hình trên bộ dữ liệu RWTH-PHOENIX-2014-T. Mặc dù khác biệt về ngôn ngữ, nhưng cấu trúc cú pháp không gian của ngôn ngữ ký hiệu có những nét tương đồng . Giai đoạn này giúp mô hình làm quen với đặc trưng của ngôn ngữ ký hiệu từ một bộ dữ liệu chuẩn hóa quốc tế.
- Giai đoạn 2: Tiếp tục huấn luyện trên tập dữ liệu làm giàu . Giai đoạn này đóng vai trò cầu nối, chuyển đổi dần trọng số của mô hình từ miền ngôn ngữ ký hiệu Đức sang ngôn ngữ tiếng Việt, đồng thời làm quen với từ vựng và cấu trúc cú pháp đặc thù của VSL.
- Giai đoạn 3: Tinh chỉnh cuối cùng trên tập dữ liệu đích gốc. Lúc này, mô hình đã sở hữu các trọng số tốt, cho phép hội tụ nhanh và chính xác hơn trên tập dữ liệu mục tiêu.

– **Chiến lược 5: Học chuyển tiếp với ngôn ngữ ký hiệu nguồn khác (ASL)**

Chiến lược này nhằm đánh giá tác động của việc bổ sung thêm một ngôn ngữ ký hiệu trong quá trình học chuyển tiếp.

- Giai đoạn 1: Huấn luyện mô hình trên bộ dữ liệu ASLG-PC12
- Giai đoạn 2: Tiếp tục huấn luyện trên dữ liệu làm giàu.
- Giai đoạn 3: Tinh chỉnh cuối cùng trên tập dữ liệu đích gốc. Lúc này, mô hình đã sở hữu các trọng số tốt, cho phép hội tụ nhanh và chính xác hơn trên tập dữ liệu mục tiêu.

Mỗi giai đoạn chỉ sử dụng một ngôn ngữ ký hiệu duy nhất, cho phép mô hình lần lượt học các đặc trưng cú pháp và biểu diễn cấu trúc từ nhiều hệ thống ký hiệu khác nhau. Việc bổ sung ASL trong chiến lược này là 1 phép kiểm chứng sự thích nghi tham số trong quá trình huấn luyện, cho phép mô hình tiếp xúc với phân bố cấu trúc ký hiệu đa dạng hơn, từ đó đưa ra sự so sánh cho mô hình khi học các ngôn ngữ khác nhau.

Mặc dù các chiến lược học chuyển tiếp đều khai thác tri thức từ các ngôn ngữ ký hiệu nguồn, mục tiêu cuối cùng của hệ thống là tối ưu hiệu suất trên

VSL. Do đó, việc thích nghi cần được định hướng theo ngôn ngữ đích thay vì đồng thời tối ưu cho nhiều ngôn ngữ ký hiệu. Các ngôn ngữ ký hiệu nguồn như DGS và ASL chủ yếu đóng vai trò cung cấp tri thức khởi tạo về cấu trúc cú pháp và biểu diễn gloss nói chung. Việc thích nghi đồng thời với nhiều ngôn ngữ ký hiệu trong cùng một giai đoạn có thể dẫn đến xung đột tham số và làm suy giảm khả năng chuyên biệt hóa cho VSL, đặc biệt trong bối cảnh dữ liệu đích rất hạn chế. Vì vậy, các chiến lược được thiết kế theo hướng thích nghi tuần tự, trong đó mô hình lần lượt học từ ngôn ngữ ký hiệu nguồn, sau đó được điều chỉnh thông qua dữ liệu tiếng Việt làm giàu, và cuối cùng được tinh chỉnh hoàn toàn trên tập dữ liệu VSL gốc.

5.5 Performance Metrics

Đánh giá chất lượng chuyển đổi từ văn bản tiếng Việt sang chuỗi gloss đặt ra những thách thức đặc thù như đầu ra vừa là một chuỗi ký hiệu vừa mang các biến đổi cú pháp khác với ngôn ngữ viết thông thường. Do đó, chúng tôi áp dụng chiến lược đánh giá đa chiều kết hợp các chỉ số tự động tiêu chuẩn trong dịch máy, tương tự các nghiên cứu Text-to-Gloss trước đây [14].

Các chỉ số tự động được sử dụng nhằm phản ánh các khía cạnh khác nhau của chất lượng dịch: bảo toàn tương đồng ngữ nghĩa, chi phí chỉnh sửa, cấu trúc chuỗi và mức bao phủ từ/cụm. Việc sử dụng đồng thời nhiều chỉ số nhằm tránh thiên lệch khi chỉ dựa trên một thước đo duy nhất, đặc biệt trong bối cảnh gloss không phải là biểu diễn ngôn ngữ tự nhiên đầy đủ.

- **sacreBLEU**: sacreBLEU [36] là một triển khai chuẩn hóa cho phép tính BLEU. Chỉ số dùng các bước tokenization/normalization cố định và sinh ra một chuỗi ngăn ghi lại cấu hình do, giúp đảm bảo khả năng tái tạo và minh bạch khi so sánh điểm số giữa các công trình. BLEU tự thân đo mức trùng khớp n-gram giữa đầu ra và tham chiếu [35]. Ở cấp độ tập hợp corpus-level, BLEU thường cho tương quan hợp lý với đánh giá con người về độ chính xác nội dung và mức độ phù hợp tổng thể.
- **Translation Edit Rate (TER)**: TER [40] đo số thao tác nhỏ nhất để biến câu sinh ra thành đầu ra mong muốn. Chỉ số này phù hợp ở bài toán gloss vì các hoán vị và xóa/chèn thường xuất hiện.
- **ROUGE-L F1**: ROUGE-L [9] đo dựa trên độ dài của longest common subsequence (LCS) giữa chuỗi sinh và chuỗi tham chiếu. LCS phản ánh mức độ bảo toàn trật tự tương đối và cấu trúc chuỗi ở quy mô câu, nhờ vậy ROUGE-L đặc biệt thích hợp để phát hiện xem các thành phần quan trọng của một gloss có còn xuất hiện ở đúng trình tự tương đối hay không. Trong lĩnh vực sign language, F1-score được lựa chọn là một trong những thước đo đánh giá chuỗi gloss sinh ra [14,6].
- **COMET**: COMET [38] là một chỉ số đánh giá dựa trên mô hình học sâu, được huấn luyện trực tiếp từ dữ liệu đánh giá của con người nhằm ước lượng mức độ tương đương ngữ nghĩa giữa bản dịch sinh và bản tham chiếu. Khác với các metric dựa trên trùng khớp bề mặt như BLEU, COMET khai thác biểu diễn ngữ nghĩa ngữ cảnh để phản ánh tốt hơn mức độ phù hợp về ý

nghĩa và tính chấp nhận của câu dịch. Trong bài toán sinh gloss, COMET được sử dụng như một thước đo bổ sung nhằm đánh giá mức độ bảo toàn ngữ nghĩa, trong khi sacreBLEU phản ánh mức độ phù hợp về mặt hình thức và cấu trúc chuỗi.

6 Results and Discussions

6.1 Data Augmentation

Với các chiến lược thiết kế prompt được mô tả tại Mục 4.2, chúng tôi tiến hành đánh giá trực tiếp chất lượng các chuỗi gloss sinh GPT-4o trên tập test gloss gốc. Kết quả trong Bảng 4 cho thấy Chiến lược 1 và Chiến lược 2 đạt hiệu năng cao và ổn định nhất trên các chỉ số BLEU, TER và COMET. Ngược lại, Chiến lược 3 thể hiện chất lượng kém ổn định hơn và do đó được loại khỏi các thiết lập thí nghiệm tiếp theo. Xét đến mục tiêu sinh dữ liệu huấn luyện với yêu cầu cao về tính nhất quán, khả năng kiểm soát lỗi và độ tin cậy, chúng tôi lựa chọn Chiến lược 2 làm cấu hình chính cho quá trình sinh dữ liệu gloss tổng hợp.

Việc đánh giá này không chỉ nhằm so sánh các chiến lược prompting, mà còn đóng vai trò như một phép kiểm định chất lượng dữ liệu sinh. Cụ thể, các chuỗi gloss do LLM sinh ra được so sánh trực tiếp với tập test được chia từ dữ liệu Vie-VSL-10k ở Mục 5.3. Phép đánh giá này phản ánh năng lực của LLM trong việc học và tái hiện các ánh xạ văn bản-gloss cũng như các đặc trưng cấu trúc cú pháp của Ngôn ngữ Ký hiệu Việt Nam, qua đó đảm bảo rằng dữ liệu sinh đạt chất lượng đủ cao để được sử dụng an toàn trong các bước làm giàu dữ liệu và huấn luyện mô hình downstream.

Table 4: Kết quả đánh giá các chiến lược prompting.

	Chiến lược	BLEU	TER	COMET
Chiến lược 1		28.75	48.47	84.46
Chiến lược 2		77.77	12.44	96.29
Chiến lược 3		77.63	12.65	95.90

6.1.1 Kiểm định dữ liệu làm giàu Kết quả trong Bảng 5 cho thấy mô hình huấn luyện hoàn toàn trên dữ liệu tổng hợp (TSTR) vượt trội so với mô hình huấn luyện trên dữ liệu thực (TRTR) trên cả ba chỉ số đánh giá: BLEU tăng 9.19 điểm, TER giảm 6.92 điểm, và COMET tăng 0.06 điểm. Việc TSTR vượt TRTR là một chỉ báo mạnh mẽ cho thấy dữ liệu gloss tổng hợp không chỉ tái hiện được các pattern của dữ liệu thực, mà còn cung cấp thêm các biến thể cấu trúc và độ bao phủ cú pháp rộng hơn, từ đó giúp mô hình học được các ánh xạ văn bản-gloss mang tính khái quát hơn.

Kết quả này cung cấp bằng chứng mạnh mẽ cho thấy dữ liệu gloss tổng hợp được sinh bằng phương pháp RAG-enhanced LLM prompting với rule-based constraints có utility cao cho tác vụ Text-to-Gloss. Dữ liệu tổng hợp đã học

Table 5: So sánh hiệu năng TSTR và TRTR cho đánh giá utility của dữ liệu gloss tổng hợp.

Cấu hình	BLEU	TER	COMET
Real-only (TRTR)	62.99	27.5	0.88
Synthetic-only (TSTR)	72.18	20.58	0.94

Table 6: Kết quả Transformer trên tập test (1,041 câu).

Cấu hình	BLEU $\uparrow$	TER $\downarrow$	ROUGE-L $_{F1}$ $\uparrow$	COMET $\uparrow$
Real-only	62.99	27.50	85.62	0.878
Syn-only	72.18	20.58	89.94	0.936
Mix	86.88	10.21	94.88	0.966
Mix $\rightarrow$ RealFT	87.03	9.68	94.96	0.968
Syn $\rightarrow$ RealFT	87.00	10.65	94.35	0.960

được các ánh xạ văn bản-gloss và cấu trúc cú pháp VSL một cách có giá trị, cho phép mô hình tổng quát hóa hiệu quả sang dữ liệu thực. Điều này xác nhận rằng dữ liệu làm giàu có thể được sử dụng một cách đáng tin cậy trong các bước downstream của pipeline, bao gồm huấn luyện mô hình và lựa chọn mô hình (model selection), trong bối cảnh dữ liệu cực kỳ ít tài nguyên như Ngôn ngữ Ký hiệu Việt Nam.

6.2 Transformer

Mục tiêu và các cấu hình. Thí nghiệm với Transformer huấn luyện từ đầu được thiết kế để thiết lập đường cơ sở trong điều kiện cực ít tài nguyên và đánh giá tác động của dữ liệu gloss tổng hợp trong bối cảnh mô hình không có lợi thế tiên huấn luyện. Chúng tôi báo cáo năm cấu hình: *Real-only* (chỉ dữ liệu thật), *Syn-only* (chỉ dữ liệu tổng hợp do LLM sinh), *Mix* (kết hợp Real+Syn, có gắn domain tags), cùng hai biến thể fine-tune cuối trên dữ liệu thật là *Mix $\rightarrow$ RealFT* và *Syn $\rightarrow$ RealFT*. Trong đó, Syn-only không được xem là cấu hình triển khai cuối, mà là bước huấn luyện khởi tạo (intermediate training nhằm kiểm tra utility của dữ liệu tổng hợp và làm nền cho *Syn $\rightarrow$ RealFT*).

Kết quả định lượng trên tập kiểm thử. Bảng 6 cho thấy Transformer hưởng lợi đáng kể từ dữ liệu tổng hợp khi phải học từ đầu. Cấu hình *Syn-only* vượt *Real-only* trên toàn bộ các chỉ số, với BLEU tăng từ 62.99 lên 72.18, TER giảm từ 27.50 xuống 20.58 và COMET tăng từ 0.878 lên 0.936. Kết quả này gợi ý rằng dữ liệu tổng hợp được tạo từ LLM, dù chưa được thẩm định thủ công, vẫn cung cấp tín hiệu học có ích cho bài toán Text-to-Gloss trong bối cảnh dữ liệu thật có thể chưa đủ đa dạng về cấu trúc để mô hình tổng quát tốt.

Tuy nhiên, mô hình huấn luyện hoàn toàn trên Syn vẫn kém xa cấu hình *Mix* (BLEU 72.18 so với 86.88; TER 20.58 so với 10.21). Khoảng cách lớn này cho thấy việc mở rộng dữ liệu bằng nguồn tổng hợp không tự động chuyển thành

Table 7: Mức thay đổi do fine-tune trên dữ liệu thật (RealFT), so với Stage 1 tương ứng.

So sánh	$\Delta\text{BLEU}\uparrow$	$\Delta\text{TER}\downarrow$	$\Delta\text{ROUGE-L}_{F1}\uparrow$	$\Delta\text{COMET}\uparrow$
Mix $\rightarrow$ RealFT vs Mix	+0.15	-0.53	+0.08	+0.0025
Syn $\rightarrow$ RealFT vs Syn	+14.82	-9.93	+4.41	+0.0233

chất lượng cao trên miền đích. Một cách giải thích hợp lý là dữ liệu tổng hợp có thể tồn tại nhiều hoặc sai lệch phân bố so với Vie-VSL thật. Khi chỉ học trên Syn, mô hình tiếp xúc với nhiều mẫu cấu trúc, nhưng thiếu ràng buộc trực tiếp từ dữ liệu thật để định hướng tối ưu theo phân bố mục tiêu; hệ quả là các lỗi hoán vị, chèn/xóa hoặc lệch cấu trúc vẫn xuất hiện khi đánh giá trên test real.

Ngược lại, *Mix* đạt chất lượng tốt nhất ở Stage 1 (BLEU 86.88; TER 10.21; COMET 0.966). Điểm mạnh của cấu hình này không chỉ nằm ở số lượng mẫu lớn hơn, mà ở sự bổ trợ giữa hai nguồn dữ liệu: phần Syn mở rộng độ phủ cấu trúc và từ vựng, trong khi phần Real đóng vai trò neo miền, giúp mô hình không trôi khỏi phân bố đích trong quá trình huấn luyện. Diễn giải này cũng nhất quán với việc *Syn-only* vẫn thua xa *Mix* mặc dù đều khai thác dữ liệu tổng hợp.


Vai trò của fine-tune trên dữ liệu thật (RealFT). Ảnh hưởng của RealFT phụ thuộc mạnh vào chất lượng khởi tạo ở Stage 1. Với *Mix $\rightarrow$ RealFT*, mức cải thiện trên test tương đối nhỏ nhưng nhất quán (BLEU +0.15; TER -0.53). Điều này phù hợp với việc mô hình đã được định hướng theo miền đích ngay từ giai đoạn đầu, nên fine-tune chủ yếu đóng vai trò tinh chỉnh cuối để tối ưu hoá.

Trái lại, *Syn $\rightarrow$ RealFT* nhận được lợi ích lớn hơn nhiều từ RealFT (BLEU +14.82; TER -9.93; ROUGE-L_{F1} +4.41). Nhờ bước fine-tune trên dữ liệu thật, mô hình được kéo về đúng phân bố mục tiêu và chất lượng tăng lên gần tương đương nhóm tốt nhất. Kết quả này củng cố vai trò phù hợp nhất của Syn trong thiết lập hiện tại: Syn hữu ích để khởi tạo và mở rộng phổ mẫu, nhưng nếu dữ liệu tổng hợp chưa được kiểm chứng chất lượng, fine-tune trên Real vẫn là bước quan trọng trước khi đánh giá hoặc triển khai.



Động học huấn luyện trên tập phát triển. Hình 9 cho thấy ở Stage 1, cả ba cấu hình đều tăng nhanh trong giai đoạn đầu, sau đó bắt đầu tách biệt theo chiến lược dữ liệu. *Real-only* đạt trạng thái ổn định sớm nhưng dừng ở mức thấp, phản ánh giới hạn độ đa dạng khi huấn luyện từ đầu chỉ với 10k mẫu. *Syn-only* đạt mức cao hơn *Real-only* nhưng vẫn kém *Mix*, đồng thời đường cong có xu hướng dao động hơn, phù hợp với giả thuyết rằng dữ liệu tổng hợp còn chứa nhiễu và lệch miền. Trong khi đó, *Mix* tiếp tục cải thiện lâu hơn và đạt vùng hội tụ cao, cho thấy mô hình khai thác tốt hơn tín hiệu từ tập dữ liệu phong phú khi vừa được mở rộng độ phủ (nhờ Syn) vừa được giữ định hướng miền (nhờ Real).

Sang Stage 2, *Mix $\rightarrow$ RealFT* bắt đầu ở mức chất lượng cao và chỉ điều chỉnh nhẹ, trong khi *Syn $\rightarrow$ RealFT* cải thiện nhanh trong các updates đầu rồi dần ổn định. Đặc biệt, xu hướng giảm mạnh của TER và tăng đều của BLEU/ROUGE-

L_{F1} trong $Syn \rightarrow RealFT$ phản ánh quá trình chỉnh miền rõ rệt từ phân bố Syn về phân bố Real.



(a) BLEU theo updates.

(b) ROUGE- L_{F1} theo updates.

(c) TER theo updates.

Fig. 9: Động học huấn luyện của Transformer trên tập phát triển (dev). Mỗi biểu đồ gồm hai panel: Stage 1 và Stage 2. Dấu chấm biểu thị checkpoint tốt nhất trên dev dùng để báo cáo kết quả trên test.


6.3 BARTpho

Mô hình BARTpho, một mô hình encoder-decoder seq2seq được tiền huấn luyện quy mô lớn chuyên biệt cho tiếng Việt, cho thấy hiệu năng vượt trội so với Transformer huấn luyện từ đầu và nhìn chung cũng nhỉnh hơn các mô hình đa ngôn ngữ như mBART trong bối cảnh dữ liệu Vie-VSL hạn chế. Kết quả này cho thấy các mô hình tiền huấn luyện đơn ngữ thường học được biểu diễn cú pháp-ngữ nghĩa phù hợp hơn cho các tác vụ xử lý tiếng Việt so với các mô hình đa ngôn ngữ [44].


Dựa trên Hình 10 và hình validation theo cross-entropy Hình 12, huấn luyện real-only trên backbone hội tụ nhanh và duy trì hiệu năng cao với độ dao động nhỏ, phản ánh tính ổn định. Đối với mô hình được continued learning trên dữ liệu tổng hợp rồi tinh chỉnh trên dữ liệu thật khởi đầu thấp hơn và có biến thiên lớn hơn trong giai đoạn tinh chỉnh, nơi quan sát thấy xu hướng tăng mạnh trong giai đoạn finetune rồi giảm nhẹ về cuối. Các chỉ số COMET và ROUGE- L_{F1} ở cả hai thiết lập đều đạt mức cao sớm và chỉ dao động rất nhỏ, cho thấy chất lượng ngữ nghĩa và độ tương đồng chuỗi dài được học tốt từ giai đoạn trước; TER có xu hướng giảm và ổn định hơn sau giai đoạn finetune. Bảng 8 làm rõ ảnh hưởng thực tế của chiến lược pretrain trên dữ liệu làm giàu và finetune trên dữ liệu real khi đánh giá trên tập kiểm tra. Cụ thể với BARTpho, cấu hình real-only đạt sacreBLEU = 93.45, TER = 4.98, ROUGE-L F1 = 0.9584 và COMET = 0.9570. Sau khi bổ sung giai đoạn tiền-huấn luyện bằng dữ liệu tổng hợp và tinh chỉnh trên dữ liệu thật, BLEU giảm nhẹ xuống 93.31, trong khi TER giảm đáng kể xuống 4.21, ROUGE-L F1 tăng lên 0.9675, và COMET đạt 0.9749 (cao nhất trong tất cả các cấu hình BARTpho). Điều này cho thấy chiến lược pretrain trên dữ liệu làm giàu finetune trên real không mang lại lợi ích về mặt BLEU cho BARTpho, nhưng lại cải thiện rõ rệt chất lượng ngữ nghĩa và mức độ nhất quán chuỗi dài của bản dịch.

Những quan sát này chỉ ra một sự đánh đổi rõ ràng giữa các nhóm chỉ số. BLEU, vốn nhạy cảm với trùng khớp bề mặt n-gram, có thể không phản ánh đầy đủ các cải thiện về ngữ nghĩa và thuật ngữ mà dữ liệu tổng hợp mang lại. Ngược lại, các chỉ số như COMET và ROUGE- L_{F1} , vốn đánh giá tốt hơn sự tương đồng ngữ nghĩa và cấu trúc chuỗi dài, cho thấy lợi ích nhất quán từ dữ liệu tổng hợp. TER giảm cũng cho thấy bản dịch sau augmentation cần ít chỉnh sửa hơn để khớp với tham chiếu.


Tóm lại, với BARTpho, dữ liệu tổng hợp không nên được diễn giải như một cơ chế tối ưu BLEU, mà đúng hơn là một phương tiện cải thiện chất lượng ngữ nghĩa và giảm sai lệch cấu trúc trong bản dịch gloss. Điều này nhấn mạnh tầm quan trọng của việc đánh giá đa chỉ số trong các bài toán dịch sang ngôn ngữ ký hiệu: trong khi BLEU phản ánh mức độ trùng khớp bề mặt, các chỉ số như COMET, ROUGE- L_{F1} và TER cung cấp góc nhìn toàn diện hơn về chất lượng ngôn ngữ và tính hữu dụng thực tế của hệ thống.



(a) BLEU score



(b) ROUGE-L F1 score




(c) TER score


Fig. 10: Diễn biến các chỉ số đánh giá trong quá trình huấn luyện của mô hình BARTpho trên tập phát triển (dev). Các biểu đồ thể hiện sự thay đổi của BLEU, COMET, ROUGE- F_1 và TER theo số bước cập nhật, với so sánh giữa huấn luyện real-only, huấn luyện có tăng cường dữ liệu và fine-tuning chuyên biệt trên Vie-VSL. .

6.4 mBART


Chúng tôi tiến hành đánh giá toàn diện hiệu năng của mBART-large-50 trên tập kiểm thử Vie-VSL-10k thông qua 5 chiến lược huấn luyện. Kết quả định lượng được trình bày tại Bảng 8 và diễn biến quá trình huấn luyện được minh họa tổng thể trong Hình 11.




(a) BLEU Score



(b) ROUGE-L F1



(c) TER



(d) COMET

Fig. 11: Evolution of evaluation metrics during mBART fine-tuning across three language configurations: Phase 1 (left), Phase 2 (center), and Phase 3 (right).

6.4.1 Hiệu năng Huấn luyện Cơ sở (Baseline Performance) Tại chiến lược cơ sở, mô hình mBART thiết lập mốc hiệu năng khả quan với điểm BLEU 92.31 và TER 5.32. Quá trình huấn luyện cho thấy sự hội tụ nhanh chóng chỉ trong 2.000 cập nhật (updates) đầu tiên, tương ứng với việc chỉ số TER giảm mạnh từ 10 xuống dưới 3. Kết quả này khẳng định kiến trúc mBART cung cấp không gian hiệu quả cho tác vụ chuyển đổi cấu trúc nói sang ngôn ngữ ký hiệu ngay cả khi chỉ sử dụng nguồn dữ liệu giới hạn.

6.4.2 Tác động của Làm giàu Dữ liệu (Impact of Data Augmentation) Việc tích hợp dữ liệu tổng hợp từ LLM (Chiến lược 2) mang lại sự cải thiện rõ rệt về độ ổn định và chất lượng sinh chuỗi. Cấu hình này nâng điểm BLEU lên 93.41, giảm TER xuống 4.45 và đạt COMET 0.9612.

Cụ thể, đường cong huấn luyện của chiến lược này (màu cam, cột trái Hình 11) thể hiện sự vượt trội ngay từ giai đoạn khởi đầu. Điểm BLEU duy trì ổn định ở mức cao (94–96), trong khi chi phí chỉnh sửa (TER) giảm nhanh và sâu hơn ($\sim 2.5\text{--}3$) so với baseline. Xu hướng tương tự cũng được ghi nhận ở các chỉ số ROUGE-L và COMET, chứng minh rằng dữ liệu tổng hợp không chỉ hỗ trợ hội tụ nhanh mà còn giúp sinh ra các chuỗi gloss có cấu trúc chính xác hơn.

6.4.3 Học Chuyển tiếp Đa ngôn ngữ (Multilingual Transfer Learning) Chúng tôi phân tích tác động của học chuyển tiếp từ hai ngôn ngữ nguồn khác nhau: Tiếng Đức (PHOENIX14-T) và Tiếng Anh (ASL).

Chuyển tiếp từ PHOENIX14-T (Chiến lược 3 & 4): Việc chuyển tiếp trực tiếp từ PHOENIX14-T đạt kết quả tương đương với baseline. Tuy nhiên, khi áp dụng chiến lược thích nghi trung gian qua dữ liệu làm giàu (Chiến lược 4), hiệu năng mô hình được cải thiện đồng bộ (93.41 BLEU, 4.45 TER).

Tại thiết lập này (cột giữa Hình 11), giai đoạn thích nghi trung gian (đường cam) đã giúp làm mịn quá trình hội tụ, giảm thiểu các dao động không cần thiết thường thấy ở cấu hình chuyển tiếp trực tiếp (đường xanh). Chỉ số TER của cấu hình có làm giàu dữ liệu đạt mức thấp hơn trong giai đoạn cuối, phản ánh hiệu quả trong việc giảm chi phí chỉnh sửa.

Chuyển tiếp từ ASL (Chiến lược 5): Thử nghiệm với ASL (cột phải Hình 11) đem lại phát hiện quan trọng nhất. Cấu hình chuyển tiếp trực tiếp gặp hiện tượng chuyển giao tiêu cực nghiêm trọng, thể hiện qua sự sụt giảm đột ngột của BLEU và sự tăng vọt của TER (lên ~ 4.5) tại thời điểm 1.500 updates.

Ngược lại, khi áp dụng giai đoạn thích nghi trung gian với dữ liệu tổng hợp, hiện tượng này hoàn toàn bị loại bỏ. Dữ liệu tổng hợp đóng vai trò như một cầu nối, giúp chuyển đổi trạng thái negative transfer sang positive transfer, thể hiện qua đường cong huấn luyện tăng đều và ổn định. Kết quả là chiến lược này đạt hiệu năng cao nhất trong tất cả các thử nghiệm: **93.68 BLEU, 4.18 TER và 0.9684 ROUGE-L.**

6.4.4 Tổng kết (Discussion) Các kết quả thực nghiệm dẫn đến ba kết luận chính:

- **Vai trò cốt lõi của dữ liệu tổng hợp:** Dữ liệu sinh từ LLM là yếu tố then chốt để ổn định quá trình huấn luyện và tăng tốc độ hội tụ.
- **Hiệu quả của thích nghi miền:** Giai đoạn trung gian là bắt buộc khi thực hiện học chuyển tiếp giữa các ngôn ngữ ký hiệu có khoảng cách cú pháp lớn (như ASL và VSL), giúp ngăn chặn việc thiếu hụt dữ liệu.
- **Khả năng tổng quát hóa:** Các chỉ số ROUGE-L và COMET đều duy trì mức cao, khẳng định khả năng của mBART trong việc bảo toàn ngữ nghĩa và cấu trúc chuỗi gloss trong điều kiện ít tài nguyên.

Table 8: Đánh giá trên tập kiểm tra Vie-VSL: sacreBLEU, TER, ROUGE-L F1 và COMET. Các giá trị in đậm biểu thị điểm tốt nhất theo từng chỉ số.

Model	Training setting	BLEU		TER	ROUGE-L (F1)	COMET
Transformer	Vie-VSL-10k	62.99	27.50		0.8562	0.8782
Transformer	Vie-VSL-10k + LLM synth	86.98	10.17		0.9465	0.9618
BARTPho	Vie-VSL-10k	93.45	4.98		0.9584	0.9570
BARTPho	Vie-VSL-10k + LLM synth	93.31	4.21		0.9675	0.9749
mBART	Vie-VSL-10k	92.31	5.32		0.9594	0.9581
mBART	Vie-VSL-10k + LLM synth	93.41	4.45		0.9674	0.9612
mBART	Vie-VSL-10k + PHOENIX14-T	92.79	5.46		0.9604	0.9610
mBART	Vie-VSL-10k + PHOENIX14-T + Aug.	93.41	4.45		0.9674	0.9612
mBART	Vie-VSL-10k + ASLG-PC12	91.99	5.50		0.9584	0.9581
mBART	Vie-VSL-10k + ASLG-PC12 + LLM synth	93.68	4.18		0.9684	0.9617

6.5 Discussion

RQ1: Trong điều kiện dữ liệu Vie-VSL quy mô nhỏ, các backbone tiền huấn luyện encoder-decoder (BARTPho, mBART) cải thiện chất lượng Text-to-Gloss như thế nào so với Transformer huấn luyện từ đầu?

Kết quả cho thấy lợi ích rõ ràng của tiền huấn luyện: BARTPho đạt BLEU 93.45, mBART đạt 92.31 so với Transformer 62.99. Hơn nữa, learning curves ở Hình 12 tiết lộ cơ chế của sự cải thiện rằng cả BARTPho và mBART đạt validation loss ổn định trong vài nghìn cập nhật, phản ánh hội tụ nhanh. Transformer từ đầu hội tụ chậm hơn và dờ ở loss cao hơn đáng kể, làm rõ chi phí học tập from scratch trên dữ liệu hạn chế. Với đánh giá cho thấy rằng pretrained model hiệu quả cho Text-to-Gloss. Pre-trained models học được cấu trúc câu, semantic space, và robust representation từ dữ liệu pre-training quy mô lớn như tiếng Việt cho BARTPho, 50 ngôn ngữ cho mBART. Những biểu diễn này giao tiếp hiệu quả với tác vụ dịch có cấu trúc cho phép thích nghi nhanh chóng ngay cả với dữ liệu huấn luyện hạn chế.

RQ2: Chiến lược tăng cường dữ liệu dựa trên LLM prompting kết hợp RAG và luật cú pháp có giúp cải thiện chất lượng dịch hay không, và mức độ cải thiện có nhất quán giữa các backbone khác nhau không?




Fig. 12: Validation loss theo số cập nhật huấn luyện của Transformer huấn luyện từ đầu, mBART-large-50 và BARTPho. Các mô hình tiền huấn luyện hội tụ nhanh và ổn định hơn đáng kể so với Transformer khởi tạo ngẫu nhiên.

Kết quả thực nghiệm tại Bảng 8 cho thấy phương pháp tăng cường dữ liệu mang lại cải thiện nhất quán trên cả Transformer, BARTPho và mBART, mặc dù mức độ cải thiện khác nhau tùy backbone. Điều này chứng tỏ chiến lược tăng cường không phụ thuộc vào kiến trúc cụ thể, mà mang lợi ích tổng quát cho tác vụ Text-to-Gloss trong bối cảnh dữ liệu hạn chế.

Transformer được huấn luyện từ đầu cho thấy mức cải thiện tương đối lớn nhất khi được bổ sung dữ liệu tổng hợp. Dữ liệu tổng hợp riêng (Aug-only) nâng BLEU từ 62.99 lên 72.18 (+9.2). Khi kết hợp với dữ liệu thật (Mix) trước Stage 2 fine-tune trên real-only, BLEU đạt 86.98, và sau tinh chỉnh thêm lên 87.0 (+24.0). Tiến độ này chứng minh rằng dữ liệu tổng hợp cung cấp structural diversity essential cho Transformer từ đầu học tập biến thể cú pháp và vocabulary mở rộng. Kết quả này cho thấy dữ liệu tổng hợp cung cấp một tín hiệu huấn luyện bổ sung và mang tính hỗ trợ cho dữ liệu thật, đặc biệt trong bối cảnh dữ liệu chú giải VSL hạn chế.

Đối với BARTPho, một mô hình đã được tiền huấn luyện với biểu diễn tiếng Việt mạnh, việc bổ sung dữ liệu gloss tổng hợp tiếp tục mang lại lợi ích rõ rệt, tuy nhiên không đồng đều trên tất cả các chỉ số đánh giá. Cụ thể, như trình bày trong Bảng 8, cấu hình BARTPho với chiến lược có dữ liệu làm giàu cho thấy điểm BLEU giảm nhẹ so với huấn luyện chỉ trên dữ liệu thật (93.31 so với 93.45, giảm 0.14 điểm), trong khi các chỉ số còn lại đều cải thiện: COMET tăng từ 0.9570 lên 0.9749 (đạt cao nhất), TER giảm từ 4.98 xuống 4.21, và ROUGE-L F1 tăng từ 0.9584 lên 0.9675. Sự suy giảm nhẹ của BLEU bởi chuỗi gloss được

tạo ra bằng cách lược bỏ các từ chức năng không cần thiết và sắp xếp lại thứ tự các từ vựng gốc để phản ánh cấu trúc cú pháp của Ngôn ngữ Ký hiệu Việt Nam. Do BLEU là chỉ số nhạy với thứ tự từ và mức độ trùng khớp n-gram bề mặt, các phép tái sắp xếp và lược bỏ này có thể làm giảm điểm BLEU ngay cả khi nội dung ngữ nghĩa được bảo toàn hoàn toàn. Ngược lại, các chỉ số như COMET, TER và ROUGE-L phản ánh tốt hơn mức độ trung thành ngữ nghĩa và tính phù hợp cấu trúc của gloss sinh ra. Đặc biệt, sự cải thiện đáng kể của COMET cho thấy mô hình học được các ánh xạ văn bản-gloss ổn định và nhất quán hơn về mặt ý nghĩa. Trong bối cảnh dịch văn bản sang gloss ngôn ngữ ký hiệu, nơi mục tiêu chính là bảo toàn nội dung ngữ nghĩa và thứ tự ký hiệu thay vì trùng khớp từ vựng bề mặt.

Tương tự, với mBART, cấu hình ASL+Aug đạt BLEU 93.68 (cao nhất trong tất cả các thiết lập), cho thấy sự cải thiện đồng thời về chất lượng tuyến tính bề mặt và độ ổn định cấu trúc gloss. Kết quả này phản ánh khả năng của dữ liệu tổng hợp trong việc hỗ trợ mBART thích nghi miền hiệu quả hơn trong bối cảnh học chuyển giao đa ngôn ngữ. Khi mBART được chuyển giao trực tiếp từ ASL/Phoenix sang VSL mà không có dữ liệu tổng hợp trung gian, hiệu năng suy giảm đáng kể, cho thấy hiện tượng negative transfer do sự khác biệt về cấu trúc cú pháp và quy ước gloss giữa các ngôn ngữ ký hiệu. Việc bổ sung dữ liệu gloss tổng hợp (ASL/PHEONIX+Aug) giúp khắc phục vấn đề này, đưa hiệu năng BLEU đạt mức cao. Cơ chế dữ liệu tổng hợp hoạt động như curriculum ngầm, dần hiệu chỉnh encoder-decoder từ ASL structure về VSL structure trước khi tiếp xúc dữ liệu thật. Giai đoạn này ngăn parameter noise từ sudden domain shift — hiện tượng đã ghi nhận trong multilingual MT.

Tóm lại, chiến lược tăng cường dữ liệu dựa trên LLM kết hợp RAG và luật cú pháp cho thấy tác động tích cực tổng thể đối với nhiệm vụ Text-to-Gloss, đặc biệt ở khía cạnh chất lượng ngữ nghĩa và tính ổn định chuỗi dài. Trên hầu hết các backbone, augmentation giúp cải thiện các chỉ số đánh giá ngữ nghĩa như COMET và ROUGE-L F1, đồng thời làm giảm TER, cho thấy bản dịch sau tăng cường cần ít chỉnh sửa hơn để khớp với tham chiếu. Tuy nhiên, ảnh hưởng của augmentation lên BLEU không đồng nhất giữa các backbone: với các mô hình đã có prior ngôn ngữ mạnh như BARTPho, BLEU có thể giảm nhẹ do các phép tái sắp xếp và lược bỏ từ làm tăng độ đa dạng bề mặt. Trong khi đó, với các mô hình khởi tạo từ đầu hoặc các mô hình đa ngôn ngữ cần thích nghi miền (như Transformer và mBART), augmentation thường mang lại cải thiện đáng kể về BLEU. Trong bối cảnh học chuyển giao đa ngôn ngữ, dữ liệu tổng hợp còn đóng vai trò như một curriculum ngầm, giúp làm dịu tác động của negative transfer và cải thiện quá trình hội tụ. Do đó, việc đánh giá hiệu quả của augmentation cần dựa trên bộ chỉ số đa chiều và gắn chặt với mục tiêu ứng dụng cụ thể, thay vì chỉ dựa vào BLEU. Do đó, việc đánh giá hiệu quả của tăng cường dữ liệu trong bài toán Text-to-Gloss cần được thực hiện dựa trên một tập chỉ số đa chiều và gắn chặt với mục tiêu ứng dụng — trong đó bảo toàn ngữ nghĩa và tính phù hợp cấu trúc đóng vai trò quan trọng hơn mức độ trùng khớp từ vựng bề mặt đơn thuần.

7 Research Limitations and Future works

7.1 Research Limitations

Mặc dù đạt được các kết quả thực nghiệm khả quan, nghiên cứu này vẫn tồn tại một số hạn chế cần được nhìn nhận một cách khách quan.

Thứ nhất, bộ dữ liệu Vie-VSL-10k được xây dựng với mục tiêu trọng tâm là mô hình hóa các biến đổi cú pháp khi chuyển từ câu tiếng Việt sang cấu trúc ngôn ngữ ký hiệu, thay vì bao phủ đầy đủ vốn từ vựng của Ngôn ngữ Ký hiệu Việt Nam. Do đó, các chuỗi gloss trong bộ dữ liệu chủ yếu phản ánh trật tự và cấu trúc câu điển hình của VSL, nhưng chưa đại diện toàn diện cho các phép diễn đạt đa dạng, các cấu trúc hiếm hoặc các biến thể từ vựng theo vùng miền. Hạn chế này có thể ảnh hưởng đến khả năng tổng quát của mô hình trong các tình huống giao tiếp thực tế phức tạp hơn.

Thứ hai, bộ từ điển ánh xạ gloss-to-SiGML trong hệ thống hiện tại chỉ tập trung vào biến thể Ngôn ngữ Ký hiệu Việt Nam miền Nam nhằm đảm bảo tính nhất quán trong quá trình dựng hoạt ảnh avatar 3D. Lựa chọn này giúp kiểm soát tốt thí nghiệm nhưng đồng thời làm giảm khả năng áp dụng rộng rãi cho các cộng đồng người khiếm thính sử dụng các biến thể VSL khác như miền Bắc hoặc miền Trung.

Cuối cùng, mặc dù dữ liệu gloss tổng hợp được sinh bằng phương pháp LLM kết hợp RAG và luật cú pháp cho thấy hiệu quả cao trong các thí nghiệm downstream, việc đánh giá chất lượng dữ liệu tổng hợp hiện tại chủ yếu dựa trên các chỉ số tự động và hiệu năng huấn luyện mô hình. Nghiên cứu chưa tiến hành một quy trình thẩm định ngôn ngữ học có hệ thống với sự tham gia của chuyên gia ngôn ngữ ký hiệu, do đó vẫn có khả năng tồn tại các sai lệch tinh vi về ngữ pháp hoặc ngữ dụng trong một phần dữ liệu tổng hợp.

7.2 Future Work

Các hướng nghiên cứu tiếp theo của công trình này tập trung vào việc mở rộng tài nguyên, chuẩn hóa biểu diễn và cải tiến pipeline sinh dữ liệu nhằm nâng cao khả năng tổng quát hóa và độ tin cậy khi triển khai thực tế. Cụ thể, trong các nghiên cứu tiếp theo, bộ dữ liệu Vie-VSL sẽ được mở rộng về quy mô và phạm vi từ vựng bằng cách thu thập thêm các câu tự nhiên, trải đều các tình huống giao tiếp khác nhau.

Mở rộng từ điển Vie-SiGML: bộ từ điển Vie-SiGML sẽ được mở rộng để bao phủ các ký hiệu hiện có và các biến thể vùng miền, nhằm giảm sự phụ thuộc vào một biến thể ký hiệu đơn lẻ, giúp cải thiện độ chính xác khi dựng hoạt ảnh 3D và phù hợp hơn với phong cách ký hiệu của toàn quốc gia. Hướng phát triển này cũng bao gồm việc thiết kế quy trình kiểm định hiển thị avatar có sự tham gia của người sử dụng VSL và chuyên gia, tương tự các quy trình đánh giá định tính trong các nghiên cứu gần đây về sinh gloss và dựng avatar, nhằm đảm bảo tính phù hợp ngôn ngữ và tính tự nhiên của hoạt ảnh trong các bối cảnh sử dụng khác nhau.

Cải tiến cơ chế tăng cường dữ liệu: các nghiên cứu tiếp theo sẽ tập trung vào việc cải tiến cơ chế truy hồi và sinh dữ liệu theo hướng có nhận thức cấu trúc (structure-aware), trong đó các đặc trưng cú pháp và mẫu chuyển đổi sẽ được tích hợp trực tiếp vào chỉ số truy hồi và chiến lược chọn ví dụ. Cách tiếp cận này nhằm giảm thiên lệch theo các mẫu cấu trúc phổ biến trong kho luật và kho truy hồi, đồng thời tăng mức độ bao phủ đối với các cấu trúc hiếm.

Tích hợp phản hồi chuyên gia và lọc dữ liệu làm giàu: dữ liệu làm giàu sẽ được mở rộng theo hướng human-in-the-loop, trong đó một phần dữ liệu tổng hợp sẽ được thẩm định thủ công bởi chuyên gia ngôn ngữ ký hiệu để phục vụ hiệu chỉnh prompt, huấn luyện bộ lọc chất lượng, hoặc hiệu chỉnh các quy tắc sinh dữ liệu. Hướng tiếp cận này phù hợp với các nghiên cứu gần đây cho thấy việc kết hợp đánh giá tự động với thẩm định của chuyên gia giúp cải thiện đáng kể độ tin cậy và chất lượng ngôn ngữ của dữ liệu tổng hợp trong các kịch bản ít tài nguyên. Tổng thể, các hướng phát triển này nhằm hướng tới một hệ thống dịch tiếng Việt sang VSL có khả năng mở rộng, chuẩn hóa tốt hơn và phù hợp hơn với các kịch bản triển khai ngoài thực tế.

8 Conclusions

Trong bài báo này, chúng tôi đề xuất một kiến trúc mô-đun để chuyển đổi tiếng Việt nói thành Ngôn ngữ Ký hiệu Việt Nam trong điều kiện dữ liệu hạn chế. Hệ thống gồm ba khối chính: ASR chuyển đổi giọng nói thành văn bản tiếng Việt; mô-đun Text-to-Gloss dựa trên các mô hình seq2seq Transformer (bao gồm Transformer khởi tạo từ đầu, BARTPho, và mBART) và mô-đun ánh xạ từ gloss sang SiGML để dựng avatar 3D thông qua bộ tổng hợp ký hiệu (JASigning). Để khắc phục thiếu hụt dữ liệu, chúng tôi áp dụng chiến lược làm giàu bằng cách dùng LLM với cơ chế RAG và quy tắc ngôn ngữ ký hiệu, tạo ra hàng chục ngàn cặp câu giả có gloss tương ứng. Các đóng góp chính của nghiên cứu bao gồm thiết kế pipeline toàn diện từ ASR đến avatar 3D, thực nghiệm phương pháp làm giàu tổng hợp có kiểm soát trên ngôn ngữ ký hiệu Việt Nam và xây dựng và so sánh hệ thống dịch sử dụng nhiều mô hình backbone và chiến lược huấn luyện khác nhau.

Kết quả thực nghiệm trả lời tích cực cả hai câu hỏi nghiên cứu. Thứ nhất, các mô hình tiền huấn luyện encoder-decoder (BARTPho và mBART) vượt trội Transformer từ đầu trong điều kiện dữ liệu hạn chế, hội tụ nhanh và đạt BLEU cao. Thứ hai, chiến lược tăng cường dữ liệu LLM+RAG mang lợi ích nhất quán trên cả ba backbone, Transformer hưởng lợi lớn nhất (+24 BLEU từ 62.99 lên 86.98), mBART cải thiện đồng đều trên tất cả metrics, trong khi BARTPho có sự đánh đổi mang tính đặc thù BLEU giảm nhẹ -0.14 nhưng COMET tăng đáng kể (+0.019, +2%) và TER giảm mạnh (-0.77, -15%). Sự phân tán này phản ánh tương tác giữa pre-trained representation và synthetic data quality. BARTPho với dữ liệu tổng hợp LLM chất lượng cao nâng cao semantic fidelity (ưu tiên của SLT) mặc dù lexical diversity tăng, còn mBART với cross-lingual transfer hưởng lợi từ cả lexical và semantic improvements.

Tổng kết, công trình đã chứng minh một giải pháp thiết thực giúp cầu nối thông tin giữa người nói tiếng Việt và cộng đồng khiếm thính thông qua ngôn ngữ ký hiệu. Hệ thống đề xuất không chỉ mở đường cho việc ứng dụng công nghệ dịch máy vào ngôn ngữ ký hiệu Việt mà còn đóng góp bộ tài nguyên và phương pháp luận mới cho cộng đồng nghiên cứu. Kết quả nghiên cứu là một bước đầu tiên đầy hứa hẹn, và chúng tôi mong rằng hướng đi này sẽ tiếp tục được mở rộng, hoàn thiện để phục vụ tốt hơn cho nhu cầu giao tiếp và tiếp cận thông tin của người khiếm thính.

References

1. Abdullah, S.M., Paul, A., Rayana, S., Kabir, A., Masud, Z.: State-of-the-art translation of text-to-gloss using mbart: A case study of bangla. *arXiv preprint arXiv:2504.02293* (2025)
2. Alaghband, M., Maghroor, H.R., Garibay, I.: A survey on sign language literature. *Machine Learning with Applications* **14**, 100504 (2023)
3. Amodei, D., Ananthanarayanan, S., Anubhai, R., Bai, J., Battenberg, E., Case, C., Casper, J., Catanzaro, B., Cheng, Q., Chen, G., et al.: Deep speech 2: End-to-end speech recognition in english and mandarin. In: *International conference on machine learning*. pp. 173–182. PMLR (2016)
4. Baevski, A., Zhou, Y., Mohamed, A., Auli, M.: wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in neural information processing systems* **33**, 12449–12460 (2020)
5. Bộ Giáo dục và Đào tạo, Việt Nam: Danh mục ngôn ngữ ký hiệu. <https://qipedc.moet.gov.vn/dictionary> (2026), truy cập ngày 05 tháng 01 năm 2026
6. Camgoz, N.C., Hadfield, S., Koller, O., Ney, H., Bowden, R.: Neural sign language translation. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 7784–7793 (2018)
7. Camgoz, N.C., Koller, O., Hadfield, S., Bowden, R.: Sign language transformers: Joint end-to-end sign language recognition and translation. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. pp. 10023–10033 (2020)
8. Caswell, I., Chelba, C., Grangier, D.: Tagged back-translation. In: *Proceedings of the Fourth Conference on Machine Translation (Volume 1: Research Papers)*. pp. 53–63. Association for Computational Linguistics (2019)
9. Chin-Yew, L.: Rouge: A package for automatic evaluation of summaries. In: *Proceedings of the Workshop on Text Summarization Branches Out, 2004* (2004)
10. Chiruzzo, L., McGill, E., Egea-Gómez, S., Saggion, H.: Translating spanish into spanish sign language: Combining rules and data-driven approaches. In: *Proceedings of the fifth workshop on technologies for machine translation of low-resource languages (LoResMT 2022)*. pp. 75–83 (2022)
11. Chu, C., Dabre, R., Kurohashi, S.: An empirical comparison of domain adaptation methods for neural machine translation. In: *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)* (2017)
12. De Sisto, M., Vandeghinste, V., Egea Gómez, S., De Coster, M., Shterionov, D., Saggion, H., Calzolari, N., Bechet, F., Blache, P., Choukri, K., et al.: Challenges

- with sign language datasets for sign language recognition and translation. In: Proceedings of the 13th International Conference on Language Resources and Evaluation (LREC). pp. 2478–2487. EUROPEAN LANGUAGE RESOURCES ASSOCIATION (ELRA) (2022)
13. Egea Gómez, S., Chiruzzo, L., McGill, E., Saggion, H.: Linguistically enhanced text to sign gloss machine translation. In: International Conference on Applications of Natural Language to Information Systems. pp. 172–183. Springer (2022)
 14. Egea-Gómez, S., McGill, E., Saggion, H.: Syntax-aware transformers for neural machine translation: The case of text to sign gloss translation. In: Proceedings of the 14th workshop on building and using comparable corpora (BUCC 2021). pp. 18–27 (2021)
 15. Elliott, R., Glauert, J., Jennings, V., Kennaway, R.: An overview of the siglml notation and siglmlsigning software system. *sign-lang@ LREC 2004* pp. 98–104 (2004)
 16. Fang, S., Chen, C., Wang, L., Zheng, C., Sui, C., Tian, Y.: Signllm: Sign language production large language models. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 6622–6634 (2025)
 17. Forster, J., Schmidt, C., Koller, O., Bellgardt, M., Ney, H.: Extensions of the sign language recognition and translation corpus *rwth-phoenix-weather*. In: LREC. pp. 1911–1916 (2014)
 18. Gong, J., Foo, L.G., He, Y., Rahmani, H., Liu, J.: Llms are good sign language translators. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 18362–18372 (2024)
 19. Guo, J., Li, P., Cohn, T.: Bridging sign and spoken languages: Pseudo gloss generation for sign language translation. *arXiv preprint arXiv:2505.15438* (2025)
 20. Hanke, T.: Hamnosys—representing sign language data in language resources and language processing contexts. In: *sign-lang@ LREC 2004*. pp. 1–6. European Language Resources Association (ELRA) (2004)
 21. Hương, N.T., Hà, T.L.P., Sương, N.T.: Một số Đặc Điểm về ngôn ngữ ký hiệu thành phố hồ chí minh
 22. Junczys-Dowmunt, M., Grundkiewicz, R., Dwojak, T., Hoang, H., Heafield, K., Neckermann, T., Seide, F., Germann, U., Fikri Aji, A., Bogoychev, N., Martins, A.F.T., Birch, A.: Marian: Fast neural machine translation in C++. In: Proceedings of ACL 2018, System Demonstrations. pp. 116–121. Association for Computational Linguistics, Melbourne, Australia (July 2018), <http://www.aclweb.org/anthology/P18-4020>
 23. Kaur, K., Kumar, P.: Hamnosys to siglml conversion system for sign language automation. *Procedia Computer Science* **89**, 794–803 (2016)
 24. Khanh, D.: Visl model: The model automatically generates sentences of vietnamese sign language. *Journal Scientific and Technical Of Information Technologies, Mechanics and Optics* **157**(5), 779 (2024)
 25. Le, T.T., Nguyen, L.T., Nguyen, D.Q.: Phowhisper: Automatic speech recognition for vietnamese. *arXiv preprint arXiv:2406.02555* (2024)
 26. Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., Zettlemoyer, L.: Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. In: Proceedings of the 58th annual meeting of the association for computational linguistics. pp. 7871–7880 (2020)
 27. Liang, Z., Li, H., Chai, J.: Sign language translation: A survey of approaches and techniques. *Electronics* **12**(12), 2678 (2023)

28. Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., Zettlemoyer, L.: Multilingual denoising pre-training for neural machine translation. *Transactions of the Association for Computational Linguistics* **8**, 726–742 (2020)
29. Moryossef, A., Yin, K., Neubig, G., Goldberg, Y.: Data augmentation for sign language gloss translation. *arXiv preprint arXiv:2105.07476* (2021)
30. Najib, F.M.: Sign language interpretation using machine learning and artificial intelligence. *Neural Computing and Applications* **37**(2), 841–857 (2025)
31. Ngo, T.D., Nguyen, D.H.L., Luong, H.L.: Sign language representation using virtual characters with 3d animation. *VNU Journal of Science: Computer Science and Communication Engineering* **41**(1 (2025)) (2025)
32. Ngõn, N.C., Đa, Q.L.: Application of hamnosys and avatar 3d jasingning to construction of vietnamese sign language animations. *Tạp chí Khoa học và Công nghệ-Đại học Đà Nẵng* pp. 61–65 (2017)
33. Nwe, H.M., Shirai, K., Kertkeidkachorn, N., Theeramunkong, T., Thu, Y.K., Supnithi, T., Kaothanthong, N.: Enhancing translation of myanmar sign language by transfer learning and self-training. In: *Proceedings of Machine Translation Summit XIX, Vol. 1: Research Track*. pp. 111–122 (2023)
34. Othman, A., Jemni, M.: English-asl gloss parallel corpus 2012: Aslg-pc12. In: *sign-lang@ LREC 2012*. pp. 151–154. European Language Resources Association (ELRA) (2012)
35. Papineni, K., Roukos, S., Ward, T., Zhu, W.J.: Bleu: a method for automatic evaluation of machine translation. In: *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*. pp. 311–318 (2002)
36. Post, M.: A call for clarity in reporting bleu scores. *arXiv preprint arXiv:1804.08771* (2018)
37. Radford, A., Kim, J.W., Xu, T., Brockman, G., McLeavey, C., Sutskever, I.: Robust speech recognition via large-scale weak supervision. In: *International conference on machine learning*. pp. 28492–28518. PMLR (2023)
38. Rei, R., Stewart, C., Farinha, A.C., Lavie, A.: Comet: A neural framework for mt evaluation. *arXiv preprint arXiv:2009.09025* (2020)
39. Roudra, N.A., Saha, N., Shahriyar, R., Sakib, S.: Introducing a Bangla sentence gloss pair dataset for Bangla sign language translation and research. Ph.D. thesis, BRAC University (2025)
40. Snover, M., Dorr, B., Schwartz, R., Micciulla, L., Makhoul, J.: A study of translation edit rate with targeted human annotation. In: *Proceedings of the 7th Conference of the Association for Machine Translation in the Americas: Technical Papers*. pp. 223–231 (2006)
41. Tan, S., Khan, N., An, Z., Ando, Y., Kawakami, R., Nakadai, K.: A review of deep learning-based approaches to sign language processing. *Advanced Robotics* **38**(23), 1649–1667 (2024)
42. Thillainathan, S., Yuan, S., Lee, E.S.A., Jayasena, S., Ranathunga, S.: Beyond vanilla fine-tuning: Leveraging multistage, multilingual, and domain-specific methods for low-resource machine translation. *arXiv preprint arXiv:2503.22582* (2025)
43. Tran, A.V., Hoang, Q.H., Pham, T.V.H., et al.: Vietnamese sign language alphabet recognition using deep learning and mediapipe methods. *JST: Smart Systems and Devices* **35**(1), 10–19 (2025)
44. Tran, N.L., Le, D.M., Nguyen, D.Q.: Bartpho: pre-trained sequence-to-sequence models for vietnamese. *arXiv preprint arXiv:2109.09701* (2021)
45. Đức Tồn, N., Phương, N.T.: Mấy vấn Đề cú pháp của ngôn ngữ ký hiệu Ở việt nam

46. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: Attention is all you need. *Advances in neural information processing systems* **30** (2017)
47. vietgpt: vietgpt/daily_dialog_vi. https://huggingface.co/datasets/vietgpt/daily_dialog_vi, hugging Face dataset. Accessed: 2026-01-25
48. Vương, H.T.: Đặc điểm biểu đạt ngôn ngữ ký hiệu của người điếc việt nam. *Nghiên cứu Giáo dục Đặc biệt* (2011)
49. Ye, J., Jiao, W., Wang, X., Tu, Z., Xiong, H.: Cross-modality data augmentation for end-to-end sign language translation. *arXiv preprint arXiv:2305.11096* (2023)
50. Yin, K., Read, J.: Better sign language translation with stmc-transformer. *arXiv preprint arXiv:2004.00588* (2020)
51. Zhang, X., Duh, K.: Approaching sign language gloss translation as a low-resource machine translation task. In: *Proceedings of the 1st International Workshop on Automatic Translation for Signed and Spoken Languages (AT4SSL)*. pp. 60–70 (2021)
52. Zhou, B., Chen, Z., Clapés, A., Wan, J., Liang, Y., Escalera, S., Lei, Z., Zhang, D.: Gloss-free sign language translation: Improving from visual-language pretraining. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. pp. 20871–20881 (2023)
53. Zhu, D., Czehmann, V., Avramidis, E.: Neural machine translation methods for translating text to sign language glosses. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. pp. 12523–12541 (2023)